Aprendizaje y Comportamiento Adaptable: Principios y Modelos

Arturo Bouzas

22 March 2026

En esta página

1 Notas de Aprendizaje y Comportamiento Adaptable **5**

Prefacio **6**
1.0.1 Prefacio . . . 6

2 Prefacio **7**
2.1 Principios y Modelos . . . 7
2.2 ¿Para Quién es Este Libro? . . . 7
2.3 Filosofía del Libro . . . 7
2.3.1 Marco Conceptual Unificado . . . 7
2.3.2 Énfasis en Principios Generales . . . 8
2.3.3 Implementación Computacional . . . 8
2.3.4 Simuladores Interactivos . . . 8
2.4 Cómo Usar Este Libro . . . 8
2.4.1 Para Estudiantes . . . 8
2.4.2 Para Instructores . . . 8
2.5 Recursos Adicionales . . . 9
2.6 Licencia y Uso . . . 9
2.7 Agradecimientos . . . 9
2.8 Contacto . . . 9
2.9 Aviso: Libro en Desarrollo . . . 10

3 Introducción **11**
3.1 Un Problema de Diseño . . . 11
3.2 El Problema con la Enseñanza Tradicional . . . 12
3.3 Un Problema Adaptativo Fundamental . . . 12
3.4 Dos Componentes Esenciales . . . 13
3.5 Dos Orígenes de Soluciones . . . 13
3.6 Mecanismos Reutilizables: Las “Tuercas y Tornillos” . . . 14
3.7 El Enfoque de Este Libro . . . 14
3.7.1 Una Perspectiva Ingenieril . . . 14
3.8 Mapa del Curso . . . 15
3.8.1 Bloque 0: Fundamentos Conceptuales (Capítulos 0-3) . . . 15
3.8.2 Bloque I: Mecanismos Sin Integración de Historia (Capítulos 4-5) . . . 15

3.8.3 Bloque II: El Problema del Conocimiento - Asignación de Crédito (Capítulos 6-10) . . . 15
3.8.4 Bloque III: El Problema de la Acción - Elección y Optimización (Capítulos 11-15) . . . 15
3.8.5 Bloque IV: Aprendizaje Secuencial . . . 16
3.8.6 Bloque V: Incertidumbre y Estados Ocultos . . . 16
3.9 Cómo Usar Estas Notas . . . 16
3.9.1 Para el Estudiante: Estrategias de Lectura Activa . . . 16
3.9.2 Para el Instructor . . . 17
3.10 Un Argumento Final . . . 18

4 Modelos y Explicación **20**
4.1 La Visión Ortodoxa y Sus Límites . . . 20
4.1.1 El Problema de la Asimetría . . . 21
4.2 De Teorías a Modelos . . . 21
4.2.1 Los Modelos como Vehículos de Inferencia . . . 22
4.3 La Pluralidad de Formas de Explicar . . . 22
4.3.1 Explicación Causal . . . 23
4.3.2 Explicación Mecanicista . . . 23
4.3.3 Explicación Unificadora . . . 23
4.4 Niveles de Análisis . . . 24
4.4.1 El Marco de Tinbergen . . . 24
4.4.2 El Marco de Killeen . . . 24
4.4.3 El Marco de Marr . . . 24
4.4.4 Progresión Científica: De Descripciones a Explicaciones . . . 25
4.5 Van Fraassen: La Explicación como Respuesta a Preguntas . . . 26
4.6 Una Nota sobre los Modelos de Datos . . . 26
4.7 Síntesis . . . 27
4.8 Ejercicios de Comprensión . . . 27

5 Teoría de la Selección Natural **28**
5.1 La Variabilidad y el Ajuste al Entorno . . . 28
5.2 Los Tres Principios de la Selección Natural . . . 29
5.3 Las Fuentes de la Variabilidad . . . 30
5.4 El Entorno como Filtro . . . 30
5.5 La Selección Natural como Algoritmo de Búsqueda . . . 31
5.5.1 El Espacio Fenotípico y el Paisaje Adaptativo . . . 31
5.5.2 Restricciones: Qué Regiones del Espacio Son Accesibles . . . 32
5.5.3 El Problema de los Óptimos Locales . . . 32
5.5.4 Cuando el Paisaje Cambia . . . 33
5.6 Otros Factores Evolutivos . . . 34
5.7 Modelando el Cambio: Ecuaciones en Diferencia . . . 34
5.8 Covarianza: La Relación entre Rasgo y Éxito Reproductivo . . . 35

5.9 La Ecuación del Cambio Evolutivo . . . 36
5.10 La Equivalencia con los Modelos de Aprendizaje . . . 37
5.10.1 El Problema de la Asignación de Crédito . . . 37
5.11 Conexiones con el Resto del Curso . . . 38
5.12 Resumen . . . 38

6 Preguntas de Estudio — Capítulo 2: Evolución y Adaptación 40
6.1 Sección I: Comprensión conceptual . . . 40
6.2 Sección II: Restricciones y espacio fenotípico . . . 40
6.3 Sección III: El modelo matemático . . . 41

7 El Papel de las Restricciones en la Evolución del Comportamiento Adaptable 42
7.1 Las Restricciones del Organismo . . . 42
7.2 Las Restricciones del Entorno . . . 43
7.3 Dos Tipos de Algoritmos Adaptativos . . . 44
7.4 Las Propiedades Estadísticas del Entorno . . . 44
7.5 Conclusión . . . 46

8 Preguntas de Estudio 48
8.0.1 Sección I: Restricciones del organismo y del entorno . . . 48
8.0.2 Sección II: Comportamiento adaptado y comportamiento adaptable . . . 48
8.0.3 Sección III: Los dos tipos de algoritmos adaptativos . . . 48
8.0.4 Sección IV: Las propiedades estadísticas del entorno . . . 49

9 Ascenso de Colina 50
9.1 Un Mecanismo de Adaptación Sin Historia . . . 50
9.2 El Problema Adaptativo . . . 50
9.3 El Comportamiento Observado . . . 51
9.3.1 Plantas . . . 51
9.3.2 La Salmonela . . . 51
9.3.3 La Pregunta Crucial: ¿Simultánea o Sucesiva? . . . 54
9.3.4 La Adaptación Sensorial . . . 54
9.4 El Algoritmo . . . 56
9.5 Formalización Matemática . . . 58
9.5.1 Un Ejemplo Numérico . . . 58
9.6 Lo que el Ascenso de Colina Hace y No Hace . . . 59
9.7 Conexiones . . . 60
9.7.1 Hacia atrás: Selección Natural . . . 60
9.7.2 Hacia adelante: Aprendizaje por Refuerzo . . . 60
9.7.3 Lateral: Sistemas de Retroalimentación (Próximo Capítulo) . . . 60

10 Resumen 62
10.1 Ejercicios de Comprensión . . . 62

1 Notas de Aprendizaje y Comportamiento Adaptable

Prefacio

1.0.1 Prefacio

2 Prefacio

2.1 Principios y Modelos

Este libro es una edición revisada y extendida del libro de notas Aprendizaje y Comportamiento Adaptable. Su origen se encuentra en las presentaciones que desarrollé a lo largo de los años para los tres cursos de Aprendizaje y Comportamiento Adaptable que imparto en la Facultad de Psicología de la UNAM. El libro ofrece una introducción rigurosa pero accesible a los principios y modelos del aprendizaje y comportamiento adaptable. A diferencia de los textos que suelen organizarse como un catálogo histórico de protocolos experimentales (condicionamiento clásico, instrumental, etc.), este libro se estructura alrededor de problemas de adaptación. Aquí no solo preguntamos qué hacen los organismos, sino qué problemas están resolviendo y qué algoritmos han evolucionado para resolverlos.

2.2 ¿Para Quién es Este Libro?

1. **Estudiantes de licenciatura** en psicología, neurociencia o ciencia cognitiva que buscan ir más allá de la descripción verbal y desean una introducción a los modelos matemáticos del comportamiento adaptable. Se asume conocimiento básico de matemáticas a nivel bachillerato. Si necesitas refrescar estos temas, consulta los tutoriales en Bouzas Lab.
2. **Estudiantes de posgrado** que necesitan un puente conceptual para conectar psicología experimental con la neurociencia computacional y el aprendizaje de máquinas (machine learning).
3. **Profesionales en transición** de física, matemáticas, ingeniería o ciencias de la computación hacia neurociencia o ciencia cognitiva. El libro aprovecha principios cuantitativos que ya conoces para introducirte al estudio formal del comportamiento.

2.3 Filosofía del Libro

2.3.1 Marco Conceptual Unificado

La introducción presenta el marco general que guía al libro. Aprenderás a distinguir entre nivel computacional (¿qué problema adaptativo se resuelve?), nivel algorítmico (¿qué procedimientos

generan el comportamiento?), y nivel de implementación (¿qué circuitos neuronales lo realizan?). Este marco evita confusiones comunes y te permite entender por qué diferentes tipos de modelos coexisten sin competir.

2.3.2 Énfasis en Principios Generales

En lugar de memorizar el resultado de protocolos particulares, aprenderás algoritmos generales necesarios para la solución de diferentes problemas de adaptación.

2.3.3 Implementación Computacional

Todos los modelos en este libro son implementables. No son solo ecuaciones abstractas: puedes programarlos, simularlos y experimentar con ellos.

2.3.4 Simuladores Interactivos

Este libro incluye simuladores embebidos y enlaces a notebooks interactivos (Google Colab) donde puedes manipular parámetros y observar resultados inmediatos, implementar algoritmos desde cero, replicar experimentos clásicos y explorar extensiones creativas. Accede a todos los simuladores y tutoriales de matemáticas en Lab 25.

2.4 Cómo Usar Este Libro

2.4.1 Para Estudiantes

Estas notas están diseñadas para lectura activa, no pasiva. Lee la Introducción completa antes de continuar con los capítulos, ya que establece el marco conceptual necesario. Cuando un capítulo menciona un simulador, explóralo antes de seguir leyendo. La Introducción contiene estrategias detalladas de lectura activa que maximizarán tu aprendizaje.

2.4.2 Para Instructores

Este libro puede usarse como texto principal en un curso de dos semestres sobre aprendizaje y comportamiento adaptable, como complemento a un texto tradicional añadiendo la perspectiva formal y de optimización que esos textos omiten, o como recurso para temas específicos. Los simuladores permiten clases invertidas donde los estudiantes exploran antes de clase, y el tiempo presencial se dedica a discusión, resolución de problemas y profundización conceptual. La Introducción incluye sugerencias específicas para implementar este modelo pedagógico.

2.5 Recursos Adicionales

Todos los recursos (simuladores, código fuente, tutoriales) están disponibles en:
Lab 25

Para reportar errores o contribuir al proyecto, visita el repositorio GitHub.

2.6 Licencia y Uso

Este libro se distribuye bajo licencia Creative Commons BY-NC-SA 4.0. Esto significa que puedes compartir (copiar y redistribuir el material) y adaptar (remezclar, transformar y construir sobre el material) bajo las siguientes condiciones: debes dar crédito apropiado (Atribución), no puedes usar el material con fines comerciales (No Comercial), y si remezclas debes distribuir bajo la misma licencia (Compartir Igual).

2.7 Agradecimientos

La primera edición del libro mejoró significativamente gracias al excelente trabajo editorial de Rodrigo Álvarez. La estructura de esta página web fue adaptada del diseño original de Christian Badillo, quien siempre apoyó que este proyecto se concretara.

Mi agradecimiento a varias generaciones del Laboratorio 25 por desarrollar los simuladores interactivos que se encuentran en la página del Laboratorio.

Finalmente, extiendo un agradecimiento especial a los cientos de estudiantes que en mis cursos han sufrido pacientemente mis intentos por enseñar los principios fundamentales del estudio del comportamiento adaptable.

La elaboración de esta página web fue financiada por los proyectos PAPIME PE309624 y PAPIME PE302221.

2.8 Contacto

Arturo Bouzas
Facultad de Psicología
Universidad Nacional Autónoma de México
arbouria@unam.mx
Lab 25

2.9 Aviso: Libro en Desarrollo

Este es un proyecto vivo. El contenido se actualiza regularmente basándose en feedback de estudiantes e instructores, nuevos desarrollos en el campo, y mejoras en simuladores y código. Verifica el repositorio GitHub para la versión más reciente.

Versión actual: v1.0 (Enero 2026)

¿Listo para comenzar? Pasa a la **Introducción al Curso**

3 Introducción

"Lo que no puedo crear, no lo entiendo." — Richard Feynman

3.1 Un Problema de Diseño

Cada mañana, antes de comenzar su día, Wall-E hace lo mismo: conecta su panel solar y recarga su batería. Este ritual aparentemente simple revela algo profundo. Wall-E enfrenta el problema fundamental que comparten todos los agentes adaptativos, desde bacterias hasta algoritmos de inteligencia artificial: cómo distribuir el comportamiento en el tiempo y en el espacio para maximizar la obtención de recursos necesarios para sobrevivir, funcionar o cumplir sus objetivos.

Imagina que te encargan diseñar un robot explorador similar a Wall-E para un planeta desconocido. La tarea del robot es localizar recursos dispersos en un terreno accidentado, evitar peligros y encontrar fuentes de energía que le permitan recargar y gestionar su limitada reserva energética. Para ello, cuentas con sensores imperfectos (cámaras con ruido, detectores químicos de sensibilidad limitada), un procesador con capacidad finita, y restricciones severas de tiempo y energía. ¿Qué capacidades mínimas debe tener este robot para sobrevivir?

Necesitará, al menos:

Sensores que transformen energía física en señales procesables, distinguiendo información útil del ruido ambiental. Wall-E usa sus cámaras para distinguir objetos compactables de obstáculos peligrosos.

Navegación que le permita moverse hacia concentraciones de recursos detectadas a distancia. Cuando Wall-E detecta un objeto de interés, no se mueve aleatoriamente sino que se dirige directamente hacia él.

Aprendizaje predictivo que le permita anticipar dónde aparecerán recursos basándose en señales previas. Si cierta formación rocosa predice agua cercana, o si cierto tipo de escombros suele contener objetos valiosos, el robot debe aprender estas regularidades. Wall-E aprende que ciertos contenedores suelen tener objetos brillantes que le interesan.

Sistemas de elección que le permitan decidir racionalmente entre opciones cuando los recursos son múltiples y los comportamientos compiten entre sí. Wall-E debe decidir constantemente:

¿sigo compactando basura o busco un lugar seguro antes del anochecer? ¿Persigo ese objeto brillante interesante o regreso a cargar energía?

Este es exactamente el problema que enfrentan todos los organismos vivos. Una rata buscando alimento, una bacteria navegando gradientes químicos, un estudiante decidiendo cuánto tiempo dedicar a cada materia, un algoritmo de ajedrez evaluando jugadas—todos enfrentan variantes del mismo desafío fundamental: cómo distribuir su comportamiento en el tiempo y en el espacio para maximizar la obtención de recursos necesarios para sobrevivir, reproducirse o cumplir sus objetivos.

Este curso estudia las soluciones biológicas y computacionales a este problema. Pero antes de construir ese robot (o de entender cómo funcionan los organismos) debemos confrontar un problema pedagógico previo.

3.2 El Problema con la Enseñanza Tradicional

La estrategia pedagógica tradicional para enseñar aprendizaje y comportamiento adaptable, reflejada en la organización típica de los libros de texto, presenta casi exclusivamente las principales regularidades empíricas derivadas de más de 100 años de investigación, organizadas alrededor de protocolos experimentales específicos: condicionamiento clásico (Pavlov), condicionamiento operante (Skinner), programas de refuerzo, y quizás, si tuvo suerte, una clase sobre el modelo de Rescorla-Wagner y el principio de igualación de Herrnstein. Si bien este enfoque tiene valor histórico y permite apreciar la riqueza empírica del campo, puede dejar frecuentemente al estudiante con la impresión de que este es un área de conocimiento estática, fragmentada y predominantemente de interés histórico, llena de hallazgos aislados y con escasa coherencia conceptual.

Los estudiantes terminan ese curso sin una visión coherente de los principios que unifican estos fenómenos, ni una comprensión de por qué este campo sigue siendo relevante en el siglo XXI. Los hallazgos aparecen desconectados entre sí y, peor aún, desconectados de desarrollos contemporáneos en neurociencias, inteligencia artificial, economía conductual y teoría de la decisión.

Este curso adopta una estrategia diferente.

3.3 Un Problema Adaptativo Fundamental

En el centro de este curso está el problema biológico fundamental que mencionamos al inicio: cómo distribuir el comportamiento en el tiempo y en el espacio para maximizar la obtención de recursos necesarios para sobrevivir y reproducirse. Los agentes biológicos y no biológicos deben aprender qué aspectos de su entorno predicen recompensas y castigos, y deben usar ese conocimiento para elegir cursos de acción que maximicen su éxito.

3.4 Dos Componentes Esenciales

El estudio del comportamiento adaptable busca los principios que permiten resolver este problema. Podemos descomponerlo en dos componentes fundamentales:

1. El Problema del Conocimiento: ¿Cómo detectar y aprender las propiedades estadísticas de la distribución de recursos relevantes desde el punto de vista biológico y psicológico? Es decir, ¿cómo aprender a predecir aquello fundamental para la supervivencia y reproducción? Este es el problema de la asignación de crédito: cuando un recurso aparece (o un peligro se presenta), ¿a cuál de los múltiples eventos, señales o acciones previas debe asignarse la responsabilidad? ¿Qué predice qué?

2. El Problema de la Acción: ¿Cómo usar eficientemente ese conocimiento para distribuir óptimamente el comportamiento en el tiempo y en el espacio? Dado que sabemos algo sobre dónde y cuándo aparecen los recursos, ¿cómo decidimos qué hacer? Este es el problema de la elección bajo restricciones: el tiempo es finito, los comportamientos compiten entre sí, y las decisiones tienen costos de oportunidad.

Estas dos preguntas (¿qué predice qué? y ¿qué hago ahora?) organizan todo el curso.

3.5 Dos Orígenes de Soluciones

Las soluciones a estos problemas adaptativos tienen dos orígenes temporales diferentes:

1. Soluciones Filogenéticas (Selección Natural): En entornos relativamente constantes a lo largo de generaciones, la selección natural puede codificar directamente en el genoma las respuestas apropiadas. El resultado es lo que llamamos comportamiento adaptado: reflejos, instintos, sesgos perceptuales y atencionales que no requieren aprendizaje individual. Un ejemplo es la impronta en aves: los patitos siguen al primer objeto en movimiento que ven después de nacer, típicamente su madre.

2. Soluciones Ontogenéticas (Aprendizaje): En entornos variables, volátiles e inciertos (la norma para la mayoría de los organismos), la selección natural no puede anticipar todas las contingencias. En estos casos, evoluciona algo diferente: mecanismos que permiten comportamiento adaptable, la capacidad de ajustar el comportamiento a la estructura estadística de los sucesos biológicamente importantes, dentro de la vida del organismo. A esto le llamamos aprendizaje.

3.6 Mecanismos Reutilizables: Las "Tuercas y Tornillos"

A lo largo del curso identificaremos un conjunto pequeño de mecanismos generales (verdaderas "tuercas y tornillos" en el cajón de herramientas de la adaptación) que aparecen una y otra vez en diferentes contextos. A estos mecanismos los llamaremos algoritmos:

Algoritmos de comparación (sucesiva vs. simultánea): Detectar diferencias entre estados del mundo.

Algoritmos de reducción de error: Ajustar predicciones cuando difieren de resultados observados.

Algoritmos para la exploración vs. explotación: El dilema entre muestrear nuevas opciones y aprovechar lo conocido.

Algoritmos de sistemas de retroalimentación: Sistemas cerrados donde la acción modifica las condiciones que la provocan.

Algoritmos para la optimización bajo restricciones: Encontrar la mejor distribución posible de comportamiento dadas las limitaciones del entorno.

Estos mecanismos y algoritmos son implementados tanto en agentes no biológicos (robots), como en agentes biológicos (sean unicelulares o humanos), y pueden estudiarse tanto a nivel conductual como neuronal.

3.7 El Enfoque de Este Libro

3.7.1 Una Perspectiva Ingenieril

Este curso adopta lo que podríamos llamar una perspectiva ingenieril: tratamos el comportamiento como una solución a problemas adaptativos específicos. Para cada fenómeno, preguntaremos no solo "¿qué hacen los organismos?" sino también:

¿Qué problema adaptativo están resolviendo? (¿Por qué esto es importante para sobrevivir y reproducirse?)

¿Qué debería hacer un agente ideal? (¿Cuál es la solución óptima dado el problema y las restricciones?)

¿Cómo lo logran? (¿Qué algoritmos o mecanismos implementan esa solución o se aproximan a ella?)

3.8 Mapa del Curso

El libro está organizado en bloques temáticos que siguen la lógica del problema adaptativo que planteamos al inicio. Cada bloque añade una capacidad funcional a nuestro "agente adaptativo", construyendo progresivamente desde mecanismos simples hasta sistemas complejos de toma de decisiones:

3.8.1 Bloque 0: Fundamentos Conceptuales (Capítulos 0-3)

Establecemos el marco teórico general: niveles de explicación, el problema de la adaptabilidad, y la teoría de la selección natural como primera solución. Aquí definimos qué significa "adaptarse" y por qué necesitamos modelos mecanicistas en lugar de solo descripciones empíricas.

3.8.2 Bloque I: Mecanismos Sin Integración de Historia (Capítulos 4-5)

Estudiamos dos mecanismos fundamentales que permiten adaptación en tiempo real sin requerir integración de experiencias pasadas: ascenso de colina (comparación sucesiva) y sistemas de retroalimentación (comparación simultánea). Estos son las "tuercas y tornillos" más básicas. Nuestro agente aprende a navegar y a mantener condiciones internas estables, pero vive completamente en el "ahora".

3.8.3 Bloque II: El Problema del Conocimiento - Asignación de Crédito (Capítulos 6-10)

Abordamos el problema central: cuando un reforzador aparece, ¿a qué se le asigna el crédito? Primero revisamos modelos clásicos de aprendizaje asociativo (Rescorla-Wagner) y sus extensiones contemporáneas, incluyendo modelos basados en teoría de la información y filtros bayesianos. Nuestro agente deja de ser puramente reactivo y aprende a predecir el futuro.

3.8.4 Bloque III: El Problema de la Acción - Elección y Optimización (Capítulos 11-15)

Dado que hemos aprendido qué predice qué, ¿cómo distribuimos nuestro comportamiento? Estudiamos la ley del efecto, programas de refuerzo, la ley de igualación, y culminamos con modelos de optimización en equilibrio que integran economía conductual. Nuestro agente ahora conecta su conocimiento con la acción y aprende a elegir racionalmente.

3.8.5 Bloque IV: Aprendizaje Secuencial

Extendemos el análisis a secuencias de acciones donde el reforzador aparece al final (problema de asignación de crédito temporal). Introducimos algoritmos de aprendizaje por refuerzo: diferencias temporales, Q-learning, Actor-Crítico. Nuestro agente aprende a planificar secuencias de acciones hacia metas distantes.

3.8.6 Bloque V: Incertidumbre y Estados Ocultos

Finalmente, relajamos el supuesto de que el agente siempre sabe en qué estado del mundo se encuentra. Estudiamos entornos volátiles y modelos bayesianos avanzados. Nuestro agente aprende a razonar bajo incertidumbre profunda sobre el estado del mundo.

3.9 Cómo Usar Estas Notas

3.9.1 Para el Estudiante: Estrategias de Lectura Activa

Estas notas están diseñadas para construcción progresiva de comprensión. No son para lectura lineal pasiva. Aquí las estrategias que maximizarán tu aprendizaje:

Antes de cada capítulo: Lee el título y el primer párrafo. Formula una pregunta concreta que esperas que el capítulo responda. Por ejemplo, antes del capítulo sobre Rescorla-Wagner, pregúntate: "¿Cómo aprende un organismo qué señales predicen recompensas y cuáles son irrelevantes?" Esta pregunta explícita activará tu atención selectiva durante la lectura.

Durante la lectura: Lee con lápiz y papel a la mano. Cuando aparece una ecuación, desarróllala. Verifica las derivaciones. Sustituye números concretos y calcula resultados. Por ejemplo, si el texto presenta la ecuación de Rescorla-Wagner, calcula manualmente los primeros cinco ensayos de un protocolo de condicionamiento antes de ver el resultado en el simulador. Esta aparente "pérdida de tiempo" es en realidad la forma más eficiente de aprendizaje profundo. La mayoría de las confusiones matemáticas se disuelven cuando calculas casos específicos con números reales.

Usa los simuladores inmediatamente y sin restricciones. Cuando un capítulo menciona un simulador, ve a explorarlo antes de seguir leyendo. No esperes a "terminar de leer" para experimentar. La secuencia óptima es: lee la presentación del problema adaptativo, explora el simulador libremente durante 10-15 minutos, regresa al texto para la formalización matemática, vuelve al simulador para validar tu comprensión con casos extremos.

En el simulador, prueba valores extremos intencionalmente. Si hay un parámetro (tasa de aprendizaje), no solo uses =0.3. Prueba =0.01 (aprendizaje extremadamente lento), =0.99 (aprendizaje casi instantáneo), =1.0 (caso límite). Rompe el modelo intencionalmente para

entender sus límites. ¿Qué pasa si todos los parámetros son cero? ¿Y si todos son máximos? Solo después de romperlo y ver qué falla, regresa al texto para consolidar por qué esas condiciones son problemáticas.

Sé paciente con las matemáticas. Algunas ecuaciones parecerán opacas al inicio. Esta incomodidad es normal y esperada. Regresa a ellas después de explorar el simulador. La intuición precede a la formalización. Si una ecuación no tiene sentido la primera vez, marca la página y continúa. Frecuentemente, un ejemplo posterior o un simulador específico iluminará retrospectivamente lo que parecía oscuro. Si después de ver el simulador y regresar al texto una ecuación sigue siendo opaca, ese es el momento de pedir ayuda, no antes.

Conecta con tus experiencias. Cada mecanismo que estudiamos opera también en tu comportamiento cotidiano. Esta no es una sugerencia decorativa sino una estrategia pedagógica fundamental. Cuando leas sobre descuento temporal, dedica cinco minutos a analizar tu última procrastinación: ¿qué valor inmediato preferiste sobre qué beneficio futuro? Cuando estudies ascenso de colina, observa durante tu próxima ducha cómo buscas el punto óptimo al ajustar la temperatura del agua: ¿haces cambios grandes o pequeños? ¿Cómo decides cuándo has encontrado el óptimo? Estas conexiones personales anclan la teoría abstracta en la experiencia vivida, transformándola de "contenido para memorizar" a "herramienta para comprender tu propio comportamiento".

Organiza revisiones activas periódicas. Después de completar tres capítulos, antes de continuar, dedica una sesión a responder: ¿Qué problema adaptativo resuelve cada mecanismo? ¿Qué tienen en común los tres algoritmos? ¿En qué se diferencian? Si tuvieras que diseñar un robot con esas capacidades, ¿en qué orden las implementarías y por qué? Esta metacognición consolida el aprendizaje más efectivamente que releer pasivamente.

3.9.2 Para el Instructor

Estas notas permiten múltiples configuraciones pedagógicas. La más efectiva en nuestra experiencia es el modelo de clase invertida. Asigna la lectura de un capítulo más la exploración libre del simulador correspondiente como tarea previa a clase. Usa el tiempo presencial para tres actividades específicas:

Primera parte (20 minutos): Resolución de dudas sobre la formalización matemática. No expliques las ecuaciones desde cero; más bien, identifica las confusiones específicas que surgieron durante la lectura. Frecuentemente, las dudas reflejan intuiciones correctas formuladas imprecisamente. Tu trabajo es ayudar a los estudiantes a articular lo que ya entendieron implícitamente a través del simulador.

Segunda parte (30 minutos): Discusión de las implicaciones teóricas de lo observado en el simulador. Plantea preguntas como: "Cuando aumentaron a 0.9, ¿qué pasó con la estabilidad del aprendizaje? ¿Por qué? ¿En qué situaciones ecológicas sería adaptativo tener

alto vs. bajo?" Estas preguntas fuerzan conexión entre el fenómeno observable y los principios subyacentes.

Tercera parte (20 minutos): Conexión del mecanismo con fenómenos reales en neurociencias o aplicaciones. Por ejemplo, después del capítulo sobre aprendizaje por diferencias temporales, discute cómo las neuronas dopaminérgicas implementan exactamente ese algoritmo. O después del capítulo sobre programas de refuerzo, analiza cómo los juegos de azar explotan esos principios.

Los simuladores y notebooks de Google Colab permiten extender el análisis más allá del libro. Asigna proyectos donde los estudiantes modifiquen el código para responder preguntas originales. Por ejemplo: "El modelo de Rescorla-Wagner asume que es constante. Modifica el código para que disminuya con la experiencia. ¿Cómo cambia el comportamiento? ¿Esto es más o menos adaptativo?"

Cada bloque temático es relativamente autocontenido, aunque se beneficia de la lectura secuencial. Si usas este libro como complemento a un texto tradicional organizado por protocolos, puedes asignar capítulos específicos como lecturas paralelas que proporcionan la formalización matemática que el texto principal omite.

3.10 Un Argumento Final

Muchos colegas me han dicho que es imposible enseñar estos temas (aprendizaje por refuerzo, modelos bayesianos, teoría de la información) a nivel introductorio. Que los estudiantes de licenciatura no tienen las herramientas matemáticas. Que es mejor mantener el enfoque tradicional, descriptivo, organizado por protocolos, que tiene el mérito probado de décadas de uso efectivo.

Entiendo esta perspectiva y reconozco el valor del enfoque clásico. La organización por protocolos experimentales tiene ventajas pedagógicas reales: permite apreciar la riqueza empírica del campo y conecta directamente con la literatura histórica. Sin embargo, creo que podemos y debemos complementar ese enfoque con algo adicional.

Los estudiantes de hoy crecieron con algoritmos de recomendación, navegación GPS y juegos con IA. Tienen una intuición operativa sobre aprendizaje de máquinas que generaciones previas no tenían. Esta familiaridad informal representa una oportunidad pedagógica única: lo que necesitamos es tender puentes entre esa intuición y los principios formales que el campo ha descubierto.

Los simuladores interactivos, los ejemplos concretos y la conexión explícita con aplicaciones contemporáneas construyen esos puentes. Las matemáticas no necesitan ser una barrera; pueden ser una revelación. Cuando un estudiante manipula los parámetros del modelo de Rescorla-Wagner y observa cómo emerge el bloqueo, la ecuación deja de ser un símbolo opaco y se convierte en una descripción precisa de un proceso observable. Cuando experimenta con

diferentes programas de refuerzo en el simulador y luego ve cómo la ley de igualación predice cuantitativamente la distribución de respuestas, las matemáticas se revelan como el lenguaje natural para expresar regularidades empíricas.

Además, el comportamiento adaptable no es solo historia: es un campo activo con aplicaciones en robótica, neurociencias computacionales, economía conductual y políticas públicas. Los mismos principios que explicamos aquí operan en algoritmos que determinan qué videos te recomienda YouTube, en modelos de neurociencias que estudian adicción, en políticas de salud pública que buscan modificar comportamientos de riesgo. Complementar el conocimiento de los fenómenos clásicos con comprensión de los principios formales permite a los estudiantes participar en estos desarrollos contemporáneos.

Estas notas son un experimento pedagógico. No buscan reemplazar los textos tradicionales sino complementarlos, ofreciendo una perspectiva adicional. Son un recurso abierto, en evolución, diseñado para estudiantes interesados en conectar el estudio clásico del aprendizaje con desarrollos contemporáneos en ciencia cognitiva, neurociencia computacional e inteligencia artificial.

Si funcionan para ti (como estudiante o instructor) compártelas. Si encuentras errores, omisiones o secciones poco claras, comunícamelo. Este es un proyecto colaborativo en el mejor espíritu de la ciencia abierta.

4 Modelos y Explicación

Cuando los científicos son tomados desprevenidos y se les pregunta cuál es el propósito de su actividad, la mayoría dirá que es "explicar" un fenómeno. Pero cuando se les pregunta qué entienden por explicar, las respuestas divergen —a veces radicalmente. En psicología esto es especialmente visible: hay investigadores que consideran que describir con precisión una relación funcional entre variables ya constituye una explicación completa, y otros que solo aceptan como explicación la identificación del mecanismo neuronal que produce el comportamiento. Con frecuencia, ambos grupos hablan de los mismos datos experimentales.

Este capítulo propone que buena parte de esa divergencia no refleja desacuerdos sobre los hechos, sino preguntas diferentes que se responden con herramientas diferentes. Entender qué tipos de preguntas existen —y qué tipo de estructura necesita una respuesta para cada una— es uno de los recursos intelectuales más útiles que puedes llevar a la lectura de la literatura científica. Para desarrollarlo necesitamos entender primero qué son los modelos y después qué significa explicar.

4.1 La Visión Ortodoxa y Sus Límites

Los psicólogos del segundo tercio del siglo XX compartían con los filósofos de su época una imagen de la teoría científica como un conjunto de leyes generales, de las cuales se podían derivar —por deducción— fenómenos individuales o patrones entre ellos. Las leyes relacionaban términos teóricos no directamente observables (como "pulsión" o "hábito") con variables medibles, mediante reglas de correspondencia que anclaban lo abstracto a lo empírico. El objetivo declarado era construir sistemas hipotético-deductivos tan completos como los que la física había desarrollado para el movimiento de los planetas o para los gases.

En este esquema, *explicar* un fenómeno significaba derivarlo lógicamente de las leyes. Si observamos que un animal corre más rápido en cierta condición, la explicación consiste en mostrar que esa velocidad se sigue de los valores de las variables teóricas postuladas por la teoría. Esta visión de la explicación —derivación lógica de un fenómeno a partir de leyes generales— es lo que Carl Hempel llamó el modelo nomológico-deductivo (ND).

El modelo ND tenía una virtud: era explícito y formalizable. Pero enfrentó un problema que resultó fatal.

4.1.1 El Problema de la Asimetría

Supongamos que llegamos tarde al trabajo una mañana porque el tráfico estaba congestionado. La explicación parece perfectamente razonable: el tráfico causó el retraso. Ahora nota que con la misma estructura lógica podríamos "derivar" el estado del tráfico a partir del retraso: si sabemos cuánto tarde normalmente y cuánto tardé esta mañana, puedo calcular el estado probable del tráfico. Sin embargo, intuitivamente algo está mal. El retraso no explica el tráfico; la relación va en una sola dirección.

Este problema, conocido como el problema de la asimetría, fue identificado por el propio Hempel. La explicación tiene una *dirección* que la relación lógica por sí sola no captura. Esa dirección tiene que ver con la causalidad: el tráfico causó el retraso, y no al revés. El modelo ND no distingue las dos direcciones porque es indiferente a la causalidad: desde su perspectiva, la deducción funciona en ambos sentidos.

Esta falla obligó a los filósofos a reconocer que la causalidad debe desempeñar un papel central en la explicación. Pero incorporarla adecuadamente requirió, primero, repensar qué es una teoría científica, lo que condujo al surgimiento de la noción de modelo como unidad básica de la práctica científica.

4.2 De Teorías a Modelos

En la práctica real, los científicos de la segunda mitad del siglo XX dejaron paulatinamente de buscar leyes universales y comenzaron a construir modelos: el modelo de la doble hélice del ADN, los modelos de dinámica poblacional, los modelos epidemiológicos de una infección, los modelos de oferta y demanda en economía. En los capítulos que siguen encontraremos modelos del aprendizaje asociativo, de la asignación del comportamiento a distintas alternativas, y del aprendizaje por refuerzo. Todos comparten una característica: son representaciones simplificadas de alguna parte del mundo que permiten entender, predecir o intervenir sobre ella.

¿Qué es exactamente un modelo? Una manera útil de pensarlo: un modelo es una estructura —matemática, computacional, o diagramática— que representa un fenómeno mediante una relación de semejanza estructural con él. Un mapa del metro es un modelo: no reproduce cada detalle de los vagones ni la arquitectura de las estaciones, pero preserva las relaciones relevantes —qué líneas conectan qué estaciones— de forma que permite al viajero navegar el sistema. Un modelo de clima no es el clima; es una estructura que captura las interacciones dinámicas entre variables atmosféricas de forma que permite hacer predicciones útiles.

Podemos tener distintos modelos del mismo fenómeno para distintos propósitos. Un mapa que muestra solo las líneas y los puntos de transferencia es útil para llegar de un punto a otro; un mapa con información turística sobrepuesta es útil para quien visita por primera vez una ciudad. Ninguno es "el correcto" en abstracto; cada uno es correcto para su propósito. Lo

mismo ocurre con los modelos en psicología: no hay un único modelo del aprendizaje que sea definitivo, sino modelos que responden preguntas distintas con distintos niveles de resolución.

4.2.1 Los Modelos como Vehículos de Inferencia

Hay una discusión importante sobre cuál es exactamente la relación entre un modelo y el fenómeno que representa. Una respuesta influyente (Suppes, van Fraassen) es que esa relación es de *isomorfismo estructural*: el modelo representa exitosamente un fenómeno cuando existe una correspondencia que preserva las relaciones relevantes entre la estructura del modelo y la estructura del fenómeno empírico. Consideremos la medición de la estatura: queremos asignar números a personas de forma que se preserve la relación "más alto que". Si A es más alta que B, el número asignado a A debe ser mayor. La medición es exitosa cuando existe ese isomorfismo entre la estructura empírica Personas, más-alta-que y la estructura numérica Números, $>$.

Esta cuenta del isomorfismo tiene méritos: hace preciso qué se requiere del modelo y guía la investigación hacia la pregunta de si la estructura empírica satisface los axiomas del modelo. En capítulos posteriores veremos que medir preferencias es problemático precisamente porque las preferencias humanas a veces violan la transitividad —una condición que el isomorfismo con los números requeriría.

Pero para este libro, una concepción más amplia resulta más útil: la visión *inferencialista* de Mauricio Suárez. Para Suárez, lo que hace que una estructura sea un modelo de un fenómeno no es que sean isomórficas, sino que el modelo *permite al usuario hacer inferencias sobre el fenómeno* en el contexto adecuado. No se requiere semejanza estructural precisa; se requiere que el modelo funcione como vehículo inferencial. Un modelo de optimización del forrajeo no es isomórfico al comportamiento de un animal buscando alimento, pero permite inferir qué patrones de búsqueda deberíamos observar si el animal está bien adaptado. Un algoritmo de aprendizaje por refuerzo no replica la fisiología neuronal, pero permite inferir cómo cambiará la conducta ante diferentes distribuciones de recompensa.

Esta concepción es más cercana a cómo los científicos usan sus modelos en la práctica, y más apropiada para un libro que incorpora modelos de optimización, algoritmos computacionales y simuladores interactivos. La pregunta que debemos hacerle a un modelo no es "¿es isomórfico al fenómeno?" sino "¿qué inferencias permite hacer, y son esas inferencias empíricamente productivas?"

4.3 La Pluralidad de Formas de Explicar

Con la noción de modelo en mano, podemos volver al problema de la explicación. Veremos que no hay un único tipo de explicación científica válida; hay varios tipos, cada uno apropiado para un tipo de pregunta.

4.3.1 Explicación Causal

Una forma de explicar consiste en identificar los *hacedores de diferencia*: los factores que, al variar, producen variación en el fenómeno de interés. Decir que A causa B es afirmar que intervenciones sobre A producirán cambios sistemáticos en B, y que en circunstancias contrafactuales donde A no ocurriera, B tampoco ocurriría.

La noción moderna de causalidad se articula típicamente en tres formas complementarias. Primero, en términos de contrafactuales: A causa B si, en el mundo más cercano al actual donde A no ocurre, B tampoco ocurriría. Segundo, en términos de intervenciones: A causa B si manipular A (manteniendo todo lo demás constante) produce cambios sistemáticos en B. Tercero, en términos de hacedores de diferencia: A es un hacedor de diferencia para B si la variación en A, dentro del rango relevante, produce variación en B.

Estas tres formulaciones son relacionadas pero enfatizan aspectos distintos. Los contrafactuales enfatizan la estructura modal —qué hubiera ocurrido en circunstancias distintas. Las intervenciones enfatizan la manipulabilidad experimental. Los hacedores de diferencia enfatizan la identificación de los factores que realmente importan para el fenómeno, abstrayendo de condiciones de fondo necesarias pero no explicativas.

4.3.2 Explicación Mecanicista

Una segunda forma de explicar consiste en especificar un mecanismo: identificar los componentes del sistema, su organización, y las interacciones entre componentes que producen el fenómeno. Un mecanismo no es solo una caja negra que transforma inputs en outputs; es una descripción de cómo esa transformación ocurre en términos de partes y operaciones.

La explicación mecanicista es particularmente satisfactoria porque no solo identifica qué causa qué, sino *cómo* lo causa. Permite predecir qué ocurriría si un componente fallara, o cómo modificar el sistema para producir resultados distintos.

4.3.3 Explicación Unificadora

Una tercera forma de explicar consiste en mostrar que fenómenos aparentemente diversos son instancias de un patrón común. La explicación por unificación reduce el número de patrones independientes que debemos aceptar. Newton unificó la caída de los cuerpos terrestres y el movimiento de los planetas bajo la ley de gravitación universal. Darwin unificó la diversidad de adaptaciones bajo el principio de selección natural. En los capítulos siguientes veremos cómo el principio de reducción del error de predicción unifica fenómenos de condicionamiento clásico, instrumental, y aprendizaje por refuerzo.

4.4 Niveles de Análisis

Los fenómenos complejos pueden analizarse en múltiples niveles, y diferentes niveles responden diferentes tipos de preguntas. Dos marcos han sido especialmente influyentes en las ciencias del comportamiento.

4.4.1 El Marco de Tinbergen

Niko Tinbergen propuso que cualquier comportamiento puede estudiarse mediante cuatro preguntas complementarias: causación próxima (¿qué mecanismos inmediatos lo producen?), ontogenia (¿cómo se desarrolla en el individuo?), función (¿qué problema adaptativo resuelve?), y filogenia (¿cómo evolucionó en la especie?). Estas preguntas no compiten; son complementarias. Una comprensión completa de un comportamiento requiere respuestas en los cuatro niveles.

4.4.2 El Marco de Killeen

Peter Killeen propone un vocabulario derivado de la distinción aristotélica entre tipos de causas, adaptado para las ciencias del comportamiento: *subyace* (¿qué sustrato físico lo soporta?), *induce* (¿qué variables lo producen?), *logra* (¿qué función adaptativa cumple?), y *representa* (¿qué estructura formal lo describe?). Este vocabulario es el que encontrarás en el programa oficial del curso y en parte de la literatura. Su equivalencia aproximada con los marcos de Tinbergen y Marr es la siguiente: *subyace* corresponde al nivel de implementación, *induce* al nivel algorítmico y mecanismo próximo, *logra* a la función adaptativa, y *representa* al nivel computacional y a los modelos formales matemáticos.

4.4.3 El Marco de Marr

David Marr propuso un marco para entender los sistemas cognitivos que refleja exactamente esta división del trabajo. Argumentó que para entender completamente un sistema que procesa información (sea un cerebro, una bacteria o un algoritmo), debemos analizarlo en tres niveles distintos y complementarios:

El nivel *computacional* pregunta qué computa el sistema y por qué —define el problema en términos abstractos sin comprometerse con cómo se resuelve. El nivel *algorítmico* pregunta cómo lo computa —especifica los procedimientos y representaciones mediante los cuales el sistema realiza esa computación. El nivel de *implementación* pregunta en qué sustrato físico ocurre esa computación.

Marr enfatizó que cada nivel es parcialmente autónomo—puede ser estudiado independientemente de los otros niveles. Pero también están interrelacionados—restricciones en un nivel afectan los otros niveles. Podemos entender el problema computacional sin saber el algoritmo

o la implementación. Del mismo modo, podemos estudiar algoritmos abstractamente sin saber su implementación neural específica. Sin embargo, el análisis computacional restringe los algoritmos apropiados. No cualquier algoritmo resolverá el problema; debe ser uno que compute la función correcta dados las entradas y restricciones especificadas a nivel computacional. Adicionalmente, los algoritmos deben ser implementables con el hardware disponible.

Reconociendo la interdependencia de niveles, Marr argumentó que el análisis a nivel computacional debería guiar el análisis a otros niveles. Sin entender qué problema está resolviendo un sistema, es difícil entender el papel de los algoritmos que usa. El análisis computacional proporciona el "por qué" que hace inteligible el "cómo".

En los capítulos siguientes, en cada uno de ellos empezaremos dándole respuesta a la pregunta "por qué" antes de presentar el "cómo".

4.4.4 Progresión Científica: De Descripciones a Explicaciones

El marco de Marr identifica niveles de análisis que pueden estudiarse en cualquier orden. Pero en la práctica científica, la investigación típicamente progresa en una secuencia específica:

Qué: Primero se identifican regularidades empíricas—patrones cuantitativos en los datos que pueden describirse matemáticamente. Estos son *modelos fenomenológicos*: resumen datos pero no explican cómo se producen. (En capítulos posteriores verás ejemplos como la ley de igualación y el gradiente de demora.)

Cómo: Después se proponen mecanismos que generan esos patrones. Estos son *modelos mecanicistas o algorítmicos*: especifican procesos paso a paso que producen las regularidades observadas. (Por ejemplo, reglas de actualización que generan los patrones empíricos identificados en el paso anterior.)

Por qué: Finalmente se identifican principios normativos que justifican por qué esos mecanismos son apropiados para el problema adaptativo. Estos son *modelos normativos*: muestran qué sería óptimo hacer dado el problema y las restricciones. (Por ejemplo, demostrando que el mecanismo aproxima una solución óptima.)

Esta progresión Qué → Cómo → Por Qué refleja tanto el desarrollo histórico de las ciencias del comportamiento como una secuencia pedagógica natural. Varios capítulos de este libro seguirán esta estructura. Cuando la encuentres, regresa a esta distinción para identificar qué tipo de modelo se está presentando y qué función cumple en la explicación.

Nota que esta secuencia no implica que un tipo de modelo sea "mejor" que otro. Los tres son necesarios y complementarios: el modelo fenomenológico identifica qué necesitas explicar, el modelo mecanicista especifica cómo se produce, y el modelo normativo justifica por qué ese mecanismo y no otro.

4.5 Van Fraassen: La Explicación como Respuesta a Preguntas

Bas van Fraassen integra los puntos anteriores con una observación aparentemente simple pero de gran alcance: la explicación no es una relación lógica abstracta sino una actividad pragmática. Explicar es responder una pregunta de "¿por qué?" en un contexto dado. Y esas preguntas tienen una estructura que habitualmente se ignora.

Cuando preguntamos "¿por qué P?", no preguntamos "¿por qué P y no cualquier otra cosa concebible?". Preguntamos "¿por qué P en lugar de Q?", donde Q es un *contraste implícito* que depende del contexto. Considera: "¿por qué el niño tomó una manzana?". Si el contraste es {tomó / no tomó}, la respuesta es que tenía hambre. Si el contraste es {manzana / naranja / plátano}, la respuesta es que prefiere las manzanas. Si el contraste es {tomó / compró / pidió}, la respuesta es que no tenía dinero. La misma información puede ser explicativa en un contexto e irrelevante en otro.

Esta perspectiva disuelve muchos debates aparentes en la literatura. Cuando dos investigadores parecen en desacuerdo sobre qué "explica" un fenómeno, con frecuencia están haciendo contrastes implícitos distintos. El que busca mecanismos neurales contrasta el comportamiento observado con lo que ocurriría si ese mecanismo no existiera. El que busca la función evolutiva contrasta el comportamiento con lo que haría un organismo sin esa capacidad adaptativa. No están en desacuerdo sobre el mundo; están haciendo preguntas distintas. La pregunta productiva no es "¿quién tiene razón?", sino "¿qué contraste está haciendo cada uno, y es ese contraste legítimo dado el propósito de la investigación?".

4.6 Una Nota sobre los Modelos de Datos

El proceso científico no termina con la observación de un fenómeno ni comienza con la construcción de un modelo teórico. Entre ambos está el trabajo de organizar los datos empíricos de forma que sean interpretables. Patrick Suppes llamó a este paso la construcción de un *modelo de datos*: la transformación de registros crudos en una representación canónica del fenómeno.

Los modelos de datos no son neutros. Cuando Skinner decidió representar el comportamiento de sus ratas como *tasa de respuesta* —número de presiones de palanca por unidad de tiempo— estaba tomando una decisión teórica disfrazada de decisión técnica. Esa representación hacía visibles ciertos patrones (pausas después del refuerzo, aceleración de la tasa bajo programas de razón) y oscurecía otros (microestructura temporal, variación en la topografía de la respuesta). Toda una tradición teórica se organizó alrededor de explicar variaciones en la tasa de respuesta, en parte porque la tasa era el modelo de datos dominante.

En los capítulos que siguen, cada vez que se introduzca una nueva medida —tiempo entre respuestas, magnitud del error de predicción, frecuencia relativa de elección— vale la pena preguntarse qué aspectos del fenómeno hace visibles esa medida y cuáles oculta.

4.7 Síntesis

Tres ideas organizan este capítulo y reaparecerán a lo largo del libro.

Los modelos no son copias de la realidad sino vehículos de inferencia: su valor se mide por la calidad de las inferencias que permiten hacer, no por su fidelidad absoluta al fenómeno. Dos modelos del mismo comportamiento pueden coexistir si sirven propósitos distintos.

La explicación no es un único tipo de actividad. Hay explicaciones causales (que identifican los factores que hacen diferencia), explicaciones unificadoras (que muestran que fenómenos heterogéneos comparten estructura), y explicaciones mecanicistas (que especifican los componentes cuyas interacciones producen el fenómeno). Estas formas se complementan.

Los fenómenos complejos pueden analizarse a múltiples niveles. Tinbergen, Marr y Killeen articulan ese espacio de niveles con vocabularios distintos pero convergentes. Cuando en los capítulos que siguen encuentres modelos que parecen incompatibles, la primera pregunta que debes hacerte es si están operando al mismo nivel o respondiendo la misma pregunta. Con frecuencia, la respuesta es que no.

4.8 Ejercicios de Comprensión

Ejercicio 1 (básico). Considera el siguiente enunciado: "Los estudiantes que duermen más horas antes de un examen obtienen mejores calificaciones." Escribe (a) una explicación contrafactual, (b) una posible explicación intervencionista, y (c) una formulación del hacedor de diferencia más abstracto. ¿Cuál de las tres te parece más informativa para el propósito de diseñar una intervención educativa? ¿Cambia tu respuesta si el propósito es comprender el funcionamiento de la memoria?

Ejercicio 2 (intermedio). Un experimento muestra que las ratas presionan más rápido una palanca cuando cada décima presión entrega comida que cuando cada presión la entrega. Usando el marco de Tinbergen, formula las cuatro preguntas que podrías hacer sobre este fenómeno e indica, para cada una, qué tipo de estudio o datos necesitarías para responderla.

Ejercicio 3 (intermedio). Alguien argumenta: "Los modelos matemáticos del aprendizaje no son realmente explicaciones porque omiten los mecanismos neuronales reales." Usando los marcos de Marr y Killeen, evalúa este argumento. ¿En qué sentido tiene razón? ¿Qué confunde?

Ejercicio 4 (avanzado). En los capítulos siguientes, el comportamiento de orientación de las bacterias se describirá a nivel conductual (kinesis), a nivel algorítmico (ascenso de colina) y brevemente a nivel mecanicista molecular. Elige dos de esos niveles y describe: (a) qué pregunta responde cada uno según el marco de Tinbergen y el de Marr; (b) si son "explicaciones" en los sentidos discutidos en este capítulo, y de qué tipo; (c) qué fenómeno adicional podría investigarse si combináramos información de ambos niveles.

5 Teoría de la Selección Natural

Para cualquier observador del mundo natural, dos propiedades resultan sorprendentes y merecen explicación. La primera es la enorme variabilidad en la morfología, fisiología y comportamiento de los organismos que habitan este planeta. La segunda es que esa variabilidad parece estar finamente ajustada a las características del entorno donde viven esos organismos. La teoría de la selección natural, propuesta por Charles Darwin en 1859, ofrece una explicación unificada de ambas observaciones a partir de tres principios sorprendentemente simples.

Este capítulo tiene dos propósitos. El primero es presentar esos principios, que constituyen uno de los logros más importantes de la ciencia. El segundo, menos obvio pero igualmente importante para este curso, es mostrar que la estructura conceptual de la selección natural es la misma que subyace a los procesos de aprendizaje que estudiaremos en los bloques siguientes. Para hacer esa conexión con precisión, introduciremos hacia el final del capítulo un modelo matemático del cambio evolutivo —la ecuación de Price en su versión simplificada— que revelará por qué la similitud entre evolución y aprendizaje no es solo una metáfora cómoda sino una identidad estructural.

5.1 La Variabilidad y el Ajuste al Entorno

Un recorrido por cualquier parque, zoológico, o incluso una búsqueda rápida en YouTube de documentales de historia natural, nos expone a una variedad de formas de vida difícil de procesar. Organismos unicelulares, hongos, medusas, insectos, aves, mamíferos —y dentro de cada grupo, una diversidad adicional que parece inagotable. Solo entre mamíferos existen aproximadamente 5,500 especies; entre insectos, más de 91,000; entre escarabajos, alrededor de 250,000, lo que llevó al biólogo J.B.S. Haldane a su famosa observación sobre la "predilección del Creador por los coleópteros". La variabilidad no es solo morfológica: varía la fisiología, el comportamiento, los mecanismos de regulación interna, los sistemas de reproducción.

Lo que Darwin notó en su viaje en el Beagle, y que constituye el punto de partida de su teoría, es que esta variabilidad no es aleatoria con respecto al entorno: está correlacionada con él. En los archipiélagos de las Galápagos, pájaros genéticamente relacionados presentaban picos radicalmente diferentes según el tipo de alimento disponible en la isla que habitaban: picos largos y delgados para acceder al néctar de flores, picos cortos y fuertes para romper semillas duras. Esta coincidencia entre la forma del organismo y las demandas del entorno es lo que llamamos *adaptación*, y es el fenómeno que requiere explicación.

A mediados del siglo XIX también se sabía, gracias al análisis de fósiles y la datación de capas geológicas, que la diversidad biológica había cambiado a lo largo del tiempo: había especies que habían desaparecido y otras que habían surgido en épocas geológicas más recientes. Era evidente que el mundo biológico no había sido "creado" todo a la vez, y que podía hablarse de una *evolución* de los organismos. La pregunta era: ¿qué proceso explica tanto el cambio a lo largo del tiempo como el ajuste al entorno?

5.2 Los Tres Principios de la Selección Natural

Darwin propuso que la evolución puede explicarse a partir de tres principios que, cuando se cumplen simultáneamente, producen un cambio adaptativo en la composición de la población.

El primero es la **variabilidad heredable**. Los organismos producen descendencia que difiere ligeramente de sus progenitores. Esta variación surge por mutaciones (cambios en el material genético) y recombinación (la mezcla de material genético de dos progenitores en la reproducción sexual). No todos los individuos son idénticos: existe diversidad en morfología, fisiología y comportamiento. Lo crucial es que esta variación se transmite, al menos parcialmente, a la siguiente generación.

El segundo principio es la **selección diferencial**: los organismos interactúan con su entorno, y esa interacción determina cuántos descendientes logra producir cada uno. A este número lo llamamos *éxito reproductivo* o *fitness*. Aquellos organismos con características que resultan más exitosas en el entorno actual —que escapan mejor de depredadores, obtienen más alimento, atraen más parejas— tienden a reproducirse más. Esta ventaja debe ser *causal*, no una mera coincidencia: el rasgo en cuestión contribuye al mayor éxito, no simplemente lo acompaña.

El tercero es la **herencia**: las características que incrementaron el éxito reproductivo se transmiten a la siguiente generación. La proporción de organismos con esas características aumenta en la población con el paso del tiempo.

Cuando estos tres principios operan a la vez, ocurre selección natural: generación tras generación, los rasgos asociados con mayor éxito reproductivo se vuelven más frecuentes. La composición de la población cambia, favoreciendo las variantes que funcionan mejor en el entorno actual. Este proceso de cambio acumulativo y diferencial es la esencia de la evolución darwiniana.

Vale la pena detenerse en algo que sorprende a muchos estudiantes al encontrarse con estos principios por primera vez: ninguno de ellos requiere intención, planificación ni dirección consciente. La selección natural es un proceso automático. Las bacterias no "intentan" desarrollar resistencia a los antibióticos; simplemente, aquellas que por variación aleatoria ya tenían cierta resistencia sobreviven y se reproducen más, y su descendencia hereda esa característica. La dirección adaptativa emerge de la interacción entre variación aleatoria y el filtro del entorno, sin necesidad de un agente que la dirija.

5.3 Las Fuentes de la Variabilidad

La teoría darwiniana original reconocía la existencia de variación heredable, pero no conocía sus mecanismos —la genética mendeliana se integró décadas después, en lo que se conoce como la Síntesis Moderna. Hoy sabemos que la variabilidad surge principalmente de tres fuentes.

Las **mutaciones genéticas** son cambios en el material genético que pueden ocurrir por errores en la copia del ADN, exposición a radiación o agentes químicos, entre otras causas. Sus efectos son diversos: algunas mutaciones son letales, otras son neutras y no afectan la supervivencia, y en ocasiones confieren alguna ventaja bajo ciertas condiciones. Las mutaciones neutras pueden acumularse en la población simplemente por azar, en un proceso conocido como deriva genética.

La **reproducción sexual y recombinación** no crea alelos nuevos, pero genera nuevas combinaciones de los existentes. Cada descendiente recibe una mezcla única de genes de ambos progenitores, lo que produce variación en los fenotipos incluso entre hermanos. La reproducción sexual es una máquina extraordinariamente eficiente para generar diversidad combinatoria.

Finalmente, los **eventos geográficos y ecológicos** pueden separar poblaciones y forzarlas a evolucionar de manera independiente. El aislamiento geográfico —la formación de una barrera que divide una población— divide el acervo genético en dos. Con el tiempo, cada subpoblación acumula mutaciones distintas y puede diverger hasta dar origen a nuevas especies.

5.4 El Entorno como Filtro

Una forma de visualizar cómo opera la selección es imaginar al entorno como un sistema de filtros. Las condiciones ambientales —disponibilidad de recursos, presencia de depredadores, temperatura, competencia— determinan cuáles variantes de la población sobreviven y se reproducen. Las variantes que no logran superar esos filtros desaparecen; las que los superan persisten y transmiten sus características.

Es importante notar que este proceso no "selecciona" en el sentido de elegir activamente lo mejor. Más bien, *elimina* lo que no funciona en el entorno actual. Lo que sobrevive no es necesariamente lo óptimo en términos absolutos, sino lo suficientemente bueno para no ser eliminado. Esta distinción tiene consecuencias importantes: la evolución no garantiza soluciones perfectas, solo soluciones funcionales en un entorno particular.

La metáfora del filtro también ilustra por qué la adaptación es siempre relativa al contexto: un rasgo ventajoso en un entorno puede ser desventajoso en otro. Las adaptaciones de las aves de las Galápagos al tipo de alimento disponible en cada isla serían perjudiciales si las aves cambiaran de isla. El "ajuste" es siempre local, contingente, histórico.

5.5 La Selección Natural como Algoritmo de Búsqueda

Llegamos ahora al segundo propósito del capítulo: mostrar la estructura que comparte la selección natural con los algoritmos de aprendizaje y decisión que estudiaremos más adelante.

Imaginemos que nos contratan para buscar jugadores para un equipo de fútbol. Tenemos un conjunto de posibles acciones disponibles: quedarnos en casa viendo partidos por televisión, ir a juegos de ligas de menor categoría, visitar clubes infantiles en una ciudad, en varias ciudades, incluyendo pequeñas localidades. A lo largo del tiempo, probaríamos distintas estrategias y a cada una le iríamos asignando un valor que refleja su éxito para encontrar buenos jugadores. Gradualmente, iríamos refinando nuestra búsqueda, manteniendo las estrategias más exitosas y abandonando las que no funcionan. Y si las condiciones cambian —por ejemplo, los costos de transporte se disparan— la estrategia óptima cambiaría también.

Esta es precisamente la estructura de un algoritmo de búsqueda. Lo que necesitamos para representarla formalmente son cuatro elementos: un espacio de posibilidades (las distintas acciones disponibles), un mecanismo para generar variantes dentro de ese espacio, una función de evaluación que asigna un valor a cada variante según su éxito, y un mecanismo que preserve y propague las variantes más exitosas.

La selección natural tiene exactamente esta estructura. El espacio de posibilidades es el espacio fenotípico; el mecanismo de variación es la mutación y la recombinación; la función de evaluación es el fitness; y el mecanismo de preservación es la herencia. Esta estructura —variación, evaluación, selección— es compartida por todos los procesos en los que algo aprende de la experiencia, ya sea una población que evoluciona, un organismo que aprende, o un algoritmo que optimiza.

5.5.1 El Espacio Fenotípico y el Paisaje Adaptativo

Para formalizar esta idea necesitamos un concepto que aparecerá repetidamente a lo largo del curso: el de *espacio de posibilidades*.

Imagina que cada organismo puede describirse por sus características medibles: la longitud de sus alas, la eficiencia de su metabolismo, la agudeza de su visión, su velocidad de reacción. Cada característica es una dimensión. Si un organismo tiene valores específicos en todas estas dimensiones, podemos pensar en él como un punto en un espacio multidimensional. El **espacio fenotípico** es el conjunto de todas las configuraciones posibles de características que un organismo podría tener.

No todas las configuraciones en ese espacio son igualmente exitosas. Si asignamos a cada punto un valor que representa el éxito reproductivo esperado, obtenemos lo que llamamos un **paisaje adaptativo**: un espacio con "picos" (combinaciones de rasgos con alto fitness) y "valles" (combinaciones con bajo fitness).

La selección natural, vista desde esta perspectiva, es el proceso mediante el cual una población se desplaza por ese paisaje. La mutación y recombinación hacen que la descendencia explore regiones cercanas a la de sus padres; la selección hace que la población tienda a moverse hacia regiones de mayor fitness.

Cuando estudien los algoritmos de aprendizaje más adelante en el curso, encontrarán que también operan buscando en espacios de posibilidades guiados por una función que asigna valor a cada opción. La estructura es la misma; cambia el dominio.

5.5.2 Restricciones: Qué Regiones del Espacio Son Accesibles

Una pregunta natural al imaginar el espacio fenotípico es: ¿puede la evolución llegar a cualquier punto de ese espacio dado suficiente tiempo? La respuesta es no, y entender por qué es importante tanto para la evolución como para los algoritmos de aprendizaje.

Las **restricciones físicas** imponen límites duros: un insecto no puede crecer al tamaño de un elefante porque su exoesqueleto no podría soportar el peso. Las **restricciones genéticas y del desarrollo** hacen que no todas las combinaciones de rasgos sean biológicamente realizables: el desarrollo de un organismo sigue rutas específicas que limitan las variaciones posibles. Las **restricciones filogenéticas** son quizás las más importantes para nuestros propósitos: la evolución es un proceso histórico, y los organismos actuales son modificaciones de organismos ancestrales. La evolución no empieza de cero en cada generación; hereda tanto las soluciones exitosas como las limitaciones de sus ancestros.

Podemos visualizar estas restricciones como filtros anidados. El espacio teóricamente posible es enorme; las restricciones físicas eliminan todo lo que viola leyes de la naturaleza; las restricciones del desarrollo y genéticas reducen aún más el espacio a lo biológicamente realizable; las restricciones filogenéticas lo reducen al espacio accesible para este linaje específico dada su historia; finalmente, el entorno actual determina qué región del espacio accesible tiene alto fitness.

Esta estructura de restricciones anidadas es análoga a lo que en el capítulo sobre asignación de crédito llamaremos *sesgos inductivos*: predisposiciones que limitan el espacio de búsqueda y hacen manejable un problema que de otro modo sería intratable. Tanto en la evolución como en el aprendizaje, las restricciones no son obstáculos al proceso sino parte constitutiva de cómo funciona.

5.5.3 El Problema de los Óptimos Locales

Una limitación adicional de la selección natural como algoritmo de búsqueda proviene de la naturaleza misma del proceso de ascenso por el paisaje adaptativo. Imaginemos a alguien con los ojos vendados que intenta llegar al punto más alto de una cordillera. La regla que sigue es simple: en cada paso, explora las alturas cercanas y se desplaza hacia la más alta. Si la

cordillera tiene un único pico, esta regla lo llevará allí. Pero si hay varios picos separados por valles, la persona quedará atrapada en el primero que encuentre, aunque haya picos más altos en otras regiones.

La selección natural enfrenta exactamente este problema. Una población bien adaptada a su entorno actual puede quedar "atrapada" en un óptimo local: cualquier pequeño cambio la llevaría a un estado menos exitoso, aunque existan configuraciones mucho mejores que requieren pasar por estados intermedios desfavorables. Para escapar de un óptimo local se necesita suficiente variación —exploración— como para "saltar" el valle, pero aumentar la variación tiene costos: también puede sacar a la población de picos donde ya estaba.

Este dilema entre explorar nuevas regiones y explotar lo conocido aparece en todos los algoritmos de búsqueda y aprendizaje. Lo encontraremos en el contexto del forrajeo, la elección entre opciones, el aprendizaje secuencial. La evolución no lo resuelve de manera perfecta; tampoco lo hacen los organismos que aprenden.

Hay una segunda razón, independiente de los óptimos locales, por la que la selección natural no produce organismos "perfectos en todo": los trade-offs. Muchos rasgos que incrementan el éxito en una dimensión lo reducen en otra. Ser grande puede ayudar a defenderse de depredadores, pero requiere más alimento. Dedicar energía a reproducirse temprano reduce la energía disponible para el mantenimiento del organismo. La cola elaborada del pavo real atrae parejas pero dificulta el vuelo y atrae depredadores. En cada uno de estos casos, no existe una solución que maximice simultáneamente todos los objetivos —el "óptimo" es siempre un balance entre presiones en tensión. Este principio, que aquí aparece en su versión evolutiva, reaparecerá en el siguiente capítulo cuando analicemos cómo los organismos distribuyen su comportamiento entre actividades que compiten por el mismo tiempo y energía.

5.5.4 Cuando el Paisaje Cambia

Hay una diferencia importante entre la selección natural y los algoritmos de optimización más simples: el paisaje adaptativo no es fijo. Cambia a lo largo del tiempo porque el entorno cambia, porque otras especies coevolucionan, porque las adaptaciones de una especie alteran el nicho de otras. Si una presa evoluciona mayor velocidad, cambia el paisaje adaptativo de su depredador. Si el depredador evoluciona mejor visión, cambia el paisaje de la presa. Es como intentar alcanzar la cima de una montaña mientras la montaña misma se está deformando.

Finalmente, cuando diferentes rasgos están en conflicto, no existe una "mejor solución única". Ser grande puede ayudar a defenderse de depredadores, pero requiere más alimento. Dedicar tiempo a buscar pareja puede ser ventajoso para reproducirse, pero reduce el tiempo disponible para alimentarse. En estos casos, el óptimo depende del balance específico entre las presiones selectivas en ese entorno particular.

A pesar de estas limitaciones, la selección natural ha producido adaptaciones extraordinariamente complejas y efectivas, porque opera con retroalimentación iterativa del entorno a lo

largo de escalas de tiempo enormes. Cada generación, la población recibe información sobre qué rasgos funcionan —en forma de éxito reproductivo diferencial— y ajusta su composición en consecuencia. Pequeños ajustes acumulados durante millones de generaciones pueden producir cambios dramáticos.

5.6 Otros Factores Evolutivos

La selección natural es el único proceso conocido que produce adaptaciones, pero no actúa sola. La **deriva genética** es un proceso de cambio aleatorio en las frecuencias génicas que es especialmente relevante en poblaciones pequeñas. A diferencia de la selección, la deriva no responde al valor adaptativo de los rasgos: puede fijar variantes neutras o incluso ligeramente desventajosas simplemente por azar, y puede en algunas circunstancias permitir que una población "salte" valles adaptativos que la selección por sí sola no podría cruzar. La **migración o flujo génico** ocurre cuando individuos se desplazan entre poblaciones, introduciendo o removiendo variantes. La **selección sexual**, identificada por Darwin como un caso especial, opera cuando los rasgos evolucionan no por supervivencia directa sino por éxito en el apareamiento —las colas elaboradas del pavo real son el ejemplo clásico.

5.7 Modelando el Cambio: Ecuaciones en Diferencia

Hasta ahora hemos hablado cualitativamente de cómo las poblaciones cambian generación tras generación. Para hacer esa conexión con el aprendizaje de manera precisa, necesitamos un lenguaje matemático para describir ese cambio. El lenguaje apropiado son las **ecuaciones en diferencia**.

Una ecuación en diferencia es una regla que nos dice cómo calcular el estado de un sistema en el tiempo $t + 1$ a partir de su estado en el tiempo t. La forma general es simplemente:

$$\text{Estado}(t + 1) = f(\text{Estado}(t))$$

donde f es alguna función que transforma el estado actual en el estado siguiente. Veamos un ejemplo familiar: el crecimiento de casos de COVID-19. En los modelos epidemiológicos más simples, el número de personas infectadas en la semana siguiente depende del número de infectados esta semana:

$$I(t+1) = r \times I(t)$$

donde $I(t)$ es el número de infectados en el tiempo t, y r es la tasa de reproducción —cuántas personas, en promedio, infecta cada persona infectada. Si $r > 1$, los casos crecen exponencialmente; si $r < 1$, decrecen. Esta simple ecuación captura la dinámica del contagio. La esencia de las ecuaciones en diferencia es esta: expresar el cambio de forma recursiva, de modo que cada nuevo valor $t + 1$ se convierte en el punto de partida del siguiente paso.

Para explorar estos conceptos, abra los Simuladores en Google Colab y siga las instrucciones de la introducción para dirigirse al simulador 2.

5.8 Covarianza: La Relación entre Rasgo y Éxito Reproductivo

En teoría evolutiva queremos una ecuación que nos diga cómo cambia la distribución de rasgos en una población de una generación a la siguiente. Consideremos un rasgo cuantitativo —altura, velocidad, longitud del pico. En la generación t, ese rasgo tiene un valor promedio en la población que llamamos $\bar{z}(t)$. En la siguiente generación, tendrá un nuevo valor promedio $\bar{z}(t+1)$. El cambio es:

$$\Delta\bar{z} = \bar{z}(t+1) - \bar{z}(t)$$

Para explorar la covarianza, abra los Simuladores en Google Colab y siga las instrucciones de la introducción para dirigirse al simulador 3.

Esta diferencia nos dice si el rasgo, en promedio, aumentó, disminuyó o se mantuvo igual. La pregunta fundamental es: ¿de qué depende $\Delta\bar{z}$? ¿Qué determina la dirección y magnitud del cambio evolutivo?

La respuesta involucra la relación estadística entre el rasgo y el éxito reproductivo. Para medirla necesitamos un concepto: la **covarianza**.

Imaginemos que medimos dos cosas en cada organismo de una población: el valor de algún rasgo z —digamos, largo de alas— y su éxito reproductivo w —número de descendientes. Queremos saber si estas dos variables están relacionadas: cuando z es grande, ¿w tiende a ser grande también? ¿O tiende a ser pequeño? ¿O no hay relación?

Recordemos cómo se calcula la media de una variable. Si tenemos n observaciones $x_1, x_2, \ldots, x_n$, la media es:

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

La **covarianza** entre dos variables extiende esta idea de manera natural. Para cada organismo i, calculamos qué tan lejos está su valor del rasgo de la media del rasgo: $(z_i - \bar{z})$. Esto es una "desviación" respecto a la media —positiva si ese organismo está por encima del promedio, negativa si está por debajo. Hacemos lo mismo para el fitness: $(w_i - \bar{w})$. Ahora viene la idea clave: multiplicamos las dos desviaciones para cada organismo:

$$(z_i - \bar{z}) \times (w_i - \bar{w})$$

Si ambas desviaciones son positivas —el organismo tiene rasgo alto y fitness alto— el producto es positivo. Si ambas son negativas, el producto también es positivo. Pero si una desviación es positiva y la otra negativa, el producto es negativo. Sumando estos productos y promediando, obtenemos la covarianza:

$$\mathrm{Cov}(w, z) = \frac{\sum_{i=1}^{n} (w_i - \bar{w})(z_i - \bar{z})}{n}$$

Una covarianza positiva significa que cuando z está por encima de su media, w tiende a estar por encima de su media también —las variables se mueven juntas. Una covarianza negativa significa que se mueven en sentidos opuestos. Una covarianza cercana a cero indica que no hay relación consistente: saber el valor de z no ayuda a predecir w.

En el contexto evolutivo, $\mathrm{Cov}(w, z)$ nos dice: ¿los organismos con valores altos del rasgo z tienden a tener más descendientes? Si la respuesta es sí, la covarianza es positiva, y ese rasgo tenderá a incrementarse en la población.

5.9 La Ecuación del Cambio Evolutivo

Ahora tenemos las herramientas necesarias: ecuaciones en diferencia para modelar cambios temporales, y covarianza para medir la relación entre rasgo y fitness. Combinándolas, podemos escribir una de las ecuaciones fundamentales de la genética evolutiva moderna.

George Price, en 1970, derivó una forma general del cambio evolutivo conocida ahora como la ecuación de Price. Aquí presentamos una versión simplificada que captura la esencia del proceso para un rasgo cuantitativo en una sola generación:

$$\Delta \bar{z} = \frac{\mathrm{Cov}(w, z)}{\bar{w}}$$

El lado izquierdo, $\Delta\bar{z}$, es el cambio en el valor promedio del rasgo de una generación a la siguiente. El lado derecho dice que ese cambio depende de la covarianza entre fitness y rasgo, dividida entre el fitness promedio de la población.

La lógica es directa. Si $\mathrm{Cov}(w, z) > 0$, entonces $\Delta\bar{z} > 0$: el rasgo aumenta en promedio. Los individuos con valores altos del rasgo tienden a tener más descendientes, y el promedio poblacional se desplaza hacia arriba. Si $\mathrm{Cov}(w, z) < 0$, entonces $\Delta\bar{z} < 0$: el rasgo disminuye. Si $\mathrm{Cov}(w, z) = 0$, entonces $\Delta\bar{z} = 0$: no hay cambio. El rasgo no está asociado con el éxito reproductivo y la selección no tiene base para alterarlo.

Esta ecuación es elegante porque destila la selección natural a su esencia estadística: **el cambio en la media de un rasgo depende de qué tanto ese rasgo covaria con el éxito reproductivo**. No necesita conocer nada sobre mecanismos genéticos, estructuras moleculares ni historias individuales; solo necesita la relación estadística entre rasgo y éxito.

Notemos además que esta es una ecuación en diferencia. Nos dice cómo calcular $\bar{z}(t+1)$ dado $\bar{z}(t)$, exactamente como las ecuaciones que modelaron el crecimiento de COVID. La evolución, al igual que esos procesos, es un sistema dinámico que se actualiza recursivamente.

Para explorar el cambio evolutivo, abra los Simuladores en Google Colab y siga las instrucciones de la introducción para dirigirse al simulador 4.

5.10 La Equivalencia con los Modelos de Aprendizaje

La ecuación de Price no es solo un resumen matemático de la selección natural. Tiene una estructura que reaparecerá, con distinto sustrato y distinta escala temporal, cuando estudiemos cómo los organismos aprenden de su experiencia. En ambos casos, el sistema se actualiza en proporción a una discrepancia entre lo que ocurrió y lo que se esperaba —o entre un rasgo y su contribución al éxito. Anticipar esta conexión aquí no es un detalle técnico: es el argumento central de este libro. Los mecanismos de aprendizaje que estudiaremos en los bloques siguientes no son procesos independientes de la evolución, sino instancias del mismo algoritmo operando en una escala de tiempo diferente y sobre un sustrato diferente.

5.10.1 El Problema de la Asignación de Crédito

Hay un problema que aparece en cualquier sistema que aprende por retroalimentación, y que conecta directamente la evolución con el aprendizaje. Cuando el sistema recibe una retroalimentación —buena o mala— ¿cómo saber qué componentes del sistema fueron responsables de ese resultado?

Imaginemos un organismo con múltiples rasgos: velocidad de carrera, agudeza visual, eficiencia metabólica, tamaño corporal. Algunos organismos tienen éxito reproductivo alto, otros bajo. La pregunta es: ¿cuál de esos rasgos fue responsable del éxito? ¿La velocidad? ¿La visión?

¿Una combinación? La selección natural resuelve este problema de manera estadística, mediante la covarianza. Si la velocidad covaria positivamente con el fitness a través de la población, pero el tamaño corporal no, entonces la velocidad "merece el crédito". La población, sin saber nada sobre causalidad, se desplaza hacia mayor velocidad.

Exactamente el mismo problema aparece en el aprendizaje: cuando ocurre un suceso biológicamente importante, ¿a cuál de todos los estímulos y respuestas que precedieron ese suceso se le debe asignar la responsabilidad? Esta pregunta —el *problema de la asignación de crédito*— es el tema central del Bloque II. Lo fascinante es que, aunque la solución evolutiva (covarianza estadística) y la solución del aprendizaje (reducción del error de predicción) parecen diferentes, ambas atacan el mismo problema fundamental: dado un resultado, inferir qué cambios en el sistema llevarán a mejores resultados futuros.

5.11 Conexiones con el Resto del Curso

Este capítulo establece tres conexiones que reaparecerán a lo largo del libro.

La primera es la equivalencia entre selección natural y aprendizaje como instancias del mismo algoritmo de actualización iterativa. Cuando en el Bloque II veamos los modelos de asignación de crédito, y en el Bloque III los modelos de elección y optimización, reconocerán la misma estructura que identificamos aquí: espacio de posibilidades, función de evaluación, regla de actualización proporcional a una discrepancia.

La segunda es el papel de las restricciones. En la evolución, las restricciones físicas, genéticas y filogenéticas limitan el espacio de rasgos posibles. En el aprendizaje, los *sesgos inductivos* cumplen la misma función: reducen el espacio de hipótesis y hacen manejable la búsqueda. Veremos esto con detalle en el capítulo sobre asignación de crédito. Igualmente veremos que los programas de refuerzo son restricciones entre diferentes distribuciones de respuestas.

La tercera es el dilema exploración-explotación. La tensión entre explorar nuevas regiones del espacio de posibilidades y explotar lo conocido aparece en la evolución, en el aprendizaje, y en la elección. Es uno de los problemas fundamentales de la adaptación, y dedicaremos atención específica a sus soluciones en varios capítulos del curso.

5.12 Resumen

La teoría de la selección natural explica la diversidad y la adaptación biológica a partir de tres principios: variabilidad heredable, selección diferencial según el entorno, y herencia. Cuando estos tres principios operan simultáneamente, la composición de la población cambia generación tras generación, favoreciendo los rasgos más exitosos en el entorno actual.

La ecuación de Price formaliza este proceso: el cambio en la media de un rasgo es proporcional a la covarianza entre ese rasgo y el éxito reproductivo. Esta ecuación no es solo una descripción de la evolución —es el prototipo de una familia de algoritmos de actualización iterativa que incluye los modelos de aprendizaje por refuerzo. En ambos casos, el sistema se actualiza en proporción a una discrepancia entre lo que tiene y lo que el entorno le devuelve.

La selección natural y el aprendizaje no son metafóricamente similares —son estructuralmente equivalentes. Entender esta equivalencia desde el principio del curso nos dará una ventaja considerable cuando encontremos esas mismas ideas en dominios aparentemente distintos: el condicionamiento, la elección, la planificación secuencial.

6 Preguntas de Estudio — Capítulo 2: Evolución y Adaptación

6.1 Sección I: Comprensión conceptual

Estas preguntas verifican que los conceptos centrales del capítulo quedaron claros. Pueden responderse sin cálculos.

1. La selección natural requiere tres condiciones simultáneas. Describe cada una con tus propias palabras y explica por qué la ausencia de cualquiera de ellas detendría el proceso evolutivo. Da un ejemplo de una situación donde se cumplan las tres.

2. El capítulo afirma que la selección natural no "elige lo mejor" sino que "elimina lo que no funciona". ¿Cuál es la diferencia práctica entre estas dos descripciones? ¿Por qué importa esta distinción para entender los límites de la adaptación?

3. Explica en qué sentido la selección natural es un proceso "ciego" —sin intención ni dirección consciente. Usa el ejemplo de la resistencia a antibióticos en bacterias para ilustrar tu respuesta.

4. ¿Qué es un paisaje adaptativo? Describe qué representan los picos y los valles, y explica por qué una población no siempre llega al pico más alto.

5. El capítulo distingue entre "óptimo local" y "óptimo global". Define ambos términos y describe una situación evolutiva concreta donde una población pudiera quedar atrapada en un óptimo local.

6. ¿Por qué el paisaje adaptativo no es fijo? Describe dos razones por las que puede cambiar a lo largo del tiempo y explica cómo esto complica la idea de que la evolución "optimiza" a los organismos.

6.2 Sección II: Restricciones y espacio fenotípico

7. El capítulo describe tres tipos de restricciones que limitan el espacio fenotípico accesible: físicas, genético-del desarrollo, y filogenéticas. Da un ejemplo de cada tipo y explica cómo cada una reduce el espacio de posibilidades disponibles para la selección.

8. ¿Por qué las restricciones filogenéticas son especialmente relevantes para entender la evolución comparada con un proceso de optimización desde cero? Usa el ejemplo del ojo humano mencionado en el texto o propón uno propio.

9. El capítulo conecta las restricciones evolutivas con los "sesgos inductivos" que veremos en aprendizaje. ¿Qué tienen en común? ¿En qué sentido las restricciones no son obstáculos al proceso sino parte de cómo funciona?

6.3 Sección III: El modelo matemático

10. ¿Qué es una ecuación en diferencia? Explica el concepto con el ejemplo del modelo de COVID presentado en el capítulo, e identifica cuál es el "estado" del sistema y cuál es la función de actualización.

11. Define covarianza con tus propias palabras. Sin usar fórmulas, explica qué significa una covarianza positiva, negativa y cercana a cero en el contexto de la relación entre un rasgo fenotípico y el fitness.

12. Considera una población de pájaros donde medimos la longitud del pico y el número de crías por temporada. Describe dos escenarios: uno donde la covarianza entre longitud del pico y éxito reproductivo sea positiva, y otro donde sea negativa. ¿Qué predice la ecuación de Price para cada caso?

13. La ecuación de Price simplificada es:

$$\Delta \bar{z} = \frac{\mathrm{Cov}(w, z)}{\bar{w}}$$

¿Qué ocurre con $\Delta \bar{z}$ cuando la covarianza es cero? ¿Qué significa biológicamente ese resultado? ¿Puede cambiar el rasgo de todas formas? ¿Cómo?

14. ¿Por qué la ecuación de Price es también una ecuación en diferencia? Escribe explícitamente cómo $\bar{z}(t+1)$ depende de $\bar{z}(t)$ y señala la analogía con el modelo de COVID.

7 El Papel de las Restricciones en la Evolución del Comportamiento Adaptable

Suponga que es ingeniero y su empresa le pide diseñar un robot de servicio autónomo para hogares. En su primera versión, el dueño conecta el robot a una toma de corriente antes de acostarse, como lo hace con su celular. Durante la noche el robot trabaja con esa energía, y por la mañana, cuando la batería se agota, se detiene. Usted puede mejorar la autonomía con baterías de mayor duración, pero el problema no desaparece: más tarde o más temprano, sin recarga, el robot se inmoviliza.

Un robot verdaderamente autónomo tendría que recargarse por sí mismo. Pero qué solución de diseño es la correcta depende de dónde va a operar. Si todas las casas fueran idénticas y la toma de corriente siempre estuviera en el mismo lugar, bastaría programar la ruta: a tal hora, dirigirse al punto X. Pero si las casas varían —que es el caso real— el robot necesita un algoritmo que le permita *aprender* la ubicación de las tomas en cada nuevo hogar. Y si el robot fuera a explorar un planeta desconocido, necesitaría algo más: algoritmos capaces de aprender en condiciones de incertidumbre profunda sobre cómo funciona ese entorno.

La selección natural ha operado exactamente como ese ingeniero. Los agentes biológicos enfrentan el mismo problema fundamental: obtener los recursos necesarios para sobrevivir y reproducirse, lo que en este libro llamamos **sucesos biológicamente importantes** (SBI). Como vimos en el capítulo anterior, la variabilidad heredable en el acceso a los SBI genera diferencias en éxito reproductivo, y esas diferencias acumuladas producen adaptación. La pregunta de este capítulo es cuáles tipos de soluciones ha seleccionado la evolución y qué determina cuál es la apropiada en cada caso.

La respuesta depende de dos conjuntos de restricciones: las que impone el propio organismo y las que impone el entorno.

7.1 Las Restricciones del Organismo

El comportamiento tiene costos. El primero y más fundamental es que cualquier comportamiento consume tiempo, y el tiempo disponible es finito. No existe tal cosa como un momento de inactividad en sentido estricto: incluso “permanecer quieto” o “dormir” es un comportamiento que ocupa tiempo y cumple funciones. Si sumamos la duración de todos los comportamientos posibles a lo largo de un período, obtenemos una identidad:

$$T = t_1 + t_2 + t_3 \cdots + t_n$$

Esta ecuación expresa una *restricción lineal*: los diferentes comportamientos compiten entre sí por el tiempo disponible. Cada segundo dedicado a buscar alimento es un segundo menos disponible para vigilar depredadores, para aparearse, para descansar. A esto le llamamos **costo de oportunidad**: el valor de la mejor alternativa a la que se renuncia cuando se elige una opción. Un agente que dedica demasiado tiempo a esconderse tendrá poco tiempo para obtener alimento o encontrar pareja, y dependiendo del entorno, eso puede resultar en menor éxito reproductivo que un animal con una distribución más equilibrada.

Estos **trade-offs** son ubicuos en biología porque las restricciones fundamentales —tiempo finito, energía limitada— hacen imposible maximizar todo simultáneamente. Como vimos al hablar de paisajes adaptativos, el óptimo es siempre un balance entre presiones en tensión. Esta restricción reaparecerá con fuerza en el Bloque III, cuando estudiemos cómo los organismos distribuyen su comportamiento entre opciones que compiten.

Un segundo grupo de restricciones del organismo incluye su estructura biológica, metabólica, neuronal y física. Estas características delimitan el rango de comportamientos posibles —el **espacio de posibilidades**— y determinan el costo energético de cada uno. A estas restricciones se suman los **costos cognitivos** de los algoritmos mismos: algunos mecanismos de aprendizaje requieren mayor capacidad de memoria o procesamiento, lo que tampoco es gratuito.

7.2 Las Restricciones del Entorno

Además de las limitaciones del organismo, el entorno impone sus propias condiciones. La más fundamental es si las condiciones que determinan la disponibilidad de los SBI son **constantes o variables** a lo largo del tiempo.

Cuando las condiciones son relativamente constantes a lo largo de la historia evolutiva de una especie, la selección natural puede codificar directamente en el genoma las respuestas apropiadas. El resultado es el **comportamiento adaptado**: patrones conductuales que no requieren aprendizaje individual porque la solución ya está incorporada filogenéticamente. El reflejo de retirada ante un estímulo doloroso es un ejemplo: la relación entre calor intenso y daño tisular ha sido suficientemente constante durante millones de años. Otro ejemplo es la impronta en aves: los patitos siguen al primer objeto en movimiento que perciben después de la eclosión porque, en la historia de esa especie, ese objeto era invariablemente la madre. El ingeniero que escribe directamente en el código del robot la respuesta correcta está haciendo, en miniatura, lo que la selección natural hace con el comportamiento adaptado.

Sin embargo, los entornos de la mayoría de los organismos son variables, volátiles e inciertos. En esas condiciones, una respuesta conductual genéticamente fija sería evolutivamente subóptima: el entorno cambia, pero la respuesta no puede hacerlo. Ante un entorno variable, la selección

natural favorece algo radicalmente diferente: no codificar respuestas específicas, sino codificar **algoritmos adaptativos** que permitan al organismo ajustar su conducta a las condiciones particulares de su entorno, en tiempo real. A esto le llamamos **comportamiento adaptable**.

7.3 Dos Tipos de Algoritmos Adaptativos

Dentro del comportamiento adaptable pueden distinguirse dos grandes familias de algoritmos, según la estructura estadística del entorno al que responden.

Considere la vida de una bacteria en el intestino. La glucosa está dispersa de manera impredecible y la bacteria carece de receptores que le permitan detectar la fuente a distancia. Una solución posible es el movimiento aleatorio; la que evolucionó es más efectiva: un algoritmo de ascenso de colina basado en comparaciones sucesivas de la concentración del nutriente. Si en este momento la concentración es mayor que hace un instante, continuar en la misma dirección; si es menor, cambiar. Este algoritmo no requiere memoria: utiliza solo información local del momento presente. En el Bloque I estudiaremos este tipo de mecanismos —todos reactivos, sin integración de experiencia previa.

Cuando el entorno tiene una estructura causal —cuando los SBI no ocurren al azar sino correlacionados con ciertos tiempos, lugares, señales o acciones— surge la posibilidad de aprovechar esa estructura. Un organismo que recuerda dónde encontró alimento ayer puede regresar mañana; uno que aprendió que cierto sonido precede a un depredador puede anticiparse. Estos algoritmos, que llamamos **aprendizaje**, integran la experiencia previa para reducir la incertidumbre sobre el entorno. La diferencia respecto a los algoritmos reactivos no es de complejidad superficial sino de lógica: el aprendizaje solo tiene sentido si el entorno tiene estructura que pueda detectarse y aprovecharse.

Esto nos lleva a una pregunta que es, en el sentido del capítulo sobre explicación, una pregunta de nivel computacional: ¿qué tipos de estructura estadística puede tener un entorno? Especificar esas propiedades es especificar los problemas que los mecanismos de aprendizaje deben resolver —y, por tanto, organizar qué mecanismos vale la pena estudiar.

7.4 Las Propiedades Estadísticas del Entorno

Un entorno puede tener estructura —información aprovechable— a lo largo de varias dimensiones. Cuáles de esas dimensiones son relevantes para un organismo determina qué clase de mecanismo debe evolucionar. Las siguientes seis propiedades han dominado el estudio del comportamiento adaptable y, no por casualidad, organizan los bloques de este libro.

1. Tiempo de Ocurrencia

Los SBI pueden distribuirse de manera uniforme a lo largo del tiempo o concentrarse en ciertos períodos. Las flores abren al amanecer; los búhos cazan de noche; los restaurantes tienen horarios. Un organismo que detecta esas regularidades puede dedicar su tiempo de búsqueda a los momentos rentables y usarlo en otras actividades el resto del día. Esta adaptación requiere mecanismos que midan intervalos y detecten periodicidades.

2. Lugar de Ocurrencia

Los SBI también pueden distribuirse de manera uniforme en el espacio o concentrarse en ciertos parches. El alimento se concentra en ciertas zonas; los depredadores frecuentan ciertos territorios. Los organismos que detectan esa estructura espacial pueden dirigir su búsqueda eficientemente: regresar a lugares previamente productivos, evitar lugares peligrosos, explorar zonas con alta probabilidad de contener recursos no descubiertos.

3. Covarianza con el Entorno y con el Comportamiento

Muchos SBI no son predecibles por tiempo o lugar per se, sino que están correlacionados con otras características del mundo. Las nubes oscuras predicen lluvia; ciertos olores indican la proximidad de un depredador; el patrón de coloración de algunas orugas señala su toxicidad. Un organismo que aprende estas relaciones puede anticipar los SBI antes de encontrarlos directamente.

Una segunda forma de covarianza involucra las acciones del propio organismo: muchos SBI solo ocurren si se ejecutan ciertas respuestas. Las mascotas obtienen comida solo cuando realizan conductas específicas; el acceso a un servicio de taxis requiere abrir una aplicación. Aprender qué respuestas producen qué consecuencias permite al organismo no solo predecir, sino controlar activamente la ocurrencia de SBI.

Estas dos formas de covarianza —con señales del entorno y con el comportamiento propio— comparten la misma lógica: detectar qué predice qué. Sin embargo, plantean problemas de asignación de crédito suficientemente distintos como para requerir dos capítulos separados en el Bloque II.

4. Detección de Cambios en el Estado del Entorno

Un problema distinto surge cuando las propiedades estadísticas del entorno cambian sin señales externas evidentes. Una reducción en la disponibilidad de presas puede reflejar variación aleatoria normal o un cambio real en el estado del entorno. Quien deja de recibir mensajes de una persona cercana debe decidir si se trata de algo fortuito o de un cambio genuino en la relación. En la literatura clásica, este problema se ha estudiado principalmente como extinción —la desaparición de un reforzador previamente presente—, pero es más general: se trata de inferir si el estado del mundo ha cambiado o si lo observado es simplemente ruido.

5. Tasa de Ocurrencia

Los organismos no solo detectan si un SBI ocurre o no, sino también con qué frecuencia. Para una abeja, no es suficiente saber que una zona del jardín tiene flores con néctar; importa la tasa —cuántas flores por minuto— porque esa tasa determina la rentabilidad de explotar esa

zona frente a explorar otra. La noción de tasa de ocurrencia desempeña un papel central en las explicaciones contemporáneas del comportamiento de elección, como veremos en el Bloque III.

6. Incertidumbre Esperada e Inesperada

Cualquiera de las propiedades anteriores puede ser más o menos incierta. Cuando la variabilidad es estable —cuando existe una distribución de probabilidad constante que la describe— hablamos de **incertidumbre esperada**. El camión de transporte público no pasa siempre exactamente a la misma hora, pero la variación es predecible: tiene una distribución con media y dispersión conocidas. Cuando los parámetros de esa distribución cambian ellos mismos de acuerdo a otra distribución, el entorno se vuelve **volátil** y la incertidumbre es inesperada. En el metro de la Ciudad de México, la probabilidad de que el tren llegue en los próximos dos minutos es alta en hora pico y baja en horas de poca demanda: hay una distribución que cambia según otra distribución. El Bloque V está dedicado a los mecanismos que permiten aprender en entornos volátiles.

Estas seis propiedades no son una taxonomía arbitraria. Son las dimensiones sobre las que un entorno puede tener estructura estadística que un agente puede, en principio, detectar y aprovechar. Si el entorno tiene regularidad en alguna de estas dimensiones y el organismo carece del mecanismo para detectarla, hay una oportunidad adaptativa sin explotar. Si la tiene, ese mecanismo tendrá ventaja selectiva. Los capítulos siguientes estudian, uno a uno, los mecanismos que evolucionaron para responder a cada tipo de estructura.

7.5 Conclusión

El acceso a los sucesos biológicamente importantes está sujeto a restricciones que ningún organismo puede eludir: el tiempo es finito, la energía es limitada, y la estructura biológica delimita el espacio de comportamientos posibles. Estas restricciones hacen inevitable la competencia entre comportamientos y convierten la distribución del tiempo en un problema de optimización bajo restricciones, no de maximización sin límites.

La forma que toma la solución evolutiva depende de la estructura del entorno. Cuando ese entorno ha sido históricamente estable, la selección codifica la respuesta directamente en el genoma —comportamiento adaptado, eficiente pero rígido. Cuando es variable, la solución es radicalmente distinta: codificar algoritmos que permitan al organismo ajustar su conducta en tiempo real. Dentro de esos algoritmos adaptativos, los reactivos operan con información local e inmediata sin integrar experiencia previa; los de aprendizaje acumulan historia para reducir incertidumbre futura, pero solo ofrecen ventaja cuando el entorno tiene estructura causal que pueda detectarse y aprovecharse.

Esa estructura puede manifestarse en seis dimensiones —tiempo, espacio, covarianza con señales del entorno, covarianza con el comportamiento propio, cambios de estado, tasa de ocurrencia— que no son una clasificación arbitraria sino los problemas estadísticos concretos

que los mecanismos de los bloques siguientes evolucionaron para resolver. Cada algoritmo que estudiaremos es una respuesta a uno de esos problemas. Entender el problema es la condición para entender por qué el mecanismo tiene la forma que tiene.

8 Preguntas de Estudio

8.0.1 Sección I: Restricciones del organismo y del entorno

1. El capítulo presenta una ecuación aparentemente simple: $T = t_1 + t_2 + \cdots + t_n$. ¿Qué afirma esta ecuación sobre la naturaleza del comportamiento? ¿Por qué implica que los comportamientos *compiten* entre sí, en lugar de simplemente coexistir?

2. Define costo de oportunidad con tus propias palabras y da un ejemplo de tu vida cotidiana que no aparezca en el capítulo. Explica explícitamente qué se gana, qué se pierde, y por qué la restricción lineal de tiempo hace inevitable ese trade-off.

3. El capítulo distingue entre restricciones del organismo y restricciones del entorno. ¿Podría existir un agente adaptativo sin restricciones del organismo? ¿Qué implicaría eso para el problema de la distribución del comportamiento?

4. ¿Por qué una respuesta conductual genéticamente fija sería evolutivamente subóptima en un entorno variable? Construye un ejemplo concreto donde una respuesta fija que funcionó bien durante generaciones se vuelve desventajosa al cambiar el entorno.

8.0.2 Sección II: Comportamiento adaptado y comportamiento adaptable

5. La impronta en aves y el reflejo de retirada ante el dolor son ejemplos de comportamiento adaptado. ¿Qué tienen en común como soluciones evolutivas? ¿Qué condición del entorno hace que ambos sean soluciones apropiadas sin necesidad de aprendizaje individual?

7. ¿Por qué el capítulo llama *algoritmos* a los mecanismos de comportamiento adaptable? ¿Qué agrega esa palabra respecto a decir simplemente "mecanismos" o "respuestas aprendidas"?

8.0.3 Sección III: Los dos tipos de algoritmos adaptativos

9. El capítulo afirma que el aprendizaje "solo tiene sentido si el entorno tiene estructura que pueda detectarse y aprovecharse." ¿Qué significa esto? Describe un entorno hipotético donde el aprendizaje no ofrecería ninguna ventaja adaptativa sobre el movimiento aleatorio, y explica por qué.

10. ¿Cuál es la diferencia fundamental entre un algoritmo reactivo y un algoritmo de aprendizaje? No se trata solo de que uno use memoria y el otro no: ¿qué problema diferente resuelve cada uno?

8.0.4 Sección IV: Las propiedades estadísticas del entorno

11. El capítulo lista seis propiedades estadísticas del entorno. Elige dos de ellas y, para cada una, describe: (a) qué tipo de regularidad tiene el entorno, (b) qué mecanismo necesitaría el organismo para aprovecharla, y (c) qué desventaja sufriría un organismo que careciera de ese mecanismo.

12. La extinción —cuando un reforzador deja de presentarse— se ha estudiado clásicamente como un fenómeno del condicionamiento. El capítulo la reencuadra como un caso de detección de cambio en el estado del entorno. ¿Qué gana esa reinterpretación? ¿Qué pregunta diferente nos lleva a hacerle al fenómeno?

13. Para una abeja que forrajea en un jardín con dos zonas de flores, ¿qué información adicional ofrece la *tasa* de ocurrencia de néctar frente a saber simplemente si hay o no néctar en cada zona? ¿Por qué esa información adicional es adaptativamente relevante?

14. El capítulo distingue entre incertidumbre esperada e inesperada (volatilidad). Usa el ejemplo del metro de la Ciudad de México para explicar la diferencia. Luego propón un ejemplo de tu propia experiencia que ilustre la misma distinción.

15. El capítulo argumenta que las seis propiedades estadísticas del entorno no son una clasificación arbitraria. ¿Cuál es el criterio que las unifica? ¿Por qué ese criterio justifica estudiarlas como categorías separadas?

16. Considera el comportamiento de estudiar para un examen. Identifica al menos tres de las seis propiedades estadísticas del entorno que son relevantes para decidir cuándo, dónde y cómo estudiar. Para cada una, describe qué información estadística estaría usando un estudiante que distribuye bien su tiempo de estudio.

9 Ascenso de Colina

9.1 Un Mecanismo de Adaptación Sin Historia

En el capítulo anterior vimos cómo la selección natural opera a escala filogenética para producir comportamiento adaptado: soluciones codificadas genéticamente que funcionan bien en entornos relativamente predecibles. Pero la mayoría de los organismos enfrentan entornos que cambian en escalas de tiempo mucho más cortas que las generaciones, y deben ajustar su comportamiento durante su propia vida, a veces en segundos. ¿Qué ocurre cuando la variación es tan rápida que la selección natural no puede anticiparla, pero tampoco hay tiempo para aprender en el sentido pleno de la palabra?

Este capítulo introduce el primer mecanismo en nuestro cajón de herramientas: el **ascenso de colina** (*hill climbing*). Es un algoritmo elegantemente simple que permite a organismos muy básicos —incluso sin sistema nervioso— navegar eficientemente hacia recursos en entornos variables. Sus componentes esenciales reaparecerán, en formas más sofisticadas, cuando lleguemos al aprendizaje propiamente dicho.

9.2 El Problema Adaptativo

Considera el problema que enfrenta cualquier organismo que necesita encontrar alimento distribuido en el espacio —una bacteria en un medio acuoso, una plántula en el suelo del bosque, una ameba en busca de nutrientes. Hay una restricción que hace el problema particularmente difícil: muchos de estos organismos carecen de **receptores de distancia**, los órganos sensoriales que permiten detectar recursos remotamente, como la visión o el olfato en mamíferos. Sin receptores de distancia, el organismo no puede simplemente "ver" dónde está la comida y dirigirse hacia ella. Solo puede detectar si la concentración de nutrientes en su ubicación *actual* es mayor o menor que hace un momento. La información disponible es estrictamente local y temporal.

A esto se suma que la detección no es perfecta: fluctuaciones aleatorias pueden hacer que una zona parezca momentáneamente mejor o peor de lo que es. Y en entornos con múltiples fuentes de nutrientes, existe el riesgo de quedarse "atascado" en una fuente pequeña cercana, sin llegar a una fuente mayor más alejada —el problema clásico de los **máximos locales**.

Es el mismo desafío que enfrentas cuando buscas señal de wifi en un edificio desconocido: sin mapa, sin vista del router, guiándote solo por la barra de señal que sube o baja con cada paso.

9.3 El Comportamiento Observado

9.3.1 Plantas

Las plantas verdes enfrentan una competencia intensa por la luz solar. Una plántula germinando en el suelo del bosque debe crecer esquivando obstáculos —otras plantas, ramas, rocas— que bloquean su camino hacia la luz. Lo hace con tres comportamientos coordinados: el tallo rota, "barriendo" diferentes direcciones; al detectar mayor intensidad lumínica en alguna dirección, crece preferentemente hacia ese lado (fototropismo); y simultáneamente crece hacia arriba, alejándose del suelo. La combinación de estos tres comportamientos simples produce trayectorias sorprendentemente eficientes hacia la luz, incluso cuando ésta proviene de direcciones cambiantes o hay obstáculos en el camino.

9.3.2 La Salmonela

La bacteria *Salmonella* es notablemente exitosa localizando alimento. En un experimento clásico, se introduce una pipeta capilar con nutrientes en agua donde bacterias nadan libremente. Después de algunos minutos, hay significativamente más bacterias dentro de la pipeta que afuera —tanto cuando el tubo contiene un atrayente como cuando contiene un repelente, en cuyo caso el movimiento neto es de alejamiento. La Fig. 9.1 muestra las tres condiciones experimentales y las trayectorias observadas.

La observación detallada del movimiento de salmonelas individuales revela dos comportamientos básicos que se alternan. El primero son las **maromas** (*tumbling mode*): la bacteria gira sobre sí misma sin desplazamiento neto —exploración, muestreo de diferentes direcciones posibles. El segundo es el **nado en línea recta** (*running mode*): la bacteria avanza en la dirección actual —explotación de una dirección prometedora. La Fig. 9.2 muestra el mecanismo físico: en modo maroma, los flagelos rotan en sentido horario y se desenredan; en nado recto, rotan en sentido antihorario y forman un haz sincronizado que propulsa a la bacteria.

Lo crucial no son los dos comportamientos en sí, sino la regla que determina cuándo cambiar de uno a otro: si la concentración química está mejorando, continúa el nado recto; si deja de mejorar o empeora, pasa a maromas hasta que por casualidad apunte en una dirección donde la concentración vuelva a mejorar. Lo que controla la transición no son los valores absolutos de concentración, sino los *cambios*. La bacteria es sensible a si las cosas están mejorando o empeorando, no a cuán buenas son en un momento dado.

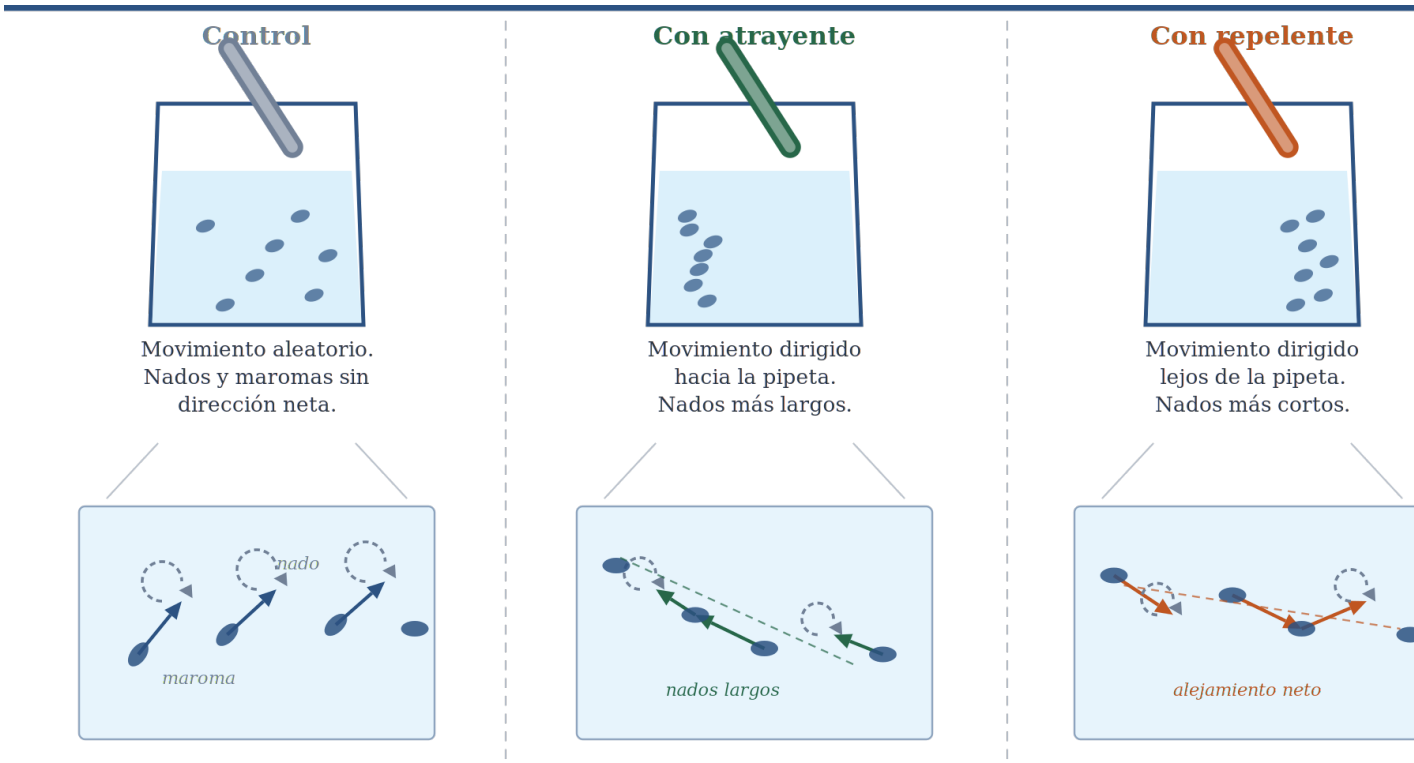

Figura 4.1. Experimento de la pipeta capilar con *Salmonella typhimurium* en tres condiciones. Control: movimiento aleatorio sin dirección neta. Con atrayente: nados más largos, maromas menos frecuentes; acumulación neta en la pipeta. Con repelente: nados dirigidos lejos de la pipeta; movimiento neto de alejamiento.

Figura 9.1

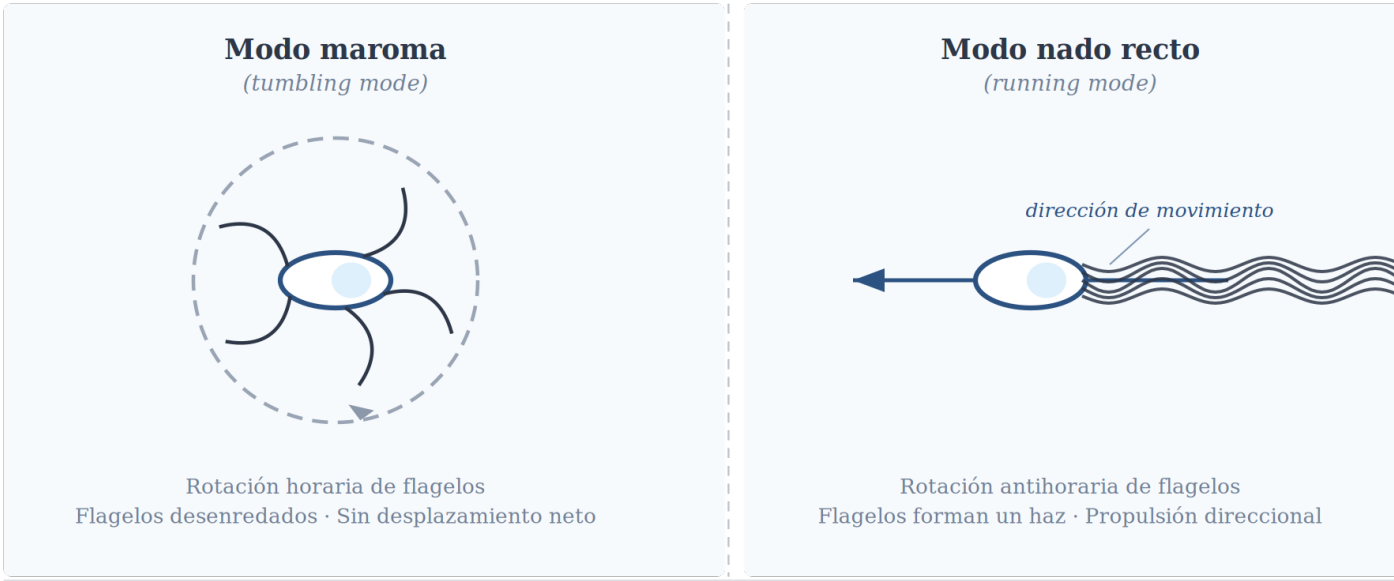

Figura 4.2. Los dos modos de locomoción bacteriana. En modo maroma (izq.), los flagelos giran en sentido horario y se desenredan, sin producir desplazamiento neto. En modo nado recto (der.), los flagelos rotan en sentido antihorario, forman un haz sincronizado y propulsan a la bacteria en línea recta.

Figura 9.2

9.3.3 La Pregunta Crucial: ¿Simultánea o Sucesiva?

Esto nos lleva a una pregunta fundamental: ¿cómo "sabe" la bacteria si va en la dirección correcta? Hay dos posibilidades en principio. La primera es **comparación simultánea**: la bacteria podría tener receptores en diferentes partes de su cuerpo que comparan la concentración en distintos puntos del espacio al mismo tiempo, como un mamífero que compara las señales que llegan a sus dos fosas nasales. La segunda es **comparación sucesiva**: la bacteria compara la concentración en su posición actual con la concentración en su posición inmediatamente anterior.

La evidencia experimental descarta la primera posibilidad. El diámetro de una bacteria es tan pequeño que la diferencia de concentración entre sus dos extremos es prácticamente imperceptible —el gradiente espacial, a esa escala, no puede detectarse. Lo que sí puede detectarse son los *cambios temporales* en la concentración mientras la bacteria se mueve. Esto se confirma experimentalmente: las transiciones entre maromas y nado recto se producen ante cambios bruscos en la concentración, no ante valores absolutos. Como veremos a lo largo del curso, esta sensibilidad a cambios más que a valores absolutos es una característica ubicua de los sistemas sensoriales y de aprendizaje.

9.3.4 La Adaptación Sensorial

Hay una complicación adicional. Si la bacteria cambiara a nado recto ante el primer incremento detectado y se quedara así indefinidamente, probablemente terminaría en la primera mejora que encontró, no en la mejor ubicación posible. Las bacterias resuelven esto mediante **adaptación sensorial**: después de un tiempo breve —menos de un minuto en Salmonella— el sistema de detección "se acostumbra" al nivel actual de concentración. Lo que antes parecía "alta concentración" se convierte gradualmente en el nuevo punto de referencia "normal". La bacteria vuelve a dar maromas hasta encontrar una concentración aún mayor.

La Fig. 9.3 muestra esta dinámica cuantitativamente. Cuando se añade un atrayente en $t = 0$, la fracción de bacterias en nado recto aumenta abruptamente, reflejando el cambio brusco detectado. Pero en el transcurso de menos de un minuto esa fracción regresa a los valores basales, aun cuando el atrayente sigue presente: la adaptación sensorial ajustó el punto de referencia al nuevo nivel. El sistema vuelve a ser sensible a *cambios adicionales*.

La adaptación sensorial implementa una forma de insatisfacción adaptativa: el organismo nunca se contenta completamente con lo actual, sino que sigue buscando mientras haya tiempo y energía. Como veremos más adelante, esta misma lógica reaparece en mecanismos de aprendizaje mucho más complejos.

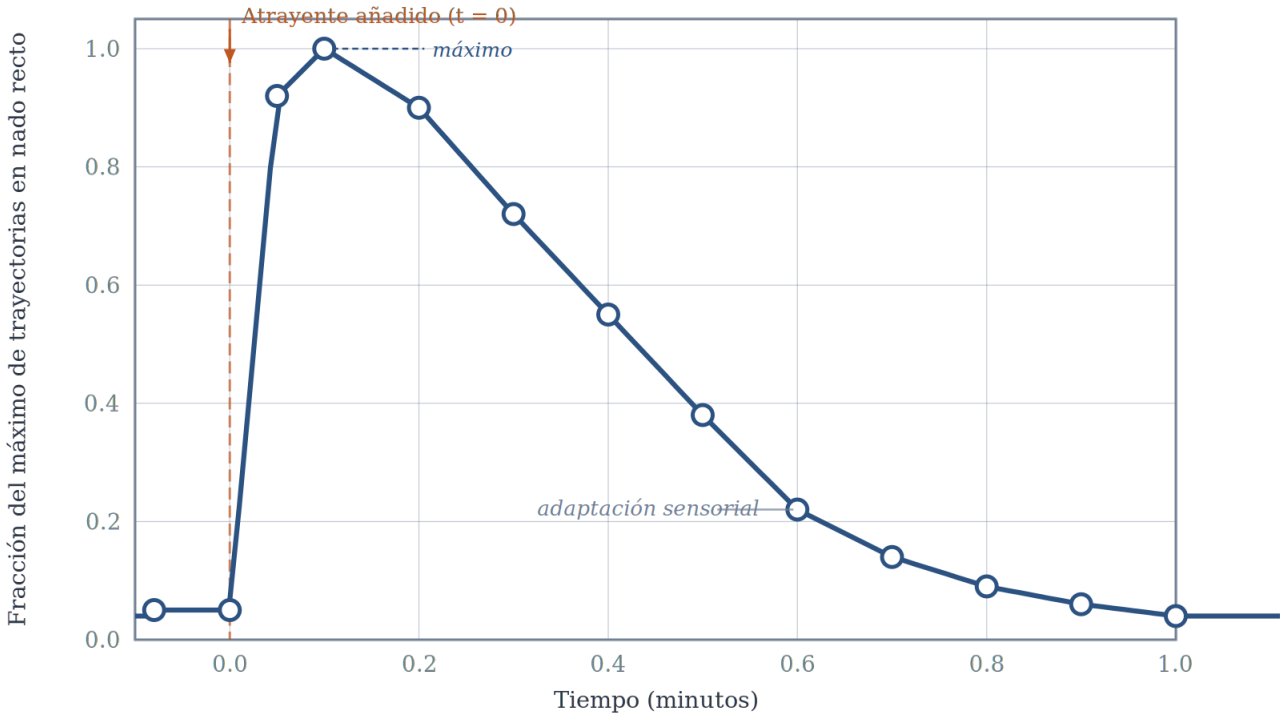

Figura 4.3. Cuantificación de la respuesta al atrayente en *Salmonella typhimurium.* Al añadir el atrayente (t = 0), la fracción de bacterias en nado recto aumenta abruptamente. La recuperación al nivel basal en menos de un minuto refleja la adaptación sensorial: el sistema responde a cambios en la concentración, no a valores absolutos.

Figura 9.3

9.4 El Algoritmo

Imagina que subes el Ajusco con los ojos vendados. No puedes ver la cima ni el sendero. Lo único que puedes hacer es sentir si el suelo bajo tus pies va hacia arriba o hacia abajo. Si sube, sigues en esa dirección. Si empieza a bajar, te detienes y tanteas otras direcciones hasta encontrar una que vuelva a subir. Después de un tiempo —aunque la cuesta siga siendo empinada— el esfuerzo muscular se vuelve la nueva normalidad y ya no distingues si estás subiendo o no: vuelves a tantear. Eso es todo el algoritmo. La bacteria hace exactamente lo mismo, pero con concentración química en lugar de pendiente, y con flagelos en lugar de piernas.

El mecanismo necesita las mismas piezas en cualquier implementación: un sensor que detecta cambios en la variable relevante, una memoria brevísima del momento anterior, dos modos de movimiento contrastantes —explorar y explotar—, una regla para cambiar entre ellos, y la adaptación sensorial que equivale al momento en que dejas de sentir la pendiente y te obliga a buscar de nuevo. Con esas cinco piezas, el algoritmo está completo.

Existe además una variante ligeramente más sofisticada: en lugar de tomar la primera dirección que mejore, el organismo muestrea múltiples direcciones, registra el valor en cada una, y se mueve hacia la que mostró la mayor mejora. Es el **ascenso de mayor pendiente** —más costoso en memoria, pero más eficiente en entornos ruidosos donde un solo muestreo puede dar una impresión equivocada. El ejemplo de wifi lo ilustra bien: en la versión simple das un paso en una dirección y decides; en la versión de mayor pendiente te detienes, exploras varios pasos en distintas direcciones, memorizas los valores, y luego caminas decididamente hacia donde la señal fue mayor.

En ambos casos estás haciendo *comparaciones sucesivas*, igual que la bacteria: no puedes ver el router, solo puedes comparar si tienes más o menos señal que hace un momento. Esto distingue al ascenso de colina del mecanismo que veremos en el capítulo siguiente, donde la comparación es simultánea —dos puntos del espacio se comparan al mismo tiempo, no el mismo punto en dos momentos distintos.

¿Qué tan bueno es el algoritmo?

El algoritmo que describimos funciona, pero conviene preguntarse qué tan bien funciona y si puede hacerse mejor. Para eso, la competencia del Ajusco es útil más allá de ilustrar el mecanismo.

Imagina que ahora tienes información sobre la montaña: sabes que el Ajusco no es una colina perfectamente suave sino un terreno accidentado, con peñascos, cerros secundarios y mesetas que desde abajo parecen la cima. Tu compañero está vendado y usa el ascenso simple —da un paso, siente si subió o bajó, decide. Tú también estás vendado, pero usas el ascenso de mayor pendiente: antes de comprometerte con una dirección, tanteas varios pasos en distintas direcciones, memorizas los valores, y luego avanzas decididamente hacia donde la pendiente fue mayor. En una montaña suave, tu estrategia no te da ninguna ventaja y te cuesta tiempo extra.

En una montaña con muchos cerros secundarios, tu estrategia reduce el riesgo de quedarte atascado en uno de ellos.

Pero hay algo que ambos hacen mal: el tamaño del paso. Lejos de la cima, cuando el terreno cambia rápidamente con cada movimiento, tiene sentido dar pasos grandes —la información de un paso pequeño es poco informativa respecto a si la dirección general es buena. Conforme te acercas a la cima, la pendiente se suaviza y la señal de cada paso se vuelve más pequeña y más ruidosa. En ese momento, un paso grande puede hacerte cruzar la cima sin notarlo. El paso óptimo no es constante: debe ir reduciéndose conforme se acerca al objetivo.

En la ecuación del mecanismo, el tamaño efectivo del paso está controlado por el parámetro b: cuánto peso le da el sistema a cada diferencia detectada. Un b grande actúa como un paso largo —sensible, rápido para reaccionar, pero propenso a sobrepasar el objetivo. Un b pequeño actúa como un paso corto —robusto ante el ruido, pero lento para reaccionar ante cambios reales. El valor óptimo de b no es fijo: depende de las características del terreno que está navegando el organismo.

Lo mismo aplica al parámetro a, que controla cuánto tiempo sigue el organismo en modo de explotación después de que la señal se estabiliza. En una montaña con pocos máximos locales, un a alto es bueno —el organismo explota con inercia y llega rápido a la cima. En una montaña con muchos cerros secundarios, un a alto es una trampa: el inercia del sistema lo mantiene escalando el primer cerro que encuentra aunque haya uno más alto a su izquierda. El valor óptimo de a también depende del terreno.

Esto no es un defecto del mecanismo sino una propiedad fundamental de cualquier algoritmo de búsqueda: no existe una estrategia universalmente óptima independiente del problema. Lo que existe son estrategias bien adaptadas a tipos particulares de entornos. Y si el entorno cambia, o si el organismo no sabe de antemano qué tipo de entorno enfrenta, el valor fijo de a y b con que parte puede ser bueno o puede ser desastroso.

La solución verdaderamente óptima al problema no es encontrar los mejores valores fijos de a y b, sino desarrollar la capacidad de *ajustar esos valores conforme se acumula experiencia con el entorno*. Un agente que empieza con pasos grandes cuando el terreno es desconocido y los va reduciendo sistemáticamente conforme aprende que está cerca de un óptimo —ese agente es mejor que cualquier agente con parámetros fijos, sin importar qué tan bien calibrados estén esos parámetros. Esa capacidad de ajustar adaptativamente la importancia del error es exactamente lo que veremos en los mecanismos de aprendizaje de los bloques siguientes.

Veremos esa capacidad —ajustar adaptativamente la importancia del cambio detectado— cuando lleguemos a los modelos de aprendizaje asociativo en el Bloque II.

9.5 Formalización Matemática

En el simulador que acaban de explorar, el parámetro a es exactamente el tiempo que el agente sigue explotando después de que la concentración dejó de mejorar. Con a cercano a 1, la inercia es grande —como un corredor que tarda en frenar. Con a cercano a 0, para casi de inmediato. El término $b \cdot [X(t+1) - X(t)]$ es la diferencia que ya calcularon en los ejercicios del simulador, multiplicada por qué tanto le importa al sistema esa diferencia.

Juntando las dos partes, la ecuación que rige todo lo que observaron es:

$$Y(t+1) = a \cdot Y(t) + b \cdot [X(t+1) - X(t)]$$

donde Y(t) es la variable de decisión que determina el modo conductual, X(t) es el valor de la variable ambiental (concentración química, intensidad lumínica, señal de wifi), a es el parámetro de adaptación sensorial ($0 < a < 1$), y b es el parámetro de sensibilidad al cambio ($b > 0$).

La regla de respuesta conecta Y con el comportamiento observable: si Y supera un umbral (típicamente cero), el organismo explota —nado recto, crecimiento hacia la luz, caminar en esa dirección; si Y está por debajo, explora —maromas, rotación, prueba otra dirección.

El marciano del capítulo anterior se preguntaba qué *hace* el vehículo. Aquí la pregunta es qué *problema resuelve* la bacteria —y esa pregunta nos dice por qué la ecuación tiene la forma que tiene. Si el problema es navegar sin mapa y sin receptores de distancia, necesitas comparación temporal, no espacial. Y necesitas adaptación que te impida conformarte con el primer gradiente positivo que encuentres. Todo lo demás se sigue de ahí.

9.5.1 Un Ejemplo Numérico

Sigamos la dinámica con valores concretos: a = 0.9, b = 0.5, umbral = 0. Partimos de Y(0) = 0 y X(0) = 5. El agente está en modo exploración.

Tiempo 1: X(1) = 7 — la concentración mejora. Y(1) = 0.9 × 0 + 0.5 × (7 − 5) = 0 + 1.0 = **1.0** → Explotar.

Tiempo 2: X(2) = 9 — sigue mejorando. Y(2) = 0.9 × 1.0 + 0.5 × (9 − 7) = 0.9 + 1.0 = **1.9** → Explotar.

Tiempo 3: X(3) = 9 — la concentración se estabiliza. Y(3) = 0.9 × 1.9 + 0.5 × (9 − 9) = 1.71 + 0 = **1.71** → Explotar (Y empieza a decaer).

Tiempo 4: X(4) = 8 — baja ligeramente. Y(4) = 0.9 × 1.71 + 0.5 × (8 − 9) = 1.54 − 0.5 = **1.04** → Explotar.

Tiempo 5: X(5) = 7 — sigue bajando. Y(5) = 0.9 × 1.04 + 0.5 × (7 − 8) = 0.94 − 0.5 = **0.44** → Explotar (Y casi en umbral).

Tiempo 6: X(6) = 6 — sigue empeorando. Y(6) = 0.9 × 0.44 + 0.5 × (6 − 7) = 0.40 − 0.5 = **−0.10** → **Explorar**.

La secuencia muestra algo importante: el sistema no cambia a exploración en el instante en que la concentración deja de mejorar. La inercia del término a · Y mantiene la explotación durante un tiempo —un filtro que evita responder a fluctuaciones momentáneas. Pero si la concentración no mejora de forma sostenida, Y cae por debajo del umbral y el organismo vuelve a buscar. Esto corresponde exactamente a lo que muestra la figura 4.3: la bacteria mantiene el nado recto por un tiempo incluso cuando la concentración se estabiliza, antes de que la adaptación sensorial la devuelva al modo exploración.

¡Prueba el Simulador Interactivo!

Para explorar los conceptos de este capítulo en la práctica, abre el siguiente simulador:
Abrir Simuladores en Google Colab

Verás un agente navegando un paisaje de concentración con dos fuentes: una fuente principal (la meta) y un máximo local (la trampa). Parámetros: a, b, nivel de ruido. La trayectoria se colorea por modo: exploración en azul, explotación en naranja. Gráficas en tiempo real de Y(t) y X(t).

Objetivo: Descubrir qué combinación de adaptación sensorial y sensibilidad al cambio produce navegación eficiente, y por qué ninguno de los extremos funciona bien.

Básico: Comienza con a = 0.9 y b = 0.5. Antes de iniciar la simulación, predice: ¿crees que el agente llegará a la fuente principal o quedará atrapado en el máximo local? Corre la simulación y verifica. Ahora reduce a a 0.3 manteniendo b constante. ¿Qué cambia?

Intermedio: Con a = 0.97 (adaptación muy lenta), ¿el agente escapa del máximo local? Prueba a = 0.5. ¿Por qué la adaptación sensorial ayuda a escapar de los máximos locales? Piensa en términos del Ajusco: si nunca dejas de sentir la pendiente actual, ¿qué te impide buscar una pendiente mayor?

Avanzado: Activa el ruido ambiental. Encuentra la combinación de a y b que produce la navegación más eficiente con ruido alto. ¿Por qué algunos valores de b que funcionaban sin ruido ya no funcionan? ¿Qué hace que el ruido sea un problema para la sensibilidad al cambio?

9.6 Lo que el Ascenso de Colina Hace y No Hace

El ascenso de colina permite adaptación en tiempo real y navegación eficiente hacia gradientes sin mapa ni receptores de distancia. El balance exploración-explotación emerge automáticamente de la dinámica del sistema, y la inercia del término a · Y actúa como filtro ante el ruido.

Lo que el mecanismo *no* hace es igualmente revelador. En este modelo la comparación es entre el valor actual y el valor inmediatamente anterior: **no hay integración de experiencias pasadas**. Si repetimos la misma situación mañana, el organismo responde igual que hoy —no hay memoria de largo plazo. El mecanismo es puramente reactivo: responde a cambios que ya ocurrieron, no anticipa cambios futuros. No hay modelo interno del entorno ni representación de dónde están las fuentes. Y no hay aprendizaje en el sentido estricto: una bacteria que navegó exitosamente ayer no navega mejor hoy por haber tenido esa experiencia.

Esta distinción es central para el libro. El **comportamiento adaptativo sin aprendizaje** —como el ascenso de colina— produce flexibilidad conductual en respuesta al entorno actual, pero sin retener información de experiencias previas. El **comportamiento adaptable** —que estudiaremos en los bloques siguientes— supone exactamente eso: un cambio duradero en el sistema como resultado de la experiencia. El ascenso de colina es un mecanismo sin historia. Su importancia pedagógica está en que los mismos principios —comparación, reducción de error, balance exploración-explotación— reaparecerán, transformados y enriquecidos, en los mecanismos de aprendizaje que estudiaremos más adelante.

9.7 Conexiones

9.7.1 Hacia atrás: Selección Natural

El ascenso de colina es una instancia de ensayo y error análoga, en su lógica, a la selección natural: la exploración aleatoria genera variación conductual; la comparación determina qué variantes se explotan; la explotación continúa mientras el gradiente es favorable. La diferencia crucial es la escala temporal. La selección natural opera en generaciones; el ascenso de colina opera en segundos o minutos en la vida del individuo. Son el mismo principio en escalas de tiempo radicalmente distintas.

9.7.2 Hacia adelante: Aprendizaje por Refuerzo

La diferencia $[X(t+1) - X(t)]$ es una primera versión del **error de predicción**: la discrepancia entre lo que se esperaba y lo que ocurrió. La actualización incremental de Y es análoga a cómo el valor asociativo se ajusta ensayo a ensayo en los modelos del Bloque II. Y el dilema exploración-explotación, que aquí aparece en su forma más simple, se convertirá en uno de los problemas centrales del aprendizaje por refuerzo en el Bloque IV.

9.7.3 Lateral: Sistemas de Retroalimentación (Próximo Capítulo)

El ascenso de colina utiliza **comparación sucesiva**: el mismo lugar en dos momentos distintos. El próximo capítulo introduce los sistemas de retroalimentación, que utilizan **comparación**

simultánea: dos puntos del espacio se comparan al mismo tiempo. Ambos son mecanismos de adaptación sin aprendizaje, pero la diferencia en el tipo de comparación tiene consecuencias importantes para qué problemas puede resolver cada uno —y la distinción entre los dos es exactamente lo que la evidencia experimental descartó en la Salmonella.

10 Resumen

El problema adaptativo de este capítulo es localizar recursos en entornos variables sin receptores de distancia ni mapa previo. La solución es el ascenso de colina: un algoritmo de comparación sucesiva que alterna entre exploración aleatoria y explotación direccional, guiado por cambios en una variable ambiental de interés. Sus piezas esenciales son: un sensor de cambios, una memoria mínima del momento anterior, dos modos conductuales contrastantes, una regla de transición entre ellos, y adaptación sensorial que previene el estancamiento en máximos locales.

Lo que el mecanismo no hace es tan importante como lo que hace: no hay integración de historia, ni predicción, ni representación del entorno, ni cambio duradero. Es comportamiento adaptativo sin aprendizaje. Su relevancia pedagógica está en que los mismos principios —comparación, reducción de error, balance exploración-explotación— reaparecerán, transformados y enriquecidos, en los mecanismos de aprendizaje de los bloques siguientes.

10.1 Ejercicios de Comprensión

1. La figura 4.3 muestra que después de añadir un atrayente, la fracción de bacterias en nado recto aumenta abruptamente y luego regresa a los valores basales en menos de un minuto. Explica este patrón en términos del parámetro a de la ecuación. ¿Qué valor de a produciría una recuperación más rápida? ¿Qué pasaría si $a = 1$ exactamente?

2. El capítulo descarta la posibilidad de comparación simultánea en Salmonella con un argumento basado en el tamaño de la bacteria. Formula ese argumento con tus propias palabras. ¿Puedes pensar en algún organismo que sí pudiera usar comparación simultánea para detectar un gradiente químico?

3. Imagina que buscas señal de wifi en un edificio desconocido. Describe, paso a paso, cómo aplicarías el ascenso de mayor pendiente. ¿En qué situaciones preferirías el ascenso simple? ¿Cuándo valdría la pena el esfuerzo adicional?

4. Usando la ecuación $Y(t+1) = a \cdot Y(t) + b \cdot [X(t+1) - X(t)]$, con $a = 0.8$ y $b = 1.0$, completa la tabla. El umbral para explotar es 0.

t	X(t)	Y(t)	¿Explorar o explotar?
0	10	0	—

t	X(t)	Y(t)	¿Explorar o explotar?
1	12	?	?
2	14	?	?
3	14	?	?
4	13	?	?

¿En qué momento el sistema cambia de modo? ¿Qué dice eso sobre la relación entre estabilización de concentración y exploración?

5. El capítulo afirma que el ascenso de colina no es aprendizaje. ¿Qué le falta para serlo? Formula una modificación hipotética al mecanismo que lo convertiría en algo más parecido al aprendizaje. ¿Qué nueva capacidad adaptativa tendría el organismo con esa modificación?

6. *(Reflexión)* La adaptación sensorial implementa una forma de "insatisfacción adaptativa". ¿Por qué sería desadaptativo un organismo que no tuviera esta propiedad —que se contentara para siempre con el primer gradiente positivo que encontrara? ¿Puedes pensar en algún contexto donde esa estrategia podría ser ventajosa?