

Aprendizaje y Comportamiento Adaptable: Principios y Modelos

Arturo Bouzas

31 May 2026

Índice de contenido

1	Notas de Aprendizaje y Comportamiento Adaptable	9
	Prefacio	10
1.0.1	Prefacio	10
2	Prefacio	11
2.1	Principios y Modelos	11
2.2	¿Para Quién es Este Libro?	11
2.3	Filosofía del Libro	11
2.3.1	Marco Conceptual Unificado	11
2.3.2	Énfasis en Principios Generales	12
2.3.3	Implementación Computacional	12
2.3.4	Simuladores Interactivos	12
2.4	Cómo Usar Este Libro	12
2.4.1	Para Estudiantes	12
2.4.2	Para Instructores	12
2.5	Recursos Adicionales	13
2.6	Licencia y Uso	13
2.7	Agradecimientos	13
2.8	Contacto	13
2.9	Aviso: Libro en Desarrollo	14
3	Introducción	15
3.1	Un Problema de Diseño	15
3.2	El Problema con la Enseñanza Tradicional	16
3.3	Un Problema Adaptativo Fundamental	16
3.4	Dos Componentes Esenciales	17
3.5	Dos Orígenes de Soluciones	17
3.6	Mecanismos Reutilizables: Las “Tuercas y Tornillos”	18
3.7	El Enfoque de Este Libro	18
3.7.1	Una Perspectiva Ingenieril	18
3.8	Mapa del Curso	19
3.8.1	Bloque 0: Fundamentos Conceptuales (Capítulos 0-3)	19
3.8.2	Bloque I: Mecanismos Sin Integración de Historia (Capítulos 4-5)	19

3.8.3	Bloque II: El Problema del Conocimiento - Asignación de Crédito (Capítulos 6-10)	19
3.8.4	Bloque III: El Problema de la Acción - Elección y Optimización (Capítulos 11-15)	19
3.8.5	Bloque IV: Aprendizaje Secuencial	20
3.8.6	Bloque V: Incertidumbre y Estados Ocultos	20
3.9	Cómo Usar Estas Notas	20
3.9.1	Para el Estudiante: Estrategias de Lectura Activa	20
3.9.2	Para el Instructor	21
3.10	Un Argumento Final	22
4	Modelos y Explicación	24
4.1	La Visión Ortodoxa y Sus Límites	24
4.1.1	El Problema de la Asimetría	25
4.2	De Teorías a Modelos	25
4.2.1	Los Modelos como Vehículos de Inferencia	26
4.3	La Pluralidad de Formas de Explicar	26
4.3.1	Explicación Causal	27
4.3.2	Explicación Mecanicista	27
4.3.3	Explicación Unificadora	27
4.4	Niveles de Análisis	28
4.4.1	El Marco de Tinbergen	28
4.4.2	El Marco de Killeen	28
4.4.3	El Marco de Marr	28
4.4.4	Progresión Científica: De Descripciones a Explicaciones	29
4.5	Van Fraassen: La Explicación como Respuesta a Preguntas	30
4.6	Una Nota sobre los Modelos de Datos	30
4.7	Síntesis	31
4.8	Ejercicios de Comprensión	31
5	Teoría de la Selección Natural	32
5.1	La Variabilidad y el Ajuste al Entorno	32
5.2	Los Tres Principios de la Selección Natural	33
5.3	Las Fuentes de la Variabilidad	34
5.4	El Entorno como Filtro	34
5.5	La Selección Natural como Algoritmo de Búsqueda	35
5.5.1	El Espacio Fenotípico y el Paisaje Adaptativo	35
5.5.2	Restricciones: Qué Regiones del Espacio Son Accesibles	36
5.5.3	El Problema de los Óptimos Locales	36
5.5.4	Cuando el Paisaje Cambia	37
5.6	Otros Factores Evolutivos	38
5.7	Modelando el Cambio: Ecuaciones en Diferencia	38
5.8	Covarianza: La Relación entre Rasgo y Éxito Reproductivo	39

5.9	La Ecuación del Cambio Evolutivo	40
5.10	La Equivalencia con los Modelos de Aprendizaje	41
5.10.1	El Problema de la Asignación de Crédito	41
5.11	Conexiones con el Resto del Curso	42
5.12	Resumen	42
6	Preguntas de Estudio — Capítulo 2: Evolución y Adaptación	44
6.1	Sección I: Comprensión conceptual	44
6.2	Sección II: Restricciones y espacio fenotípico	44
6.3	Sección III: El modelo matemático	45
7	El Papel de las Restricciones en la Evolución del Comportamiento Adaptable	46
7.1	Las Restricciones del Organismo	46
7.2	Las Restricciones del Entorno	47
7.3	Dos Tipos de Algoritmos Adaptativos	48
7.4	Las Propiedades Estadísticas del Entorno	48
7.5	Conclusión	50
8	Preguntas de Estudio	52
8.0.1	Sección I: Restricciones del organismo y del entorno	52
8.0.2	Sección II: Comportamiento adaptado y comportamiento adaptable	52
8.0.3	Sección III: Los dos tipos de algoritmos adaptativos	52
8.0.4	Sección IV: Las propiedades estadísticas del entorno	53
9	Ascenso de Colina	54
9.1	Un Mecanismo de Adaptación Sin Historia	54
9.2	El Problema Adaptativo	54
9.3	El Comportamiento Observado	55
9.3.1	Plantas	55
9.3.2	La Salmonela	55
9.3.3	La Pregunta Crucial: ¿Simultánea o Sucesiva?	58
9.3.4	La Adaptación Sensorial	58
9.4	El Algoritmo	60
9.5	Formalización Matemática	62
9.5.1	Un Ejemplo Numérico	62
9.6	Lo que el Ascenso de Colina Hace y No Hace	63
9.7	Conexiones	64
9.7.1	Hacia atrás: Selección Natural	64
9.7.2	Hacia adelante: Aprendizaje por Refuerzo	64
9.7.3	Lateral: Sistemas de Retroalimentación (Próximo Capítulo)	64
10	Resumen	66
10.1	Ejercicios de Comprensión	66

11	Sistemas de Retroalimentación	68
11.1	Comparación Simultánea y el Límite de la Reactividad	68
11.2	El Problema: Orientarse en el Espacio	68
11.3	El Mecanismo: Comparación Simultánea	69
11.4	El Sistema de Retroalimentación	72
11.5	Las Cuatro Preguntas	74
11.5.1	¿Qué tan buena es la función de control?	76
11.6	Regulación y Servomecanismos	77
11.7	El Límite Fundamental: Esclavos del Presente	78
11.8	El Conductor y las Gasolineras	79
11.9	El Puente Hacia el Aprendizaje	80
11.10	Comparación: Los Dos Mecanismos Sin Historia	80
11.11	Ejercicios de Comprensión	81
11.12	Para Profundizar	81
12	El Problema de la Asignación de Crédito	84
12.1	El Problema: Un Espacio Enorme de Candidatos	84
12.2	El Genoma Como Archivo Causal	85
12.3	El Sistema de Comportamiento Como Primer Filtro	86
12.4	El Primer Sesgo: Contigüidad Temporal	86
12.4.1	El Experimento de Pavlov	86
12.5	¿Es la Contigüidad Condición Necesaria? El Experimento de García	88
12.5.1	La Relevancia Biológica Como Sesgo Evolutivo	90
12.5.2	El Sesgo de Novedad	91
12.6	¿Es la Contigüidad Condición Suficiente?	91
12.6.1	Ensombrecimiento: Los Estímulos Compiten	92
12.6.2	Bloqueo: La Historia del Organismo Importa	93
12.7	Optimalidad: ¿Cuándo Funciona la Contigüidad y Cuándo Falla?	95
12.8	Hacia el Modelo Formal	97
12.9	Conexiones	98
12.9.1	Hacia atrás: Selección Natural y Retroalimentación	98
12.9.2	Hacia adelante: Asignación de Crédito a Respuestas (Capítulo 9)	98
12.9.3	Hacia adelante: Bush y Mosteller y el Error de Predicción (Capítulo 10)	98
12.9.4	Hacia adelante: Rescorla-Wagner y la Competencia entre Estímulos (Capítulo 11)	99
12.10	Resumen	99
12.11	Ejercicios	100
12.12	Lecturas Recomendadas	101
13	El Problema de la Asignación de Crédito (II)	103
13.1	Acciones, Inducción y el Problema del Control	103
13.2	Thorndike y dos preguntas que se confundieron durante décadas	103
13.3	El primer sesgo: la inducción de respuestas por el SBI	104

13.4 El experimento de Skinner y la réplica de Staddon y Simmelhag	105
13.5 ¿Es la contigüidad una condición necesaria?	107
13.6 Perspectiva molecular y perspectiva molar	111
13.7 La percepción de causalidad: el experimento de Killeen	111
13.8 Por qué la contigüidad es un buen sesgo, y cuándo falla	113
13.9 Apertura hacia los modelos formales	114
13.10 Simulador 7.1: Inducción temporal y respuestas interinas/terminales	115
13.11 Simulador 7.2: Detección de contingencia con gradiente de demora	115
13.12 Conexiones	116
13.12.1 Hacia atrás: Asignación de crédito a estímulos (Capítulo 6)	116
13.12.2 Hacia adelante: La ecuación de Bush y Mosteller (Capítulo 8)	116
13.12.3 Lateral: Programas de refuerzo e igualación (Bloque IV)	116
13.13 Ejercicios	117
13.14 Resumen	118
13.15 Lecturas Recomendadas	118
14 Aprendizaje por Refuerzo	121
14.1 El Modelo de Bush y Mosteller	121
14.2 Las curvas de aprendizaje	121
14.3 Aprendizaje por Refuerzo: elementos comunes	124
14.4 Ecuaciones en diferencia: un lenguaje ya conocido	124
14.5 Primera lectura: el integrador con fuga	125
14.6 Segunda lectura: la reducción del error de predicción	129
14.7 Tercera lectura: el filtro de media exponencial corrida	131
14.7.1 Medianas corridas y el problema del alisamiento	131
14.7.2 De la media simple a la regla delta	131
14.7.3 Del peso decreciente al peso constante	131
14.8 Las tres lecturas son la misma ecuación	131
14.9 Conexiones	131
14.9.1 Hacia atrás: Kinesis, Retroalimentación y Asignación de Crédito	131
14.9.2 Hacia adelante: Rescorla-Wagner (Capítulo 11)	131
14.10 Resumen	131
14.11 Ejercicios	131
14.12 Lecturas Recomendadas	131
15 El Modelo de Rescorla y Wagner	131
15.1 El problema de Bush y Mosteller con estímulos compuestos	131
15.2 Dos componentes del modelo de Rescorla y Wagner	131
15.2.1 Separabilidad	131
15.2.2 Valor predictivo de los elementos	131
15.2.3 La regla de integración: la suma	131
15.2.4 La regla de actualización: el error compartido	131
15.2.5 Competencia	131

15.3	Los parámetros α y β	131
15.4	Un ejemplo cotidiano	131
15.5	Aplicación al ensombrecimiento	131
15.6	Aplicación al bloqueo	131
15.7	Predicción contraintuitiva: la sobreexpectación	131
15.8	Inhibición condicionada	131
15.8.1	Por qué un estímulo neutral no se convierte en inhibidor	131
15.8.2	Cómo se crea un inhibidor	131
15.8.3	El problema empírico: ¿inhibidor o neutral?	131
15.9	Limitaciones del modelo	131
15.9.1	La extinción no reduce el valor a cero	131
15.9.2	La inhibición condicionada no se extingue	131
15.9.3	Inhibición latente	131
15.10	Conexiones	131
15.10.1	El comparador universal: de la selección natural a Rescorla-Wagner	131
15.10.2	Hacia atrás: Bush y Mosteller y la asignación de crédito	131
15.10.3	Hacia adelante: Correlaciones, tiempo y modelos bayesianos	131
15.11	Resumen	131
15.12	Ejercicios	131
15.13	Lecturas Recomendadas	131
16	Traducción del Conocimiento en Acción	131
16.1	1. Primera respuesta: sustitución de estímulos	131
16.2	2. La anticipación no es una copia del reflejo	131
16.3	3. La forma de la respuesta depende de lo que se anticipa y de cómo se anuncia	131
16.3.1	Video: Respuestas para comida y agua	131
16.4	4. El predictor en el flujo conductual	131
16.5	5. Predictores que adquieren valor hedónico	131
16.6	6. Predictores como imanes y repelentes	131
16.6.1	Video: Automoldeamiento de la respuesta de picar una tecla	131
16.7	7. Sistemas de comportamiento	131
16.8	8. La ventaja adaptativa de anticipar	131
16.9	Conclusión	131
16.10	Conexiones	131
16.10.1	Hacia atrás	131
16.10.2	Hacia adelante	131
16.11	Resumen	131
16.12	Ejercicios	131
16.13	Lecturas recomendadas	131
17	La Ley del Efecto y los Programas de refuerzo	131
17.1	Del Conocimiento a la Acción	131
17.2	De Thorndike a Skinner: una nueva unidad de análisis	131

17.3 Entornos intermitentes: los programas de refuerzo	131
17.4 Los patrones: regularidades sorprendentes	131
17.5 El experimento de cajas acopladas	131
17.6 Primera explicación: el reforzamiento diferencial de tiempos entre respuestas	131
17.7 Segunda explicación: sensibilidad a las correlaciones	131
17.8 El reforzador como estímulo discriminativo	131
17.9 La función de retroalimentación: formalización	131
17.10 Lo que la ley del efecto simple no explica (y lo que sí)	131
17.11 Conexiones	131
17.11.1 Hacia atrás	131
17.11.2 Hacia adelante	131
17.12 Resumen	131
17.13 Ejercicios	131
17.14 Lecturas Recomendadas	131
18 Elección Recurrente: Igualación	131
18.1 Decisiones Basadas en el Valor	131
18.2 Elección Recurrente	131
18.3 La Ley de Igualación	131
18.3.1 Igualación de Tiempos Asignados	131
18.4 Desviaciones de la Igualación Perfecta	131
18.4.1 Sesgo	131
18.4.2 Sensibilidad	131
18.5 La Ley Generalizada de Igualación	131
18.6 ¿Qué Computa el Organismo? Dos Preguntas Sobre Igualación	131
18.6.1 ¿Es la Igualación Funcionalmente Equivalente a Maximizar?	131
18.6.2 ¿Cuál es el Algoritmo? Maximización vs. Rentabilidad	131
18.6.3 Maximización vs. Rentabilidad: Un Experimento Decisivo	131
18.7 Conexiones	131
18.7.1 Hacia Atrás	131
18.7.2 Hacia Adelante	131
18.8 Resumen	131
18.9 Ejercicios	131
18.10 Lecturas Recomendadas	131

1 Notas de Aprendizaje y Comportamiento Adaptable

Prefacio

1.0.1 Prefacio

2 Prefacio

2.1 Principios y Modelos

Este libro es una edición revisada y extendida del libro de notas [Aprendizaje y Comportamiento Adaptable](#). Su origen se encuentra en las presentaciones que desarrollé a lo largo de los años para los tres cursos de Aprendizaje y Comportamiento Adaptable que imparto en la Facultad de Psicología de la UNAM. El libro ofrece una introducción rigurosa pero accesible a los principios y modelos del aprendizaje y comportamiento adaptable. A diferencia de los textos que suelen organizarse como un catálogo histórico de protocolos experimentales (condicionamiento clásico, instrumental, etc.), este libro se estructura alrededor de problemas de adaptación. Aquí no solo preguntamos qué hacen los organismos, sino qué problemas están resolviendo y qué algoritmos han evolucionado para resolverlos.

2.2 ¿Para Quién es Este Libro?

1. **Estudiantes de licenciatura** en psicología, neurociencia o ciencia cognitiva que buscan ir más allá de la descripción verbal y desean una introducción a los modelos matemáticos del comportamiento adaptable. Se asume conocimiento básico de matemáticas a nivel bachillerato. Si necesitas refrescar estos temas, consulta los tutoriales en Bouzas Lab.
2. **Estudiantes de posgrado** que necesitan un puente conceptual para conectar psicología experimental con la neurociencia computacional y el aprendizaje de máquinas (machine learning).
3. **Profesionales en transición** de física, matemáticas, ingeniería o ciencias de la computación hacia neurociencia o ciencia cognitiva. El libro aprovecha principios cuantitativos que ya conoces para introducirte al estudio formal del comportamiento.

2.3 Filosofía del Libro

2.3.1 Marco Conceptual Unificado

La introducción presenta el marco general que guía al libro. Aprenderás a distinguir entre nivel computacional (¿qué problema adaptativo se resuelve?), nivel algorítmico (¿qué procedimientos

generan el comportamiento?), y nivel de implementación (¿qué circuitos neuronales lo realizan?). Este marco evita confusiones comunes y te permite entender por qué diferentes tipos de modelos coexisten sin competir.

2.3.2 Énfasis en Principios Generales

En lugar de memorizar el resultado de protocolos particulares, aprenderás algoritmos generales necesarios para la solución de diferentes problemas de adaptación.

2.3.3 Implementación Computacional

Todos los modelos en este libro son implementables. No son solo ecuaciones abstractas: puedes programarlos, simularlos y experimentar con ellos.

2.3.4 Simuladores Interactivos

Este libro incluye simuladores embebidos y enlaces a notebooks interactivos (Google Colab) donde puedes manipular parámetros y observar resultados inmediatos, implementar algoritmos desde cero, replicar experimentos clásicos y explorar extensiones creativas. Accede a todos los simuladores y tutoriales de matemáticas en [Lab 25](#).

2.4 Cómo Usar Este Libro

2.4.1 Para Estudiantes

Estas notas están diseñadas para lectura activa, no pasiva. Lee la Introducción completa antes de continuar con los capítulos, ya que establece el marco conceptual necesario. Cuando un capítulo menciona un simulador, explóralo antes de seguir leyendo. La Introducción contiene estrategias detalladas de lectura activa que maximizarán tu aprendizaje.

2.4.2 Para Instructores

Este libro puede usarse como texto principal en un curso de dos semestres sobre aprendizaje y comportamiento adaptable, como complemento a un texto tradicional añadiendo la perspectiva formal y de optimización que esos textos omiten, o como recurso para temas específicos. Los simuladores permiten clases invertidas donde los estudiantes exploran antes de clase, y el tiempo presencial se dedica a discusión, resolución de problemas y profundización conceptual. La Introducción incluye sugerencias específicas para implementar este modelo pedagógico.

2.5 Recursos Adicionales

Todos los recursos (simuladores, código fuente, tutoriales) están disponibles en:

[Lab 25](#)

Para reportar errores o contribuir al proyecto, visita el repositorio GitHub.

2.6 Licencia y Uso

Este libro se distribuye bajo licencia Creative Commons BY-NC-SA 4.0. Esto significa que puedes compartir (copiar y redistribuir el material) y adaptar (remezclar, transformar y construir sobre el material) bajo las siguientes condiciones: debes dar crédito apropiado (Atribución), no puedes usar el material con fines comerciales (No Comercial), y si remezclas debes distribuir bajo la misma licencia (Compartir Igual).

2.7 Agradecimientos

La primera edición del libro mejoró significativamente gracias al excelente trabajo editorial de Rodrigo Álvarez. La estructura de esta página web fue adaptada del diseño original de Christian Badillo, quien siempre apoyó que este proyecto se concretara.

Mi agradecimiento a varias generaciones del Laboratorio 25 por desarrollar los simuladores interactivos que se encuentran en la página del Laboratorio.

Finalmente, extendiendo un agradecimiento especial a los cientos de estudiantes que en mis cursos han sufrido pacientemente mis intentos por enseñar los principios fundamentales del estudio del comportamiento adaptable.

La elaboración de esta página web fue financiada por los proyectos PAPIME PE309624 y PAPIME PE302221.

2.8 Contacto

Arturo Bouzas

Facultad de Psicología

Universidad Nacional Autónoma de México

arbouria@unam.mx

[Lab 25](#)

2.9 Aviso: Libro en Desarrollo

Este es un proyecto vivo. El contenido se actualiza regularmente basándose en feedback de estudiantes e instructores, nuevos desarrollos en el campo, y mejoras en simuladores y código. Verifica el repositorio GitHub para la versión más reciente.

Versión actual: v1.0 (Enero 2026)

¿Listo para comenzar? Pasa a la **Introducción al Curso**

3 Introducción

“Lo que no puedo crear, no lo entiendo.” — Richard Feynman

3.1 Un Problema de Diseño

Cada mañana, antes de comenzar su día, Wall-E hace lo mismo: conecta su panel solar y recarga su batería. Este ritual aparentemente simple revela algo profundo. Wall-E enfrenta el problema fundamental que comparten todos los agentes adaptativos, desde bacterias hasta algoritmos de inteligencia artificial: cómo distribuir el comportamiento en el tiempo y en el espacio para maximizar la obtención de recursos necesarios para sobrevivir, funcionar o cumplir sus objetivos.

Imagina que te encargan diseñar un robot explorador similar a Wall-E para un planeta desconocido. La tarea del robot es localizar recursos dispersos en un terreno accidentado, evitar peligros y encontrar fuentes de energía que le permitan recargar y gestionar su limitada reserva energética. Para ello, cuentas con sensores imperfectos (cámaras con ruido, detectores químicos de sensibilidad limitada), un procesador con capacidad finita, y restricciones severas de tiempo y energía. ¿Qué capacidades mínimas debe tener este robot para sobrevivir?

Necesitará, al menos:

Sensores que transformen energía física en señales procesables, distinguiendo información útil del ruido ambiental. Wall-E usa sus cámaras para distinguir objetos compactables de obstáculos peligrosos.

Navegación que le permita moverse hacia concentraciones de recursos detectadas a distancia. Cuando Wall-E detecta un objeto de interés, no se mueve aleatoriamente sino que se dirige directamente hacia él.

Aprendizaje predictivo que le permita anticipar dónde aparecerán recursos basándose en señales previas. Si cierta formación rocosa predice agua cercana, o si cierto tipo de escombros suele contener objetos valiosos, el robot debe aprender estas regularidades. Wall-E aprende que ciertos contenedores suelen tener objetos brillantes que le interesan.

Sistemas de elección que le permitan decidir racionalmente entre opciones cuando los recursos son múltiples y los comportamientos compiten entre sí. Wall-E debe decidir constantemente:

¿sigo compactando basura o busco un lugar seguro antes del anochecer? ¿Persigo ese objeto brillante interesante o regreso a cargar energía?

Este es exactamente el problema que enfrentan todos los organismos vivos. Una rata buscando alimento, una bacteria navegando gradientes químicos, un estudiante decidiendo cuánto tiempo dedicar a cada materia, un algoritmo de ajedrez evaluando jugadas—todos enfrentan variantes del mismo desafío fundamental: cómo distribuir su comportamiento en el tiempo y en el espacio para maximizar la obtención de recursos necesarios para sobrevivir, reproducirse o cumplir sus objetivos.

Este curso estudia las soluciones biológicas y computacionales a este problema. Pero antes de construir ese robot (o de entender cómo funcionan los organismos) debemos confrontar un problema pedagógico previo.

3.2 El Problema con la Enseñanza Tradicional

La estrategia pedagógica tradicional para enseñar aprendizaje y comportamiento adaptable, reflejada en la organización típica de los libros de texto, presenta casi exclusivamente las principales regularidades empíricas derivadas de más de 100 años de investigación, organizadas alrededor de protocolos experimentales específicos: condicionamiento clásico (Pavlov), condicionamiento operante (Skinner), programas de refuerzo, y quizás, si tuvo suerte, una clase sobre el modelo de Rescorla-Wagner y el principio de igualación de Herrnstein. Si bien este enfoque tiene valor histórico y permite apreciar la riqueza empírica del campo, puede dejar frecuentemente al estudiante con la impresión de que este es un área de conocimiento estática, fragmentada y predominantemente de interés histórico, llena de hallazgos aislados y con escasa coherencia conceptual.

Los estudiantes terminan ese curso sin una visión coherente de los principios que unifican estos fenómenos, ni una comprensión de por qué este campo sigue siendo relevante en el siglo XXI. Los hallazgos aparecen desconectados entre sí y, peor aún, desconectados de desarrollos contemporáneos en neurociencias, inteligencia artificial, economía conductual y teoría de la decisión.

Este curso adopta una estrategia diferente.

3.3 Un Problema Adaptativo Fundamental

En el centro de este curso está el problema biológico fundamental que mencionamos al inicio: cómo distribuir el comportamiento en el tiempo y en el espacio para maximizar la obtención de recursos necesarios para sobrevivir y reproducirse. Los agentes biológicos y no biológicos deben aprender qué aspectos de su entorno predicen recompensas y castigos, y deben usar ese conocimiento para elegir cursos de acción que maximicen su éxito.

3.4 Dos Componentes Esenciales

El estudio del comportamiento adaptable busca los principios que permiten resolver este problema. Podemos descomponerlo en dos componentes fundamentales:

1. El Problema del Conocimiento: ¿Cómo detectar y aprender las propiedades estadísticas de la distribución de recursos relevantes desde el punto de vista biológico y psicológico? Es decir, ¿cómo aprender a predecir aquello fundamental para la supervivencia y reproducción? Este es el problema de la asignación de crédito: cuando un recurso aparece (o un peligro se presenta), ¿a cuál de los múltiples eventos, señales o acciones previas debe asignarse la responsabilidad? ¿Qué predice qué?

2. El Problema de la Acción: ¿Cómo usar eficientemente ese conocimiento para distribuir óptimamente el comportamiento en el tiempo y en el espacio? Dado que sabemos algo sobre dónde y cuándo aparecen los recursos, ¿cómo decidimos qué hacer? Este es el problema de la elección bajo restricciones: el tiempo es finito, los comportamientos compiten entre sí, y las decisiones tienen costos de oportunidad.

Estas dos preguntas (¿qué predice qué? y ¿qué hago ahora?) organizan todo el curso.

3.5 Dos Orígenes de Soluciones

Las soluciones a estos problemas adaptativos tienen dos orígenes temporales diferentes:

1. Soluciones Filogenéticas (Selección Natural): En entornos relativamente constantes a lo largo de generaciones, la selección natural puede codificar directamente en el genoma las respuestas apropiadas. El resultado es lo que llamamos comportamiento adaptado: reflejos, instintos, sesgos perceptuales y atencionales que no requieren aprendizaje individual. Un ejemplo es la impronta en aves: los patitos siguen al primer objeto en movimiento que ven después de nacer, típicamente su madre.

2. Soluciones Ontogenéticas (Aprendizaje): En entornos variables, volátiles e inciertos (la norma para la mayoría de los organismos), la selección natural no puede anticipar todas las contingencias. En estos casos, evoluciona algo diferente: mecanismos que permiten comportamiento adaptable, la capacidad de ajustar el comportamiento a la estructura estadística de los sucesos biológicamente importantes, dentro de la vida del organismo. A esto le llamamos aprendizaje.

3.6 Mecanismos Reutilizables: Las “Tuercas y Tornillos”

A lo largo del curso identificaremos un conjunto pequeño de mecanismos generales (verdaderas “tuercas y tornillos” en el cajón de herramientas de la adaptación) que aparecen una y otra vez en diferentes contextos. A estos mecanismos los llamaremos algoritmos:

Algoritmos de comparación (sucesiva vs. simultánea): Detectar diferencias entre estados del mundo.

Algoritmos de reducción de error: Ajustar predicciones cuando difieren de resultados observados.

Algoritmos para la exploración vs. explotación: El dilema entre muestrear nuevas opciones y aprovechar lo conocido.

Algoritmos de sistemas de retroalimentación: Sistemas cerrados donde la acción modifica las condiciones que la provocan.

Algoritmos para la optimización bajo restricciones: Encontrar la mejor distribución posible de comportamiento dadas las limitaciones del entorno.

Estos mecanismos y algoritmos son implementados tanto en agentes no biológicos (robots), como en agentes biológicos (sean unicelulares o humanos), y pueden estudiarse tanto a nivel conductual como neuronal.

3.7 El Enfoque de Este Libro

3.7.1 Una Perspectiva Ingenieril

Este curso adopta lo que podríamos llamar una perspectiva ingenieril: tratamos el comportamiento como una solución a problemas adaptativos específicos. Para cada fenómeno, preguntaremos no solo “¿qué hacen los organismos?” sino también:

¿Qué problema adaptativo están resolviendo? (¿Por qué esto es importante para sobrevivir y reproducirse?)

¿Qué debería hacer un agente ideal? (¿Cuál es la solución óptima dado el problema y las restricciones?)

¿Cómo lo logran? (¿Qué algoritmos o mecanismos implementan esa solución o se aproximan a ella?)

3.8 Mapa del Curso

El libro está organizado en bloques temáticos que siguen la lógica del problema adaptativo que planteamos al inicio. Cada bloque añade una capacidad funcional a nuestro “agente adaptativo”, construyendo progresivamente desde mecanismos simples hasta sistemas complejos de toma de decisiones:

3.8.1 Bloque 0: Fundamentos Conceptuales (Capítulos 0-3)

Establecemos el marco teórico general: niveles de explicación, el problema de la adaptabilidad, y la teoría de la selección natural como primera solución. Aquí definimos qué significa “adaptarse” y por qué necesitamos modelos mecanicistas en lugar de solo descripciones empíricas.

3.8.2 Bloque I: Mecanismos Sin Integración de Historia (Capítulos 4-5)

Estudiamos dos mecanismos fundamentales que permiten adaptación en tiempo real sin requerir integración de experiencias pasadas: ascenso de colina (comparación sucesiva) y sistemas de retroalimentación (comparación simultánea). Estos son las “tuercas y tornillos” más básicas. Nuestro agente aprende a navegar y a mantener condiciones internas estables, pero vive completamente en el “ahora”.

3.8.3 Bloque II: El Problema del Conocimiento - Asignación de Crédito (Capítulos 6-10)

Abordamos el problema central: cuando un reforzador aparece, ¿a qué se le asigna el crédito? Primero revisamos modelos clásicos de aprendizaje asociativo (Rescorla-Wagner) y sus extensiones contemporáneas, incluyendo modelos basados en teoría de la información y filtros bayesianos. Nuestro agente deja de ser puramente reactivo y aprende a predecir el futuro.

3.8.4 Bloque III: El Problema de la Acción - Elección y Optimización (Capítulos 11-15)

Dado que hemos aprendido qué predice qué, ¿cómo distribuimos nuestro comportamiento? Estudiamos la ley del efecto, programas de refuerzo, la ley de igualación, y culminamos con modelos de optimización en equilibrio que integran economía conductual. Nuestro agente ahora conecta su conocimiento con la acción y aprende a elegir racionalmente.

3.8.5 Bloque IV: Aprendizaje Secuencial

Extendemos el análisis a secuencias de acciones donde el reforzador aparece al final (problema de asignación de crédito temporal). Introducimos algoritmos de aprendizaje por refuerzo: diferencias temporales, Q-learning, Actor-Crítico. Nuestro agente aprende a planificar secuencias de acciones hacia metas distantes.

3.8.6 Bloque V: Incertidumbre y Estados Ocultos

Finalmente, relajamos el supuesto de que el agente siempre sabe en qué estado del mundo se encuentra. Estudiamos entornos volátiles y modelos bayesianos avanzados. Nuestro agente aprende a razonar bajo incertidumbre profunda sobre el estado del mundo.

3.9 Cómo Usar Estas Notas

3.9.1 Para el Estudiante: Estrategias de Lectura Activa

Estas notas están diseñadas para construcción progresiva de comprensión. No son para lectura lineal pasiva. Aquí las estrategias que maximizarán tu aprendizaje:

Antes de cada capítulo: Lee el título y el primer párrafo. Formula una pregunta concreta que esperas que el capítulo responda. Por ejemplo, antes del capítulo sobre Rescorla-Wagner, pregúntate: “¿Cómo aprende un organismo qué señales predicen recompensas y cuáles son irrelevantes?” Esta pregunta explícita activará tu atención selectiva durante la lectura.

Durante la lectura: Lee con lápiz y papel a la mano. Cuando aparece una ecuación, desarróllala. Verifica las derivaciones. Sustituye números concretos y calcula resultados. Por ejemplo, si el texto presenta la ecuación de Rescorla-Wagner, calcula manualmente los primeros cinco ensayos de un protocolo de condicionamiento antes de ver el resultado en el simulador. Esta aparente “pérdida de tiempo” es en realidad la forma más eficiente de aprendizaje profundo. La mayoría de las confusiones matemáticas se disuelven cuando calculas casos específicos con números reales.

Usa los simuladores inmediatamente y sin restricciones. Cuando un capítulo menciona un simulador, ve a explorarlo antes de seguir leyendo. No esperes a “terminar de leer” para experimentar. La secuencia óptima es: lee la presentación del problema adaptativo, explora el simulador libremente durante 10-15 minutos, regresa al texto para la formalización matemática, vuelve al simulador para validar tu comprensión con casos extremos.

En el simulador, prueba valores extremos intencionalmente. Si hay un parámetro α (tasa de aprendizaje), no solo uses $\alpha=0.3$. Prueba $\alpha=0.01$ (aprendizaje extremadamente lento), $\alpha=0.99$ (aprendizaje casi instantáneo), $\alpha=1.0$ (caso límite). Rompe el modelo intencionalmente para

entender sus límites. ¿Qué pasa si todos los parámetros son cero? ¿Y si todos son máximos? Solo después de romperlo y ver qué falla, regresa al texto para consolidar por qué esas condiciones son problemáticas.

Sé paciente con las matemáticas. Algunas ecuaciones parecerán opacas al inicio. Esta incomodidad es normal y esperada. Regresa a ellas después de explorar el simulador. La intuición precede a la formalización. Si una ecuación no tiene sentido la primera vez, marca la página y continúa. Frecuentemente, un ejemplo posterior o un simulador específico iluminará retrospectivamente lo que parecía oscuro. Si después de ver el simulador y regresar al texto una ecuación sigue siendo opaca, ese es el momento de pedir ayuda, no antes.

Conecta con tus experiencias. Cada mecanismo que estudiamos opera también en tu comportamiento cotidiano. Esta no es una sugerencia decorativa sino una estrategia pedagógica fundamental. Cuando leas sobre descuento temporal, dedica cinco minutos a analizar tu última procrastinación: ¿qué valor inmediato preferiste sobre qué beneficio futuro? Cuando estudies ascenso de colina, observa durante tu próxima ducha cómo buscas el punto óptimo al ajustar la temperatura del agua: ¿haces cambios grandes o pequeños? ¿Cómo decides cuándo has encontrado el óptimo? Estas conexiones personales anclan la teoría abstracta en la experiencia vivida, transformándola de “contenido para memorizar” a “herramienta para comprender tu propio comportamiento”.

Organiza revisiones activas periódicas. Después de completar tres capítulos, antes de continuar, dedica una sesión a responder: ¿Qué problema adaptativo resuelve cada mecanismo? ¿Qué tienen en común los tres algoritmos? ¿En qué se diferencian? Si tuvieras que diseñar un robot con esas capacidades, ¿en qué orden las implementarías y por qué? Esta metacognición consolida el aprendizaje más efectivamente que releer pasivamente.

3.9.2 Para el Instructor

Estas notas permiten múltiples configuraciones pedagógicas. La más efectiva en nuestra experiencia es el modelo de clase invertida. Asigna la lectura de un capítulo más la exploración libre del simulador correspondiente como tarea previa a clase. Usa el tiempo presencial para tres actividades específicas:

Primera parte (20 minutos): Resolución de dudas sobre la formalización matemática. No expliques las ecuaciones desde cero; más bien, identifica las confusiones específicas que surgieron durante la lectura. Frecuentemente, las dudas reflejan intuiciones correctas formuladas imprecisamente. Tu trabajo es ayudar a los estudiantes a articular lo que ya entendieron implícitamente a través del simulador.

Segunda parte (30 minutos): Discusión de las implicaciones teóricas de lo observado en el simulador. Plantea preguntas como: “Cuando aumentaron α a 0.9, ¿qué pasó con la estabilidad del aprendizaje? ¿Por qué? ¿En qué situaciones ecológicas sería adaptativo tener

alto vs. bajo?” Estas preguntas fuerzan conexión entre el fenómeno observable y los principios subyacentes.

Tercera parte (20 minutos): Conexión del mecanismo con fenómenos reales en neurociencias o aplicaciones. Por ejemplo, después del capítulo sobre aprendizaje por diferencias temporales, discute cómo las neuronas dopaminérgicas implementan exactamente ese algoritmo. O después del capítulo sobre programas de refuerzo, analiza cómo los juegos de azar explotan esos principios.

Los simuladores y notebooks de Google Colab permiten extender el análisis más allá del libro. Asigna proyectos donde los estudiantes modifiquen el código para responder preguntas originales. Por ejemplo: “El modelo de Rescorla-Wagner asume que α es constante. Modifica el código para que α disminuya con la experiencia. ¿Cómo cambia el comportamiento? ¿Esto es más o menos adaptativo?”

Cada bloque temático es relativamente autocontenido, aunque se beneficia de la lectura secuencial. Si usas este libro como complemento a un texto tradicional organizado por protocolos, puedes asignar capítulos específicos como lecturas paralelas que proporcionan la formalización matemática que el texto principal omite.

3.10 Un Argumento Final

Muchos colegas me han dicho que es imposible enseñar estos temas (aprendizaje por refuerzo, modelos bayesianos, teoría de la información) a nivel introductorio. Que los estudiantes de licenciatura no tienen las herramientas matemáticas. Que es mejor mantener el enfoque tradicional, descriptivo, organizado por protocolos, que tiene el mérito probado de décadas de uso efectivo.

Entiendo esta perspectiva y reconozco el valor del enfoque clásico. La organización por protocolos experimentales tiene ventajas pedagógicas reales: permite apreciar la riqueza empírica del campo y conecta directamente con la literatura histórica. Sin embargo, creo que podemos y debemos complementar ese enfoque con algo adicional.

Los estudiantes de hoy crecieron con algoritmos de recomendación, navegación GPS y juegos con IA. Tienen una intuición operativa sobre aprendizaje de máquinas que generaciones previas no tenían. Esta familiaridad informal representa una oportunidad pedagógica única: lo que necesitamos es tender puentes entre esa intuición y los principios formales que el campo ha descubierto.

Los simuladores interactivos, los ejemplos concretos y la conexión explícita con aplicaciones contemporáneas construyen esos puentes. Las matemáticas no necesitan ser una barrera; pueden ser una revelación. Cuando un estudiante manipula los parámetros del modelo de Rescorla-Wagner y observa cómo emerge el bloqueo, la ecuación deja de ser un símbolo opaco y se convierte en una descripción precisa de un proceso observable. Cuando experimenta con

diferentes programas de refuerzo en el simulador y luego ve cómo la ley de igualación predice cuantitativamente la distribución de respuestas, las matemáticas se revelan como el lenguaje natural para expresar regularidades empíricas.

Además, el comportamiento adaptable no es solo historia: es un campo activo con aplicaciones en robótica, neurociencias computacionales, economía conductual y políticas públicas. Los mismos principios que explicamos aquí operan en algoritmos que determinan qué videos te recomienda YouTube, en modelos de neurociencias que estudian adicción, en políticas de salud pública que buscan modificar comportamientos de riesgo. Complementar el conocimiento de los fenómenos clásicos con comprensión de los principios formales permite a los estudiantes participar en estos desarrollos contemporáneos.

Estas notas son un experimento pedagógico. No buscan reemplazar los textos tradicionales sino complementarlos, ofreciendo una perspectiva adicional. Son un recurso abierto, en evolución, diseñado para estudiantes interesados en conectar el estudio clásico del aprendizaje con desarrollos contemporáneos en ciencia cognitiva, neurociencia computacional e inteligencia artificial.

Si funcionan para ti (como estudiante o instructor) compártelas. Si encuentras errores, omisiones o secciones poco claras, comunícamelo. Este es un proyecto colaborativo en el mejor espíritu de la ciencia abierta.

4 Modelos y Explicación

Cuando los científicos son tomados desprevenidos y se les pregunta cuál es el propósito de su actividad, la mayoría dirá que es “explicar” un fenómeno. Pero cuando se les pregunta qué entienden por explicar, las respuestas divergen —a veces radicalmente. En psicología esto es especialmente visible: hay investigadores que consideran que describir con precisión una relación funcional entre variables ya constituye una explicación completa, y otros que solo aceptan como explicación la identificación del mecanismo neuronal que produce el comportamiento. Con frecuencia, ambos grupos hablan de los mismos datos experimentales.

Este capítulo propone que buena parte de esa divergencia no refleja desacuerdos sobre los hechos, sino preguntas diferentes que se responden con herramientas diferentes. Entender qué tipos de preguntas existen —y qué tipo de estructura necesita una respuesta para cada una— es uno de los recursos intelectuales más útiles que puedes llevar a la lectura de la literatura científica. Para desarrollarlo necesitamos entender primero qué son los modelos y después qué significa explicar.

4.1 La Visión Ortodoxa y Sus Límites

Los psicólogos del segundo tercio del siglo XX compartían con los filósofos de su época una imagen de la teoría científica como un conjunto de leyes generales, de las cuales se podían derivar —por deducción— fenómenos individuales o patrones entre ellos. Las leyes relacionaban términos teóricos no directamente observables (como “pulsión” o “hábito”) con variables medibles, mediante reglas de correspondencia que anclaban lo abstracto a lo empírico. El objetivo declarado era construir sistemas hipotético-deductivos tan completos como los que la física había desarrollado para el movimiento de los planetas o para los gases.

En este esquema, *explicar* un fenómeno significaba derivarlo lógicamente de las leyes. Si observamos que un animal corre más rápido en cierta condición, la explicación consiste en mostrar que esa velocidad se sigue de los valores de las variables teóricas postuladas por la teoría. Esta visión de la explicación —derivación lógica de un fenómeno a partir de leyes generales— es lo que Carl Hempel llamó el modelo nomológico-deductivo (ND).

El modelo ND tenía una virtud: era explícito y formalizable. Pero enfrentó un problema que resultó fatal.

4.1.1 El Problema de la Asimetría

Supongamos que llegamos tarde al trabajo una mañana porque el tráfico estaba congestionado. La explicación parece perfectamente razonable: el tráfico causó el retraso. Ahora nota que con la misma estructura lógica podríamos “derivar” el estado del tráfico a partir del retraso: si sabemos cuánto tarde normalmente y cuánto tardé esta mañana, puedo calcular el estado probable del tráfico. Sin embargo, intuitivamente algo está mal. El retraso no explica el tráfico; la relación va en una sola dirección.

Este problema, conocido como el problema de la asimetría, fue identificado por el propio Hempel. La explicación tiene una *dirección* que la relación lógica por sí sola no captura. Esa dirección tiene que ver con la causalidad: el tráfico causó el retraso, y no al revés. El modelo ND no distingue las dos direcciones porque es indiferente a la causalidad: desde su perspectiva, la deducción funciona en ambos sentidos.

Esta falla obligó a los filósofos a reconocer que la causalidad debe desempeñar un papel central en la explicación. Pero incorporarla adecuadamente requirió, primero, repensar qué es una teoría científica, lo que condujo al surgimiento de la noción de modelo como unidad básica de la práctica científica.

4.2 De Teorías a Modelos

En la práctica real, los científicos de la segunda mitad del siglo XX dejaron paulatinamente de buscar leyes universales y comenzaron a construir modelos: el modelo de la doble hélice del ADN, los modelos de dinámica poblacional, los modelos epidemiológicos de una infección, los modelos de oferta y demanda en economía. En los capítulos que siguen encontraremos modelos del aprendizaje asociativo, de la asignación del comportamiento a distintas alternativas, y del aprendizaje por refuerzo. Todos comparten una característica: son representaciones simplificadas de alguna parte del mundo que permiten entender, predecir o intervenir sobre ella.

¿Qué es exactamente un modelo? Una manera útil de pensarlo: un modelo es una estructura —matemática, computacional, o diagramática— que representa un fenómeno mediante una relación de semejanza estructural con él. Un mapa del metro es un modelo: no reproduce cada detalle de los vagones ni la arquitectura de las estaciones, pero preserva las relaciones relevantes —qué líneas conectan qué estaciones— de forma que permite al viajero navegar el sistema. Un modelo de clima no es el clima; es una estructura que captura las interacciones dinámicas entre variables atmosféricas de forma que permite hacer predicciones útiles.

Podemos tener distintos modelos del mismo fenómeno para distintos propósitos. Un mapa que muestra solo las líneas y los puntos de transferencia es útil para llegar de un punto a otro; un mapa con información turística superpuesta es útil para quien visita por primera vez una ciudad. Ninguno es “el correcto” en abstracto; cada uno es correcto para su propósito. Lo

mismo ocurre con los modelos en psicología: no hay un único modelo del aprendizaje que sea definitivo, sino modelos que responden preguntas distintas con distintos niveles de resolución.

4.2.1 Los Modelos como Vehículos de Inferencia

Hay una discusión importante sobre cuál es exactamente la relación entre un modelo y el fenómeno que representa. Una respuesta influyente (Suppes, van Fraassen) es que esa relación es de *isomorfismo estructural*: el modelo representa exitosamente un fenómeno cuando existe una correspondencia que preserva las relaciones relevantes entre la estructura del modelo y la estructura del fenómeno empírico. Consideremos la medición de la estatura: queremos asignar números a personas de forma que se preserve la relación “más alto que”. Si A es más alta que B, el número asignado a A debe ser mayor. La medición es exitosa cuando existe ese isomorfismo entre la estructura empírica Personas, más-alta-que y la estructura numérica Números, $>$.

Esta cuenta del isomorfismo tiene méritos: hace preciso qué se requiere del modelo y guía la investigación hacia la pregunta de si la estructura empírica satisface los axiomas del modelo. En capítulos posteriores veremos que medir preferencias es problemático precisamente porque las preferencias humanas a veces violan la transitividad —una condición que el isomorfismo con los números requeriría.

Pero para este libro, una concepción más amplia resulta más útil: la visión *inferencialista* de Mauricio Suárez. Para Suárez, lo que hace que una estructura sea un modelo de un fenómeno no es que sean isomórficas, sino que el modelo *permite al usuario hacer inferencias sobre el fenómeno* en el contexto adecuado. No se requiere semejanza estructural precisa; se requiere que el modelo funcione como vehículo inferencial. Un modelo de optimización del forrajeo no es isomórfico al comportamiento de un animal buscando alimento, pero permite inferir qué patrones de búsqueda deberíamos observar si el animal está bien adaptado. Un algoritmo de aprendizaje por refuerzo no replica la fisiología neuronal, pero permite inferir cómo cambiará la conducta ante diferentes distribuciones de recompensa.

Esta concepción es más cercana a cómo los científicos usan sus modelos en la práctica, y más apropiada para un libro que incorpora modelos de optimización, algoritmos computacionales y simuladores interactivos. La pregunta que debemos hacerle a un modelo no es “¿es isomórfico al fenómeno?” sino “¿qué inferencias permite hacer, y son esas inferencias empíricamente productivas?”

4.3 La Pluralidad de Formas de Explicar

Con la noción de modelo en mano, podemos volver al problema de la explicación. Veremos que no hay un único tipo de explicación científica válida; hay varios tipos, cada uno apropiado para un tipo de pregunta.

4.3.1 Explicación Causal

Una forma de explicar consiste en identificar los *hacedores de diferencia*: los factores que, al variar, producen variación en el fenómeno de interés. Decir que A causa B es afirmar que intervenciones sobre A producirán cambios sistemáticos en B, y que en circunstancias contrafactuales donde A no ocurriera, B tampoco ocurriría.

La noción moderna de causalidad se articula típicamente en tres formas complementarias. Primero, en términos de contrafactuales: A causa B si, en el mundo más cercano al actual donde A no ocurre, B tampoco ocurriría. Segundo, en términos de intervenciones: A causa B si manipular A (manteniendo todo lo demás constante) produce cambios sistemáticos en B. Tercero, en términos de *hacedores de diferencia*: A es un *hacedor de diferencia* para B si la variación en A, dentro del rango relevante, produce variación en B.

Estas tres formulaciones son relacionadas pero enfatizan aspectos distintos. Los contrafactuales enfatizan la estructura modal —qué hubiera ocurrido en circunstancias distintas. Las intervenciones enfatizan la manipulabilidad experimental. Los *hacedores de diferencia* enfatizan la identificación de los factores que realmente importan para el fenómeno, abstrayendo de condiciones de fondo necesarias pero no explicativas.

4.3.2 Explicación Mecanicista

Una segunda forma de explicar consiste en especificar un mecanismo: identificar los componentes del sistema, su organización, y las interacciones entre componentes que producen el fenómeno. Un mecanismo no es solo una caja negra que transforma inputs en outputs; es una descripción de cómo esa transformación ocurre en términos de partes y operaciones.

La explicación mecanicista es particularmente satisfactoria porque no solo identifica qué causa qué, sino *cómo* lo causa. Permite predecir qué ocurriría si un componente fallara, o cómo modificar el sistema para producir resultados distintos.

4.3.3 Explicación Unificadora

Una tercera forma de explicar consiste en mostrar que fenómenos aparentemente diversos son instancias de un patrón común. La explicación por unificación reduce el número de patrones independientes que debemos aceptar. Newton unificó la caída de los cuerpos terrestres y el movimiento de los planetas bajo la ley de gravitación universal. Darwin unificó la diversidad de adaptaciones bajo el principio de selección natural. En los capítulos siguientes veremos cómo el principio de reducción del error de predicción unifica fenómenos de condicionamiento clásico, instrumental, y aprendizaje por refuerzo.

4.4 Niveles de Análisis

Los fenómenos complejos pueden analizarse en múltiples niveles, y diferentes niveles responden diferentes tipos de preguntas. Dos marcos han sido especialmente influyentes en las ciencias del comportamiento.

4.4.1 El Marco de Tinbergen

Niko Tinbergen propuso que cualquier comportamiento puede estudiarse mediante cuatro preguntas complementarias: causación próxima (¿qué mecanismos inmediatos lo producen?), ontogenia (¿cómo se desarrolla en el individuo?), función (¿qué problema adaptativo resuelve?), y filogenia (¿cómo evolucionó en la especie?). Estas preguntas no compiten; son complementarias. Una comprensión completa de un comportamiento requiere respuestas en los cuatro niveles.

4.4.2 El Marco de Killeen

Peter Killeen propone un vocabulario derivado de la distinción aristotélica entre tipos de causas, adaptado para las ciencias del comportamiento: *subyace* (¿qué sustrato físico lo soporta?), *induce* (¿qué variables lo producen?), *logra* (¿qué función adaptativa cumple?), y *representa* (¿qué estructura formal lo describe?). Este vocabulario es el que encontrarás en el programa oficial del curso y en parte de la literatura. Su equivalencia aproximada con los marcos de Tinbergen y Marr es la siguiente: *subyace* corresponde al nivel de implementación, *induce* al nivel algorítmico y mecanismo próximo, *logra* a la función adaptativa, y *representa* al nivel computacional y a los modelos formales matemáticos.

4.4.3 El Marco de Marr

David Marr propuso un marco para entender los sistemas cognitivos que refleja exactamente esta división del trabajo. Argumentó que para entender completamente un sistema que procesa información (sea un cerebro, una bacteria o un algoritmo), debemos analizarlo en tres niveles distintos y complementarios:

El nivel *computacional* pregunta qué computa el sistema y por qué —define el problema en términos abstractos sin comprometerse con cómo se resuelve. El nivel *algorítmico* pregunta cómo lo computa —especifica los procedimientos y representaciones mediante los cuales el sistema realiza esa computación. El nivel de *implementación* pregunta en qué sustrato físico ocurre esa computación.

Marr enfatizó que cada nivel es parcialmente autónomo—puede ser estudiado independientemente de los otros niveles. Pero también están interrelacionados—restricciones en un nivel afectan los otros niveles. Podemos entender el problema computacional sin saber el algoritmo

o la implementación. Del mismo modo, podemos estudiar algoritmos abstractamente sin saber su implementación neural específica. Sin embargo, el análisis computacional restringe los algoritmos apropiados. No cualquier algoritmo resolverá el problema; debe ser uno que compute la función correcta dados las entradas y restricciones especificadas a nivel computacional. Adicionalmente, los algoritmos deben ser implementables con el hardware disponible.

Reconociendo la interdependencia de niveles, Marr argumentó que el análisis a nivel computacional debería guiar el análisis a otros niveles. Sin entender qué problema está resolviendo un sistema, es difícil entender el papel de los algoritmos que usa. El análisis computacional proporciona el “por qué” que hace inteligible el “cómo”.

En los capítulos siguientes, en cada uno de ellos empezaremos dándole respuesta a la pregunta “por qué” antes de presentar el “cómo”.

4.4.4 Progresión Científica: De Descripciones a Explicaciones

El marco de Marr identifica niveles de análisis que pueden estudiarse en cualquier orden. Pero en la práctica científica, la investigación típicamente progresa en una secuencia específica:

Qué: Primero se identifican regularidades empíricas—patrones cuantitativos en los datos que pueden describirse matemáticamente. Estos son *modelos fenomenológicos*: resumen datos pero no explican cómo se producen. (En capítulos posteriores verás ejemplos como la ley de igualación y el gradiente de demora.)

Cómo: Después se proponen mecanismos que generan esos patrones. Estos son *modelos mecanicistas o algorítmicos*: especifican procesos paso a paso que producen las regularidades observadas. (Por ejemplo, reglas de actualización que generan los patrones empíricos identificados en el paso anterior.)

Por qué: Finalmente se identifican principios normativos que justifican por qué esos mecanismos son apropiados para el problema adaptativo. Estos son *modelos normativos*: muestran qué sería óptimo hacer dado el problema y las restricciones. (Por ejemplo, demostrando que el mecanismo aproxima una solución óptima.)

Esta progresión Qué → Cómo → Por Qué refleja tanto el desarrollo histórico de las ciencias del comportamiento como una secuencia pedagógica natural. Varios capítulos de este libro seguirán esta estructura. Cuando la encuentres, regresa a esta distinción para identificar qué tipo de modelo se está presentando y qué función cumple en la explicación.

Nota que esta secuencia no implica que un tipo de modelo sea “mejor” que otro. Los tres son necesarios y complementarios: el modelo fenomenológico identifica qué necesitas explicar, el modelo mecanicista especifica cómo se produce, y el modelo normativo justifica por qué ese mecanismo y no otro.

4.5 Van Fraassen: La Explicación como Respuesta a Preguntas

Bas van Fraassen integra los puntos anteriores con una observación aparentemente simple pero de gran alcance: la explicación no es una relación lógica abstracta sino una actividad pragmática. Explicar es responder una pregunta de “¿por qué?” en un contexto dado. Y esas preguntas tienen una estructura que habitualmente se ignora.

Cuando preguntamos “¿por qué P?”, no preguntamos “¿por qué P y no cualquier otra cosa concebible?”. Preguntamos “¿por qué P en lugar de Q?”, donde Q es un *contraste implícito* que depende del contexto. Considera: “¿por qué el niño tomó una manzana?”. Si el contraste es {tomó / no tomó}, la respuesta es que tenía hambre. Si el contraste es {manzana / naranja / plátano}, la respuesta es que prefiere las manzanas. Si el contraste es {tomó / compró / pidió}, la respuesta es que no tenía dinero. La misma información puede ser explicativa en un contexto e irrelevante en otro.

Esta perspectiva disuelve muchos debates aparentes en la literatura. Cuando dos investigadores parecen en desacuerdo sobre qué “explica” un fenómeno, con frecuencia están haciendo contrastes implícitos distintos. El que busca mecanismos neurales contrasta el comportamiento observado con lo que ocurriría si ese mecanismo no existiera. El que busca la función evolutiva contrasta el comportamiento con lo que haría un organismo sin esa capacidad adaptativa. No están en desacuerdo sobre el mundo; están haciendo preguntas distintas. La pregunta productiva no es “¿quién tiene razón?”, sino “¿qué contraste está haciendo cada uno, y es ese contraste legítimo dado el propósito de la investigación?”.

4.6 Una Nota sobre los Modelos de Datos

El proceso científico no termina con la observación de un fenómeno ni comienza con la construcción de un modelo teórico. Entre ambos está el trabajo de organizar los datos empíricos de forma que sean interpretables. Patrick Suppes llamó a este paso la construcción de un *modelo de datos*: la transformación de registros crudos en una representación canónica del fenómeno.

Los modelos de datos no son neutros. Cuando Skinner decidió representar el comportamiento de sus ratas como *tasa de respuesta* —número de presiones de palanca por unidad de tiempo— estaba tomando una decisión teórica disfrazada de decisión técnica. Esa representación hacía visibles ciertos patrones (pausas después del refuerzo, aceleración de la tasa bajo programas de razón) y oscurecía otros (microestructura temporal, variación en la topografía de la respuesta). Toda una tradición teórica se organizó alrededor de explicar variaciones en la tasa de respuesta, en parte porque la tasa era el modelo de datos dominante.

En los capítulos que siguen, cada vez que se introduzca una nueva medida —tiempo entre respuestas, magnitud del error de predicción, frecuencia relativa de elección— vale la pena preguntarse qué aspectos del fenómeno hace visibles esa medida y cuáles oculta.

4.7 Síntesis

Tres ideas organizan este capítulo y reaparecerán a lo largo del libro.

Los modelos no son copias de la realidad sino vehículos de inferencia: su valor se mide por la calidad de las inferencias que permiten hacer, no por su fidelidad absoluta al fenómeno. Dos modelos del mismo comportamiento pueden coexistir si sirven propósitos distintos.

La explicación no es un único tipo de actividad. Hay explicaciones causales (que identifican los factores que hacen diferencia), explicaciones unificadoras (que muestran que fenómenos heterogéneos comparten estructura), y explicaciones mecanicistas (que especifican los componentes cuyas interacciones producen el fenómeno). Estas formas se complementan.

Los fenómenos complejos pueden analizarse a múltiples niveles. Tinbergen, Marr y Killeen articulan ese espacio de niveles con vocabularios distintos pero convergentes. Cuando en los capítulos que siguen encuentres modelos que parecen incompatibles, la primera pregunta que debes hacerte es si están operando al mismo nivel o respondiendo la misma pregunta. Con frecuencia, la respuesta es que no.

4.8 Ejercicios de Comprensión

Ejercicio 1 (básico). Considera el siguiente enunciado: “Los estudiantes que duermen más horas antes de un examen obtienen mejores calificaciones.” Escribe (a) una explicación contrafactual, (b) una posible explicación intervencionista, y (c) una formulación del hacedor de diferencia más abstracto. ¿Cuál de las tres te parece más informativa para el propósito de diseñar una intervención educativa? ¿Cambia tu respuesta si el propósito es comprender el funcionamiento de la memoria?

Ejercicio 2 (intermedio). Un experimento muestra que las ratas presionan más rápido una palanca cuando cada décima presión entrega comida que cuando cada presión la entrega. Usando el marco de Tinbergen, formula las cuatro preguntas que podrías hacer sobre este fenómeno e indica, para cada una, qué tipo de estudio o datos necesitarías para responderla.

Ejercicio 3 (intermedio). Alguien argumenta: “Los modelos matemáticos del aprendizaje no son realmente explicaciones porque omiten los mecanismos neuronales reales.” Usando los marcos de Marr y Killeen, evalúa este argumento. ¿En qué sentido tiene razón? ¿Qué confunde?

Ejercicio 4 (avanzado). En los capítulos siguientes, el comportamiento de orientación de las bacterias se describirá a nivel conductual (kinesis), a nivel algorítmico (ascenso de colina) y brevemente a nivel mecanicista molecular. Elige dos de esos niveles y describe: (a) qué pregunta responde cada uno según el marco de Tinbergen y el de Marr; (b) si son “explicaciones” en los sentidos discutidos en este capítulo, y de qué tipo; (c) qué fenómeno adicional podría investigarse si combináramos información de ambos niveles.

5 Teoría de la Selección Natural

Para cualquier observador del mundo natural, dos propiedades resultan sorprendentes y merecen explicación. La primera es la enorme variabilidad en la morfología, fisiología y comportamiento de los organismos que habitan este planeta. La segunda es que esa variabilidad parece estar finamente ajustada a las características del entorno donde viven esos organismos. La teoría de la selección natural, propuesta por Charles Darwin en 1859, ofrece una explicación unificada de ambas observaciones a partir de tres principios sorprendentemente simples.

Este capítulo tiene dos propósitos. El primero es presentar esos principios, que constituyen uno de los logros más importantes de la ciencia. El segundo, menos obvio pero igualmente importante para este curso, es mostrar que la estructura conceptual de la selección natural es la misma que subyace a los procesos de aprendizaje que estudiaremos en los bloques siguientes. Para hacer esa conexión con precisión, introduciremos hacia el final del capítulo un modelo matemático del cambio evolutivo —la ecuación de Price en su versión simplificada— que revelará por qué la similitud entre evolución y aprendizaje no es solo una metáfora cómoda sino una identidad estructural.

5.1 La Variabilidad y el Ajuste al Entorno

Un recorrido por cualquier parque, zoológico, o incluso una búsqueda rápida en YouTube de documentales de historia natural, nos expone a una variedad de formas de vida difícil de procesar. Organismos unicelulares, hongos, medusas, insectos, aves, mamíferos —y dentro de cada grupo, una diversidad adicional que parece inagotable. Solo entre mamíferos existen aproximadamente 5,500 especies; entre insectos, más de 91,000; entre escarabajos, alrededor de 250,000, lo que llevó al biólogo J.B.S. Haldane a su famosa observación sobre la “predilección del Creador por los coleópteros”. La variabilidad no es solo morfológica: varía la fisiología, el comportamiento, los mecanismos de regulación interna, los sistemas de reproducción.

Lo que Darwin notó en su viaje en el Beagle, y que constituye el punto de partida de su teoría, es que esta variabilidad no es aleatoria con respecto al entorno: está correlacionada con él. En los archipiélagos de las Galápagos, pájaros genéticamente relacionados presentaban picos radicalmente diferentes según el tipo de alimento disponible en la isla que habitaban: picos largos y delgados para acceder al néctar de flores, picos cortos y fuertes para romper semillas duras. Esta coincidencia entre la forma del organismo y las demandas del entorno es lo que llamamos *adaptación*, y es el fenómeno que requiere explicación.

A mediados del siglo XIX también se sabía, gracias al análisis de fósiles y la datación de capas geológicas, que la diversidad biológica había cambiado a lo largo del tiempo: había especies que habían desaparecido y otras que habían surgido en épocas geológicas más recientes. Era evidente que el mundo biológico no había sido “creado” todo a la vez, y que podía hablarse de una *evolución* de los organismos. La pregunta era: ¿qué proceso explica tanto el cambio a lo largo del tiempo como el ajuste al entorno?

5.2 Los Tres Principios de la Selección Natural

Darwin propuso que la evolución puede explicarse a partir de tres principios que, cuando se cumplen simultáneamente, producen un cambio adaptativo en la composición de la población.

El primero es la **variabilidad heredable**. Los organismos producen descendencia que difiere ligeramente de sus progenitores. Esta variación surge por mutaciones (cambios en el material genético) y recombinación (la mezcla de material genético de dos progenitores en la reproducción sexual). No todos los individuos son idénticos: existe diversidad en morfología, fisiología y comportamiento. Lo crucial es que esta variación se transmite, al menos parcialmente, a la siguiente generación.

El segundo principio es la **selección diferencial**: los organismos interactúan con su entorno, y esa interacción determina cuántos descendientes logra producir cada uno. A este número lo llamamos *éxito reproductivo* o *fitness*. Aquellos organismos con características que resultan más exitosas en el entorno actual —que escapan mejor de depredadores, obtienen más alimento, atraen más parejas— tienden a reproducirse más. Esta ventaja debe ser *causal*, no una mera coincidencia: el rasgo en cuestión contribuye al mayor éxito, no simplemente lo acompaña.

El tercero es la **herencia**: las características que incrementaron el éxito reproductivo se transmiten a la siguiente generación. La proporción de organismos con esas características aumenta en la población con el paso del tiempo.

Cuando estos tres principios operan a la vez, ocurre selección natural: generación tras generación, los rasgos asociados con mayor éxito reproductivo se vuelven más frecuentes. La composición de la población cambia, favoreciendo las variantes que funcionan mejor en el entorno actual. Este proceso de cambio acumulativo y diferencial es la esencia de la evolución darwiniana.

Vale la pena detenerse en algo que sorprende a muchos estudiantes al encontrarse con estos principios por primera vez: ninguno de ellos requiere intención, planificación ni dirección consciente. La selección natural es un proceso automático. Las bacterias no “intentan” desarrollar resistencia a los antibióticos; simplemente, aquellas que por variación aleatoria ya tenían cierta resistencia sobreviven y se reproducen más, y su descendencia hereda esa característica. La dirección adaptativa emerge de la interacción entre variación aleatoria y el filtro del entorno, sin necesidad de un agente que la dirija.

5.3 Las Fuentes de la Variabilidad

La teoría darwiniana original reconocía la existencia de variación heredable, pero no conocía sus mecanismos —la genética mendeliana se integró décadas después, en lo que se conoce como la Síntesis Moderna. Hoy sabemos que la variabilidad surge principalmente de tres fuentes.

Las **mutaciones genéticas** son cambios en el material genético que pueden ocurrir por errores en la copia del ADN, exposición a radiación o agentes químicos, entre otras causas. Sus efectos son diversos: algunas mutaciones son letales, otras son neutras y no afectan la supervivencia, y en ocasiones confieren alguna ventaja bajo ciertas condiciones. Las mutaciones neutras pueden acumularse en la población simplemente por azar, en un proceso conocido como deriva genética.

La **reproducción sexual y recombinación** no crea alelos nuevos, pero genera nuevas combinaciones de los existentes. Cada descendiente recibe una mezcla única de genes de ambos progenitores, lo que produce variación en los fenotipos incluso entre hermanos. La reproducción sexual es una máquina extraordinariamente eficiente para generar diversidad combinatoria.

Finalmente, los **eventos geográficos y ecológicos** pueden separar poblaciones y forzarlas a evolucionar de manera independiente. El aislamiento geográfico —la formación de una barrera que divide una población— divide el acervo genético en dos. Con el tiempo, cada subpoblación acumula mutaciones distintas y puede diverger hasta dar origen a nuevas especies.

5.4 El Entorno como Filtro

Una forma de visualizar cómo opera la selección es imaginar al entorno como un sistema de filtros. Las condiciones ambientales —disponibilidad de recursos, presencia de depredadores, temperatura, competencia— determinan cuáles variantes de la población sobreviven y se reproducen. Las variantes que no logran superar esos filtros desaparecen; las que los superan persisten y transmiten sus características.

Es importante notar que este proceso no “selecciona” en el sentido de elegir activamente lo mejor. Más bien, *elimina* lo que no funciona en el entorno actual. Lo que sobrevive no es necesariamente lo óptimo en términos absolutos, sino lo suficientemente bueno para no ser eliminado. Esta distinción tiene consecuencias importantes: la evolución no garantiza soluciones perfectas, solo soluciones funcionales en un entorno particular.

La metáfora del filtro también ilustra por qué la adaptación es siempre relativa al contexto: un rasgo ventajoso en un entorno puede ser desventajoso en otro. Las adaptaciones de las aves de las Galápagos al tipo de alimento disponible en cada isla serían perjudiciales si las aves cambiaran de isla. El “ajuste” es siempre local, contingente, histórico.

5.5 La Selección Natural como Algoritmo de Búsqueda

Llegamos ahora al segundo propósito del capítulo: mostrar la estructura que comparte la selección natural con los algoritmos de aprendizaje y decisión que estudiaremos más adelante.

Imaginemos que nos contratan para buscar jugadores para un equipo de fútbol. Tenemos un conjunto de posibles acciones disponibles: quedarnos en casa viendo partidos por televisión, ir a juegos de ligas de menor categoría, visitar clubes infantiles en una ciudad, en varias ciudades, incluyendo pequeñas localidades. A lo largo del tiempo, probaríamos distintas estrategias y a cada una le iríamos asignando un valor que refleja su éxito para encontrar buenos jugadores. Gradualmente, iríamos refinando nuestra búsqueda, manteniendo las estrategias más exitosas y abandonando las que no funcionan. Y si las condiciones cambian —por ejemplo, los costos de transporte se disparan— la estrategia óptima cambiaría también.

Esta es precisamente la estructura de un algoritmo de búsqueda. Lo que necesitamos para representarla formalmente son cuatro elementos: un espacio de posibilidades (las distintas acciones disponibles), un mecanismo para generar variantes dentro de ese espacio, una función de evaluación que asigna un valor a cada variante según su éxito, y un mecanismo que preserve y propague las variantes más exitosas.

La selección natural tiene exactamente esta estructura. El espacio de posibilidades es el espacio fenotípico; el mecanismo de variación es la mutación y la recombinación; la función de evaluación es el fitness; y el mecanismo de preservación es la herencia. Esta estructura —variación, evaluación, selección— es compartida por todos los procesos en los que algo aprende de la experiencia, ya sea una población que evoluciona, un organismo que aprende, o un algoritmo que optimiza.

5.5.1 El Espacio Fenotípico y el Paisaje Adaptativo

Para formalizar esta idea necesitamos un concepto que aparecerá repetidamente a lo largo del curso: el de *espacio de posibilidades*.

Imagina que cada organismo puede describirse por sus características medibles: la longitud de sus alas, la eficiencia de su metabolismo, la agudeza de su visión, su velocidad de reacción. Cada característica es una dimensión. Si un organismo tiene valores específicos en todas estas dimensiones, podemos pensar en él como un punto en un espacio multidimensional. El **espacio fenotípico** es el conjunto de todas las configuraciones posibles de características que un organismo podría tener.

No todas las configuraciones en ese espacio son igualmente exitosas. Si asignamos a cada punto un valor que representa el éxito reproductivo esperado, obtenemos lo que llamamos un **paisaje adaptativo**: un espacio con “picos” (combinaciones de rasgos con alto fitness) y “valles” (combinaciones con bajo fitness).

La selección natural, vista desde esta perspectiva, es el proceso mediante el cual una población se desplaza por ese paisaje. La mutación y recombinación hacen que la descendencia explore regiones cercanas a la de sus padres; la selección hace que la población tienda a moverse hacia regiones de mayor fitness.

Cuando estudien los algoritmos de aprendizaje más adelante en el curso, encontrarán que también operan buscando en espacios de posibilidades guiados por una función que asigna valor a cada opción. La estructura es la misma; cambia el dominio.

5.5.2 Restricciones: Qué Regiones del Espacio Son Accesibles

Una pregunta natural al imaginar el espacio fenotípico es: ¿puede la evolución llegar a cualquier punto de ese espacio dado suficiente tiempo? La respuesta es no, y entender por qué es importante tanto para la evolución como para los algoritmos de aprendizaje.

Las **restricciones físicas** imponen límites duros: un insecto no puede crecer al tamaño de un elefante porque su exoesqueleto no podría soportar el peso. Las **restricciones genéticas y del desarrollo** hacen que no todas las combinaciones de rasgos sean biológicamente realizables: el desarrollo de un organismo sigue rutas específicas que limitan las variaciones posibles. Las **restricciones filogenéticas** son quizás las más importantes para nuestros propósitos: la evolución es un proceso histórico, y los organismos actuales son modificaciones de organismos ancestrales. La evolución no empieza de cero en cada generación; hereda tanto las soluciones exitosas como las limitaciones de sus ancestros.

Podemos visualizar estas restricciones como filtros anidados. El espacio teóricamente posible es enorme; las restricciones físicas eliminan todo lo que viola leyes de la naturaleza; las restricciones del desarrollo y genéticas reducen aún más el espacio a lo biológicamente realizable; las restricciones filogenéticas lo reducen al espacio accesible para este linaje específico dada su historia; finalmente, el entorno actual determina qué región del espacio accesible tiene alto fitness.

Esta estructura de restricciones anidadas es análoga a lo que en el capítulo sobre asignación de crédito llamaremos *sesgos inductivos*: predisposiciones que limitan el espacio de búsqueda y hacen manejable un problema que de otro modo sería intratable. Tanto en la evolución como en el aprendizaje, las restricciones no son obstáculos al proceso sino parte constitutiva de cómo funciona.

5.5.3 El Problema de los Óptimos Locales

Una limitación adicional de la selección natural como algoritmo de búsqueda proviene de la naturaleza misma del proceso de ascenso por el paisaje adaptativo. Imaginemos a alguien con los ojos vendados que intenta llegar al punto más alto de una cordillera. La regla que sigue es simple: en cada paso, explora las alturas cercanas y se desplaza hacia la más alta. Si la

cordillera tiene un único pico, esta regla lo llevará allí. Pero si hay varios picos separados por valles, la persona quedará atrapada en el primero que encuentre, aunque haya picos más altos en otras regiones.

La selección natural enfrenta exactamente este problema. Una población bien adaptada a su entorno actual puede quedar “atrapada” en un óptimo local: cualquier pequeño cambio la llevaría a un estado menos exitoso, aunque existan configuraciones mucho mejores que requieren pasar por estados intermedios desfavorables. Para escapar de un óptimo local se necesita suficiente variación —exploración— como para “saltar” el valle, pero aumentar la variación tiene costos: también puede sacar a la población de picos donde ya estaba.

Este dilema entre explorar nuevas regiones y explotar lo conocido aparece en todos los algoritmos de búsqueda y aprendizaje. Lo encontraremos en el contexto del forrajeo, la elección entre opciones, el aprendizaje secuencial. La evolución no lo resuelve de manera perfecta; tampoco lo hacen los organismos que aprenden.

Hay una segunda razón, independiente de los óptimos locales, por la que la selección natural no produce organismos “perfectos en todo”: los trade-offs. Muchos rasgos que incrementan el éxito en una dimensión lo reducen en otra. Ser grande puede ayudar a defenderse de depredadores, pero requiere más alimento. Dedicar energía a reproducirse temprano reduce la energía disponible para el mantenimiento del organismo. La cola elaborada del pavo real atrae parejas pero dificulta el vuelo y atrae depredadores. En cada uno de estos casos, no existe una solución que maximice simultáneamente todos los objetivos —el “óptimo” es siempre un balance entre presiones en tensión. Este principio, que aquí aparece en su versión evolutiva, reaparecerá en el siguiente capítulo cuando analicemos cómo los organismos distribuyen su comportamiento entre actividades que compiten por el mismo tiempo y energía.

5.5.4 Cuando el Paisaje Cambia

Hay una diferencia importante entre la selección natural y los algoritmos de optimización más simples: el paisaje adaptativo no es fijo. Cambia a lo largo del tiempo porque el entorno cambia, porque otras especies coevolucionan, porque las adaptaciones de una especie alteran el nicho de otras. Si una presa evoluciona mayor velocidad, cambia el paisaje adaptativo de su depredador. Si el depredador evoluciona mejor visión, cambia el paisaje de la presa. Es como intentar alcanzar la cima de una montaña mientras la montaña misma se está deformando.

Finalmente, cuando diferentes rasgos están en conflicto, no existe una “mejor solución única”. Ser grande puede ayudar a defenderse de depredadores, pero requiere más alimento. Dedicar tiempo a buscar pareja puede ser ventajoso para reproducirse, pero reduce el tiempo disponible para alimentarse. En estos casos, el óptimo depende del balance específico entre las presiones selectivas en ese entorno particular.

A pesar de estas limitaciones, la selección natural ha producido adaptaciones extraordinariamente complejas y efectivas, porque opera con retroalimentación iterativa del entorno a lo

largo de escalas de tiempo enormes. Cada generación, la población recibe información sobre qué rasgos funcionan —en forma de éxito reproductivo diferencial— y ajusta su composición en consecuencia. Pequeños ajustes acumulados durante millones de generaciones pueden producir cambios dramáticos.

5.6 Otros Factores Evolutivos

La selección natural es el único proceso conocido que produce adaptaciones, pero no actúa sola. La **deriva genética** es un proceso de cambio aleatorio en las frecuencias génicas que es especialmente relevante en poblaciones pequeñas. A diferencia de la selección, la deriva no responde al valor adaptativo de los rasgos: puede fijar variantes neutras o incluso ligeramente desventajosas simplemente por azar, y puede en algunas circunstancias permitir que una población “salte” valles adaptativos que la selección por sí sola no podría cruzar. La **migración o flujo génico** ocurre cuando individuos se desplazan entre poblaciones, introduciendo o removiendo variantes. La **selección sexual**, identificada por Darwin como un caso especial, opera cuando los rasgos evolucionan no por supervivencia directa sino por éxito en el apareamiento —las colas elaboradas del pavo real son el ejemplo clásico.

5.7 Modelando el Cambio: Ecuaciones en Diferencia

Hasta ahora hemos hablado cualitativamente de cómo las poblaciones cambian generación tras generación. Para hacer esa conexión con el aprendizaje de manera precisa, necesitamos un lenguaje matemático para describir ese cambio. El lenguaje apropiado son las **ecuaciones en diferencia**.

Una ecuación en diferencia es una regla que nos dice cómo calcular el estado de un sistema en el tiempo $t + 1$ a partir de su estado en el tiempo t . La forma general es simplemente:

$$\text{Estado}(t + 1) = f(\text{Estado}(t))$$

donde f es alguna función que transforma el estado actual en el estado siguiente. Veamos un ejemplo familiar: el crecimiento de casos de COVID-19. En los modelos epidemiológicos más simples, el número de personas infectadas en la semana siguiente depende del número de infectados esta semana:

$$I(t+1) = r \times I(t)$$

donde $I(t)$ es el número de infectados en el tiempo t , y r es la tasa de reproducción —cuántas personas, en promedio, infecta cada persona infectada. Si $r > 1$, los casos crecen exponencialmente; si $r < 1$, decrecen. Esta simple ecuación captura la dinámica del contagio. La esencia de las ecuaciones en diferencia es esta: expresar el cambio de forma recursiva, de modo que cada nuevo valor $t + 1$ se convierte en el punto de partida del siguiente paso.

Para explorar estos conceptos, abra los [Simuladores en Google Colab](#) y siga las instrucciones de la introducción para dirigirse al simulador 2.

5.8 Covarianza: La Relación entre Rasgo y Éxito Reproductivo

En teoría evolutiva queremos una ecuación que nos diga cómo cambia la distribución de rasgos en una población de una generación a la siguiente. Consideremos un rasgo cuantitativo —altura, velocidad, longitud del pico. En la generación t , ese rasgo tiene un valor promedio en la población que llamamos $\bar{z}(t)$. En la siguiente generación, tendrá un nuevo valor promedio $\bar{z}(t+1)$. El cambio es:

$$\Delta\bar{z} = \bar{z}(t+1) - \bar{z}(t)$$

Para explorar la covarianza, abra los [Simuladores en Google Colab](#) y siga las instrucciones de la introducción para dirigirse al simulador 3.

Esta diferencia nos dice si el rasgo, en promedio, aumentó, disminuyó o se mantuvo igual. La pregunta fundamental es: ¿de qué depende $\Delta\bar{z}$? ¿Qué determina la dirección y magnitud del cambio evolutivo?

La respuesta involucra la relación estadística entre el rasgo y el éxito reproductivo. Para medirla necesitamos un concepto: la **covarianza**.

Imaginemos que medimos dos cosas en cada organismo de una población: el valor de algún rasgo z —digamos, largo de alas— y su éxito reproductivo w —número de descendientes. Queremos saber si estas dos variables están relacionadas: cuando z es grande, ¿ w tiende a ser grande también? ¿O tiende a ser pequeño? ¿O no hay relación?

Recordemos cómo se calcula la media de una variable. Si tenemos n observaciones $x_1, x_2, \dots, x_n$, la media es:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

La **covarianza** entre dos variables extiende esta idea de manera natural. Para cada organismo i , calculamos qué tan lejos está su valor del rasgo de la media del rasgo: $(z_i - \bar{z})$. Esto es una “desviación” respecto a la media —positiva si ese organismo está por encima del promedio, negativa si está por debajo. Hacemos lo mismo para el fitness: $(w_i - \bar{w})$. Ahora viene la idea clave: multiplicamos las dos desviaciones para cada organismo:

$$(z_i - \bar{z}) \times (w_i - \bar{w})$$

Si ambas desviaciones son positivas —el organismo tiene rasgo alto *y* fitness alto— el producto es positivo. Si ambas son negativas, el producto también es positivo. Pero si una desviación es positiva y la otra negativa, el producto es negativo. Sumando estos productos y promediando, obtenemos la covarianza:

$$\text{Cov}(w, z) = \frac{\sum_{i=1}^n (w_i - \bar{w})(z_i - \bar{z})}{n}$$

Una covarianza positiva significa que cuando z está por encima de su media, w tiende a estar por encima de su media también —las variables se mueven juntas. Una covarianza negativa significa que se mueven en sentidos opuestos. Una covarianza cercana a cero indica que no hay relación consistente: saber el valor de z no ayuda a predecir w .

En el contexto evolutivo, $\text{Cov}(w, z)$ nos dice: ¿los organismos con valores altos del rasgo z tienden a tener más descendientes? Si la respuesta es sí, la covarianza es positiva, y ese rasgo tenderá a incrementarse en la población.

5.9 La Ecuación del Cambio Evolutivo

Ahora tenemos las herramientas necesarias: ecuaciones en diferencia para modelar cambios temporales, y covarianza para medir la relación entre rasgo y fitness. Combinándolas, podemos escribir una de las ecuaciones fundamentales de la genética evolutiva moderna.

George Price, en 1970, derivó una forma general del cambio evolutivo conocida ahora como la ecuación de Price. Aquí presentamos una versión simplificada que captura la esencia del proceso para un rasgo cuantitativo en una sola generación:

$$\Delta \bar{z} = \frac{\text{Cov}(w, z)}{\bar{w}}$$

El lado izquierdo, $\Delta\bar{z}$, es el cambio en el valor promedio del rasgo de una generación a la siguiente. El lado derecho dice que ese cambio depende de la covarianza entre fitness y rasgo, dividida entre el fitness promedio de la población.

La lógica es directa. Si $\text{Cov}(w, z) > 0$, entonces $\Delta\bar{z} > 0$: el rasgo aumenta en promedio. Los individuos con valores altos del rasgo tienden a tener más descendientes, y el promedio poblacional se desplaza hacia arriba. Si $\text{Cov}(w, z) < 0$, entonces $\Delta\bar{z} < 0$: el rasgo disminuye. Si $\text{Cov}(w, z) = 0$, entonces $\Delta\bar{z} = 0$: no hay cambio. El rasgo no está asociado con el éxito reproductivo y la selección no tiene base para alterarlo.

Esta ecuación es elegante porque destila la selección natural a su esencia estadística: **el cambio en la media de un rasgo depende de qué tanto ese rasgo covaria con el éxito reproductivo**. No necesita conocer nada sobre mecanismos genéticos, estructuras moleculares ni historias individuales; solo necesita la relación estadística entre rasgo y éxito.

Notemos además que esta es una ecuación en diferencia. Nos dice cómo calcular $\bar{z}(t+1)$ dado $\bar{z}(t)$, exactamente como las ecuaciones que modelaron el crecimiento de COVID. La evolución, al igual que esos procesos, es un sistema dinámico que se actualiza recursivamente.

Para explorar el cambio evolutivo, abra los [Simuladores en Google Colab](#) y siga las instrucciones de la introducción para dirigirse al simulador 4.

5.10 La Equivalencia con los Modelos de Aprendizaje

La ecuación de Price no es solo un resumen matemático de la selección natural. Tiene una estructura que reaparecerá, con distinto sustrato y distinta escala temporal, cuando estudiemos cómo los organismos aprenden de su experiencia. En ambos casos, el sistema se actualiza en proporción a una discrepancia entre lo que ocurrió y lo que se esperaba —o entre un rasgo y su contribución al éxito. Anticipar esta conexión aquí no es un detalle técnico: es el argumento central de este libro. Los mecanismos de aprendizaje que estudiaremos en los bloques siguientes no son procesos independientes de la evolución, sino instancias del mismo algoritmo operando en una escala de tiempo diferente y sobre un sustrato diferente.

5.10.1 El Problema de la Asignación de Crédito

Hay un problema que aparece en cualquier sistema que aprende por retroalimentación, y que conecta directamente la evolución con el aprendizaje. Cuando el sistema recibe una retroalimentación —buena o mala— ¿cómo saber qué componentes del sistema fueron responsables de ese resultado?

Imaginemos un organismo con múltiples rasgos: velocidad de carrera, agudeza visual, eficiencia metabólica, tamaño corporal. Algunos organismos tienen éxito reproductivo alto, otros bajo. La pregunta es: ¿cuál de esos rasgos fue responsable del éxito? ¿La velocidad? ¿La visión?

¿Una combinación? La selección natural resuelve este problema de manera estadística, mediante la covarianza. Si la velocidad covaria positivamente con el fitness a través de la población, pero el tamaño corporal no, entonces la velocidad “merece el crédito”. La población, sin saber nada sobre causalidad, se desplaza hacia mayor velocidad.

Exactamente el mismo problema aparece en el aprendizaje: cuando ocurre un suceso biológicamente importante, ¿a cuál de todos los estímulos y respuestas que precedieron ese suceso se le debe asignar la responsabilidad? Esta pregunta —el *problema de la asignación de crédito*— es el tema central del Bloque II. Lo fascinante es que, aunque la solución evolutiva (covarianza estadística) y la solución del aprendizaje (reducción del error de predicción) parecen diferentes, ambas atacan el mismo problema fundamental: dado un resultado, inferir qué cambios en el sistema llevarán a mejores resultados futuros.

5.11 Conexiones con el Resto del Curso

Este capítulo establece tres conexiones que reaparecerán a lo largo del libro.

La primera es la equivalencia entre selección natural y aprendizaje como instancias del mismo algoritmo de actualización iterativa. Cuando en el Bloque II veamos los modelos de asignación de crédito, y en el Bloque III los modelos de elección y optimización, reconocerán la misma estructura que identificamos aquí: espacio de posibilidades, función de evaluación, regla de actualización proporcional a una discrepancia.

La segunda es el papel de las restricciones. En la evolución, las restricciones físicas, genéticas y filogenéticas limitan el espacio de rasgos posibles. En el aprendizaje, los *sesgos inductivos* cumplen la misma función: reducen el espacio de hipótesis y hacen manejable la búsqueda. Veremos esto con detalle en el capítulo sobre asignación de crédito. Igualmente veremos que los programas de refuerzo son restricciones entre diferentes distribuciones de respuestas.

La tercera es el dilema exploración-explotación. La tensión entre explorar nuevas regiones del espacio de posibilidades y explotar lo conocido aparece en la evolución, en el aprendizaje, y en la elección. Es uno de los problemas fundamentales de la adaptación, y dedicaremos atención específica a sus soluciones en varios capítulos del curso.

5.12 Resumen

La teoría de la selección natural explica la diversidad y la adaptación biológica a partir de tres principios: variabilidad heredable, selección diferencial según el entorno, y herencia. Cuando estos tres principios operan simultáneamente, la composición de la población cambia generación tras generación, favoreciendo los rasgos más exitosos en el entorno actual.

La ecuación de Price formaliza este proceso: el cambio en la media de un rasgo es proporcional a la covarianza entre ese rasgo y el éxito reproductivo. Esta ecuación no es solo una descripción de la evolución —es el prototipo de una familia de algoritmos de actualización iterativa que incluye los modelos de aprendizaje por refuerzo. En ambos casos, el sistema se actualiza en proporción a una discrepancia entre lo que tiene y lo que el entorno le devuelve.

La selección natural y el aprendizaje no son metafóricamente similares —son estructuralmente equivalentes. Entender esta equivalencia desde el principio del curso nos dará una ventaja considerable cuando encontremos esas mismas ideas en dominios aparentemente distintos: el condicionamiento, la elección, la planificación secuencial.

6 Preguntas de Estudio — Capítulo 2: Evolución y Adaptación

6.1 Sección I: Comprensión conceptual

Estas preguntas verifican que los conceptos centrales del capítulo quedaron claros. Pueden responderse sin cálculos.

1. La selección natural requiere tres condiciones simultáneas. Describe cada una con tus propias palabras y explica por qué la ausencia de cualquiera de ellas detendría el proceso evolutivo. Da un ejemplo de una situación donde se cumplan las tres.
2. El capítulo afirma que la selección natural no “elige lo mejor” sino que “elimina lo que no funciona”. ¿Cuál es la diferencia práctica entre estas dos descripciones? ¿Por qué importa esta distinción para entender los límites de la adaptación?
3. Explica en qué sentido la selección natural es un proceso “ciego” —sin intención ni dirección consciente. Usa el ejemplo de la resistencia a antibióticos en bacterias para ilustrar tu respuesta.
4. ¿Qué es un paisaje adaptativo? Describe qué representan los picos y los valles, y explica por qué una población no siempre llega al pico más alto.
5. El capítulo distingue entre “óptimo local” y “óptimo global”. Define ambos términos y describe una situación evolutiva concreta donde una población pudiera quedar atrapada en un óptimo local.
6. ¿Por qué el paisaje adaptativo no es fijo? Describe dos razones por las que puede cambiar a lo largo del tiempo y explica cómo esto complica la idea de que la evolución “optimiza” a los organismos.

6.2 Sección II: Restricciones y espacio fenotípico

7. El capítulo describe tres tipos de restricciones que limitan el espacio fenotípico accesible: físicas, genético-del desarrollo, y filogenéticas. Da un ejemplo de cada tipo y explica cómo cada una reduce el espacio de posibilidades disponibles para la selección.

8. ¿Por qué las restricciones filogenéticas son especialmente relevantes para entender la evolución comparada con un proceso de optimización desde cero? Usa el ejemplo del ojo humano mencionado en el texto o propón uno propio.
9. El capítulo conecta las restricciones evolutivas con los “sesgos inductivos” que veremos en aprendizaje. ¿Qué tienen en común? ¿En qué sentido las restricciones no son obstáculos al proceso sino parte de cómo funciona?

6.3 Sección III: El modelo matemático

10. ¿Qué es una ecuación en diferencia? Explica el concepto con el ejemplo del modelo de COVID presentado en el capítulo, e identifica cuál es el “estado” del sistema y cuál es la función de actualización.
11. Define covarianza con tus propias palabras. Sin usar fórmulas, explica qué significa una covarianza positiva, negativa y cercana a cero en el contexto de la relación entre un rasgo fenotípico y el fitness.
12. Considera una población de pájaros donde medimos la longitud del pico y el número de crías por temporada. Describe dos escenarios: uno donde la covarianza entre longitud del pico y éxito reproductivo sea positiva, y otro donde sea negativa. ¿Qué predice la ecuación de Price para cada caso?
13. La ecuación de Price simplificada es:

$$\Delta \bar{z} = \frac{\text{Cov}(w, z)}{\bar{w}}$$

- ¿Qué ocurre con $\Delta \bar{z}$ cuando la covarianza es cero? ¿Qué significa biológicamente ese resultado? ¿Puede cambiar el rasgo de todas formas? ¿Cómo?
14. ¿Por qué la ecuación de Price es también una ecuación en diferencia? Escribe explícitamente cómo $\bar{z}(t+1)$ depende de $\bar{z}(t)$ y señala la analogía con el modelo de COVID.

7 El Papel de las Restricciones en la Evolución del Comportamiento Adaptable

Suponga que es ingeniero y su empresa le pide diseñar un robot de servicio autónomo para hogares. En su primera versión, el dueño conecta el robot a una toma de corriente antes de acostarse, como lo hace con su celular. Durante la noche el robot trabaja con esa energía, y por la mañana, cuando la batería se agota, se detiene. Usted puede mejorar la autonomía con baterías de mayor duración, pero el problema no desaparece: más tarde o más temprano, sin recarga, el robot se inmoviliza.

Un robot verdaderamente autónomo tendría que recargarse por sí mismo. Pero qué solución de diseño es la correcta depende de dónde va a operar. Si todas las casas fueran idénticas y la toma de corriente siempre estuviera en el mismo lugar, bastaría programar la ruta: a tal hora, dirigirse al punto X. Pero si las casas varían —que es el caso real— el robot necesita un algoritmo que le permita *aprender* la ubicación de las tomas en cada nuevo hogar. Y si el robot fuera a explorar un planeta desconocido, necesitaría algo más: algoritmos capaces de aprender en condiciones de incertidumbre profunda sobre cómo funciona ese entorno.

La selección natural ha operado exactamente como ese ingeniero. Los agentes biológicos enfrentan el mismo problema fundamental: obtener los recursos necesarios para sobrevivir y reproducirse, lo que en este libro llamamos **sucesos biológicamente importantes** (SBI). Como vimos en el capítulo anterior, la variabilidad heredable en el acceso a los SBI genera diferencias en éxito reproductivo, y esas diferencias acumuladas producen adaptación. La pregunta de este capítulo es cuáles tipos de soluciones ha seleccionado la evolución y qué determina cuál es la apropiada en cada caso.

La respuesta depende de dos conjuntos de restricciones: las que impone el propio organismo y las que impone el entorno.

7.1 Las Restricciones del Organismo

El comportamiento tiene costos. El primero y más fundamental es que cualquier comportamiento consume tiempo, y el tiempo disponible es finito. No existe tal cosa como un momento de inactividad en sentido estricto: incluso “permanecer quieto” o “dormir” es un comportamiento que ocupa tiempo y cumple funciones. Si sumamos la duración de todos los comportamientos posibles a lo largo de un período, obtenemos una identidad:

$$T = t_1 + t_2 + t_3 \cdots + t_n$$

Esta ecuación expresa una *restricción lineal*: los diferentes comportamientos compiten entre sí por el tiempo disponible. Cada segundo dedicado a buscar alimento es un segundo menos disponible para vigilar depredadores, para aparearse, para descansar. A esto le llamamos **costo de oportunidad**: el valor de la mejor alternativa a la que se renuncia cuando se elige una opción. Un agente que dedica demasiado tiempo a esconderse tendrá poco tiempo para obtener alimento o encontrar pareja, y dependiendo del entorno, eso puede resultar en menor éxito reproductivo que un animal con una distribución más equilibrada.

Estos **trade-offs** son ubicuos en biología porque las restricciones fundamentales —tiempo finito, energía limitada— hacen imposible maximizar todo simultáneamente. Como vimos al hablar de paisajes adaptativos, el óptimo es siempre un balance entre presiones en tensión. Esta restricción reaparecerá con fuerza en el Bloque III, cuando estudiemos cómo los organismos distribuyen su comportamiento entre opciones que compiten.

Un segundo grupo de restricciones del organismo incluye su estructura biológica, metabólica, neuronal y física. Estas características delimitan el rango de comportamientos posibles —el **espacio de posibilidades**— y determinan el costo energético de cada uno. A estas restricciones se suman los **costos cognitivos** de los algoritmos mismos: algunos mecanismos de aprendizaje requieren mayor capacidad de memoria o procesamiento, lo que tampoco es gratuito.

7.2 Las Restricciones del Entorno

Además de las limitaciones del organismo, el entorno impone sus propias condiciones. La más fundamental es si las condiciones que determinan la disponibilidad de los SBI son **constantes o variables** a lo largo del tiempo.

Cuando las condiciones son relativamente constantes a lo largo de la historia evolutiva de una especie, la selección natural puede codificar directamente en el genoma las respuestas apropiadas. El resultado es el **comportamiento adaptado**: patrones conductuales que no requieren aprendizaje individual porque la solución ya está incorporada filogenéticamente. El reflejo de retirada ante un estímulo doloroso es un ejemplo: la relación entre calor intenso y daño tisular ha sido suficientemente constante durante millones de años. Otro ejemplo es la impronta en aves: los patitos siguen al primer objeto en movimiento que perciben después de la eclosión porque, en la historia de esa especie, ese objeto era invariablemente la madre. El ingeniero que escribe directamente en el código del robot la respuesta correcta está haciendo, en miniatura, lo que la selección natural hace con el comportamiento adaptado.

Sin embargo, los entornos de la mayoría de los organismos son variables, volátiles e inciertos. En esas condiciones, una respuesta conductual genéticamente fija sería evolutivamente subóptima: el entorno cambia, pero la respuesta no puede hacerlo. Ante un entorno variable, la selección

natural favorece algo radicalmente diferente: no codificar respuestas específicas, sino codificar **algoritmos adaptativos** que permitan al organismo ajustar su conducta a las condiciones particulares de su entorno, en tiempo real. A esto le llamamos **comportamiento adaptable**.

7.3 Dos Tipos de Algoritmos Adaptativos

Dentro del comportamiento adaptable pueden distinguirse dos grandes familias de algoritmos, según la estructura estadística del entorno al que responden.

Considere la vida de una bacteria en el intestino. La glucosa está dispersa de manera impredecible y la bacteria carece de receptores que le permitan detectar la fuente a distancia. Una solución posible es el movimiento aleatorio; la que evolucionó es más efectiva: un algoritmo de ascenso de colina basado en comparaciones sucesivas de la concentración del nutriente. Si en este momento la concentración es mayor que hace un instante, continuar en la misma dirección; si es menor, cambiar. Este algoritmo no requiere memoria: utiliza solo información local del momento presente. En el Bloque I estudiaremos este tipo de mecanismos —todos reactivos, sin integración de experiencia previa.

Cuando el entorno tiene una estructura causal —cuando los SBI no ocurren al azar sino correlacionados con ciertos tiempos, lugares, señales o acciones— surge la posibilidad de aprovechar esa estructura. Un organismo que recuerda dónde encontró alimento ayer puede regresar mañana; uno que aprendió que cierto sonido precede a un depredador puede anticiparse. Estos algoritmos, que llamamos **aprendizaje**, integran la experiencia previa para reducir la incertidumbre sobre el entorno. La diferencia respecto a los algoritmos reactivos no es de complejidad superficial sino de lógica: el aprendizaje solo tiene sentido si el entorno tiene estructura que pueda detectarse y aprovecharse.

Esto nos lleva a una pregunta que es, en el sentido del capítulo sobre explicación, una pregunta de nivel computacional: ¿qué tipos de estructura estadística puede tener un entorno? Especificar esas propiedades es especificar los problemas que los mecanismos de aprendizaje deben resolver —y, por tanto, organizar qué mecanismos vale la pena estudiar.

7.4 Las Propiedades Estadísticas del Entorno

Un entorno puede tener estructura —información aprovechable— a lo largo de varias dimensiones. Cuáles de esas dimensiones son relevantes para un organismo determina qué clase de mecanismo debe evolucionar. Las siguientes seis propiedades han dominado el estudio del comportamiento adaptable y, no por casualidad, organizan los bloques de este libro.

1. Tiempo de Ocurrencia

Los SBI pueden distribuirse de manera uniforme a lo largo del tiempo o concentrarse en ciertos períodos. Las flores abren al amanecer; los búhos cazan de noche; los restaurantes tienen horarios. Un organismo que detecta esas regularidades puede dedicar su tiempo de búsqueda a los momentos rentables y usarlo en otras actividades el resto del día. Esta adaptación requiere mecanismos que midan intervalos y detecten periodicidades.

2. Lugar de Ocurrencia

Los SBI también pueden distribuirse de manera uniforme en el espacio o concentrarse en ciertos parches. El alimento se concentra en ciertas zonas; los depredadores frecuentan ciertos territorios. Los organismos que detectan esa estructura espacial pueden dirigir su búsqueda eficientemente: regresar a lugares previamente productivos, evitar lugares peligrosos, explorar zonas con alta probabilidad de contener recursos no descubiertos.

3. Covarianza con el Entorno y con el Comportamiento

Muchos SBI no son predecibles por tiempo o lugar per se, sino que están correlacionados con otras características del mundo. Las nubes oscuras predicen lluvia; ciertos olores indican la proximidad de un depredador; el patrón de coloración de algunas orugas señala su toxicidad. Un organismo que aprende estas relaciones puede anticipar los SBI antes de encontrarlos directamente.

Una segunda forma de covarianza involucra las acciones del propio organismo: muchos SBI solo ocurren si se ejecutan ciertas respuestas. Las mascotas obtienen comida solo cuando realizan conductas específicas; el acceso a un servicio de taxis requiere abrir una aplicación. Aprender qué respuestas producen qué consecuencias permite al organismo no solo predecir, sino controlar activamente la ocurrencia de SBI.

Estas dos formas de covarianza —con señales del entorno y con el comportamiento propio— comparten la misma lógica: detectar qué predice qué. Sin embargo, plantean problemas de asignación de crédito suficientemente distintos como para requerir dos capítulos separados en el Bloque II.

4. Detección de Cambios en el Estado del Entorno

Un problema distinto surge cuando las propiedades estadísticas del entorno cambian sin señales externas evidentes. Una reducción en la disponibilidad de presas puede reflejar variación aleatoria normal o un cambio real en el estado del entorno. Quien deja de recibir mensajes de una persona cercana debe decidir si se trata de algo fortuito o de un cambio genuino en la relación. En la literatura clásica, este problema se ha estudiado principalmente como extinción —la desaparición de un reforzador previamente presente—, pero es más general: se trata de inferir si el estado del mundo ha cambiado o si lo observado es simplemente ruido.

5. Tasa de Ocurrencia

Los organismos no solo detectan si un SBI ocurre o no, sino también con qué frecuencia. Para una abeja, no es suficiente saber que una zona del jardín tiene flores con néctar; importa la tasa —cuántas flores por minuto— porque esa tasa determina la rentabilidad de explotar esa

zona frente a explorar otra. La noción de tasa de ocurrencia desempeña un papel central en las explicaciones contemporáneas del comportamiento de elección, como veremos en el Bloque III.

6. Incertidumbre Esperada e Inesperada

Cualquiera de las propiedades anteriores puede ser más o menos incierta. Cuando la variabilidad es estable —cuando existe una distribución de probabilidad constante que la describe— hablamos de **incertidumbre esperada**. El camión de transporte público no pasa siempre exactamente a la misma hora, pero la variación es predecible: tiene una distribución con media y dispersión conocidas. Cuando los parámetros de esa distribución cambian ellos mismos de acuerdo a otra distribución, el entorno se vuelve **volátil** y la incertidumbre es inesperada. En el metro de la Ciudad de México, la probabilidad de que el tren llegue en los próximos dos minutos es alta en hora pico y baja en horas de poca demanda: hay una distribución que cambia según otra distribución. El Bloque V está dedicado a los mecanismos que permiten aprender en entornos volátiles.

Estas seis propiedades no son una taxonomía arbitraria. Son las dimensiones sobre las que un entorno puede tener estructura estadística que un agente puede, en principio, detectar y aprovechar. Si el entorno tiene regularidad en alguna de estas dimensiones y el organismo carece del mecanismo para detectarla, hay una oportunidad adaptativa sin explotar. Si la tiene, ese mecanismo tendrá ventaja selectiva. Los capítulos siguientes estudian, uno a uno, los mecanismos que evolucionaron para responder a cada tipo de estructura.

7.5 Conclusión

El acceso a los sucesos biológicamente importantes está sujeto a restricciones que ningún organismo puede eludir: el tiempo es finito, la energía es limitada, y la estructura biológica delimita el espacio de comportamientos posibles. Estas restricciones hacen inevitable la competencia entre comportamientos y convierten la distribución del tiempo en un problema de optimización bajo restricciones, no de maximización sin límites.

La forma que toma la solución evolutiva depende de la estructura del entorno. Cuando ese entorno ha sido históricamente estable, la selección codifica la respuesta directamente en el genoma —comportamiento adaptado, eficiente pero rígido. Cuando es variable, la solución es radicalmente distinta: codificar algoritmos que permitan al organismo ajustar su conducta en tiempo real. Dentro de esos algoritmos adaptativos, los reactivos operan con información local e inmediata sin integrar experiencia previa; los de aprendizaje acumulan historia para reducir incertidumbre futura, pero solo ofrecen ventaja cuando el entorno tiene estructura causal que pueda detectarse y aprovecharse.

Esa estructura puede manifestarse en seis dimensiones —tiempo, espacio, covarianza con señales del entorno, covarianza con el comportamiento propio, cambios de estado, tasa de ocurrencia— que no son una clasificación arbitraria sino los problemas estadísticos concretos

que los mecanismos de los bloques siguientes evolucionaron para resolver. Cada algoritmo que estudiaremos es una respuesta a uno de esos problemas. Entender el problema es la condición para entender por qué el mecanismo tiene la forma que tiene.

8 Preguntas de Estudio

8.0.1 Sección I: Restricciones del organismo y del entorno

1. El capítulo presenta una ecuación aparentemente simple: $T = t_1 + t_2 + \dots + t_n$. ¿Qué afirma esta ecuación sobre la naturaleza del comportamiento? ¿Por qué implica que los comportamientos *compiten* entre sí, en lugar de simplemente coexistir?
2. Define costo de oportunidad con tus propias palabras y da un ejemplo de tu vida cotidiana que no aparezca en el capítulo. Explica explícitamente qué se gana, qué se pierde, y por qué la restricción lineal de tiempo hace inevitable ese trade-off.
3. El capítulo distingue entre restricciones del organismo y restricciones del entorno. ¿Podría existir un agente adaptativo sin restricciones del organismo? ¿Qué implicaría eso para el problema de la distribución del comportamiento?
4. ¿Por qué una respuesta conductual genéticamente fija sería evolutivamente subóptima en un entorno variable? Construye un ejemplo concreto donde una respuesta fija que funcionó bien durante generaciones se vuelve desventajosa al cambiar el entorno.

8.0.2 Sección II: Comportamiento adaptado y comportamiento adaptable

5. La impronta en aves y el reflejo de retirada ante el dolor son ejemplos de comportamiento adaptado. ¿Qué tienen en común como soluciones evolutivas? ¿Qué condición del entorno hace que ambos sean soluciones apropiadas sin necesidad de aprendizaje individual?
7. ¿Por qué el capítulo llama *algoritmos* a los mecanismos de comportamiento adaptable? ¿Qué agrega esa palabra respecto a decir simplemente “mecanismos” o “respuestas aprendidas”?

8.0.3 Sección III: Los dos tipos de algoritmos adaptativos

9. El capítulo afirma que el aprendizaje “solo tiene sentido si el entorno tiene estructura que pueda detectarse y aprovecharse.” ¿Qué significa esto? Describe un entorno hipotético donde el aprendizaje no ofrecería ninguna ventaja adaptativa sobre el movimiento aleatorio, y explica por qué.

10. ¿Cuál es la diferencia fundamental entre un algoritmo reactivo y un algoritmo de aprendizaje? No se trata solo de que uno use memoria y el otro no: ¿qué problema diferente resuelve cada uno?

8.0.4 Sección IV: Las propiedades estadísticas del entorno

11. El capítulo lista seis propiedades estadísticas del entorno. Elige dos de ellas y, para cada una, describe: (a) qué tipo de regularidad tiene el entorno, (b) qué mecanismo necesitaría el organismo para aprovecharla, y (c) qué desventaja sufriría un organismo que careciera de ese mecanismo.

12. La extinción —cuando un reforzador deja de presentarse— se ha estudiado clásicamente como un fenómeno del condicionamiento. El capítulo la reencuadra como un caso de detección de cambio en el estado del entorno. ¿Qué gana esa reinterpretación? ¿Qué pregunta diferente nos lleva a hacerle al fenómeno?

13. Para una abeja que forrajea en un jardín con dos zonas de flores, ¿qué información adicional ofrece la *tasa* de ocurrencia de néctar frente a saber simplemente si hay o no néctar en cada zona? ¿Por qué esa información adicional es adaptativamente relevante?

14. El capítulo distingue entre incertidumbre esperada e inesperada (volatilidad). Usa el ejemplo del metro de la Ciudad de México para explicar la diferencia. Luego propón un ejemplo de tu propia experiencia que ilustre la misma distinción.

15. El capítulo argumenta que las seis propiedades estadísticas del entorno no son una clasificación arbitraria. ¿Cuál es el criterio que las unifica? ¿Por qué ese criterio justifica estudiarlas como categorías separadas?

16. Considera el comportamiento de estudiar para un examen. Identifica al menos tres de las seis propiedades estadísticas del entorno que son relevantes para decidir cuándo, dónde y cómo estudiar. Para cada una, describe qué información estadística estaría usando un estudiante que distribuye bien su tiempo de estudio.

9 Ascenso de Colina

9.1 Un Mecanismo de Adaptación Sin Historia

En el capítulo anterior vimos cómo la selección natural opera a escala filogenética para producir comportamiento adaptado: soluciones codificadas genéticamente que funcionan bien en entornos relativamente predecibles. Pero la mayoría de los organismos enfrentan entornos que cambian en escalas de tiempo mucho más cortas que las generaciones, y deben ajustar su comportamiento durante su propia vida, a veces en segundos. ¿Qué ocurre cuando la variación es tan rápida que la selección natural no puede anticiparla, pero tampoco hay tiempo para aprender en el sentido pleno de la palabra?

Este capítulo introduce el primer mecanismo en nuestro cajón de herramientas: el **ascenso de colina** (*hill climbing*). Es un algoritmo elegantemente simple que permite a organismos muy básicos —incluso sin sistema nervioso— navegar eficientemente hacia recursos en entornos variables. Sus componentes esenciales reaparecerán, en formas más sofisticadas, cuando lleguemos al aprendizaje propiamente dicho.

9.2 El Problema Adaptativo

Considera el problema que enfrenta cualquier organismo que necesita encontrar alimento distribuido en el espacio —una bacteria en un medio acuoso, una plántula en el suelo del bosque, una ameba en busca de nutrientes. Hay una restricción que hace el problema particularmente difícil: muchos de estos organismos carecen de **receptores de distancia**, los órganos sensoriales que permiten detectar recursos remotamente, como la visión o el olfato en mamíferos. Sin receptores de distancia, el organismo no puede simplemente “ver” dónde está la comida y dirigirse hacia ella. Solo puede detectar si la concentración de nutrientes en su ubicación *actual* es mayor o menor que hace un momento. La información disponible es estrictamente local y temporal.

A esto se suma que la detección no es perfecta: fluctuaciones aleatorias pueden hacer que una zona parezca momentáneamente mejor o peor de lo que es. Y en entornos con múltiples fuentes de nutrientes, existe el riesgo de quedarse “atascado” en una fuente pequeña cercana, sin llegar a una fuente mayor más alejada —el problema clásico de los **máximos locales**.

Es el mismo desafío que enfrentas cuando buscas señal de wifi en un edificio desconocido: sin mapa, sin vista del router, guiándote solo por la barra de señal que sube o baja con cada paso.

9.3 El Comportamiento Observado

9.3.1 Plantas

Las plantas verdes enfrentan una competencia intensa por la luz solar. Una plántula germinando en el suelo del bosque debe crecer esquivando obstáculos —otras plantas, ramas, rocas— que bloquean su camino hacia la luz. Lo hace con tres comportamientos coordinados: el tallo rota, “barriendo” diferentes direcciones; al detectar mayor intensidad lumínica en alguna dirección, crece preferentemente hacia ese lado (fototropismo); y simultáneamente crece hacia arriba, alejándose del suelo. La combinación de estos tres comportamientos simples produce trayectorias sorprendentemente eficientes hacia la luz, incluso cuando ésta proviene de direcciones cambiantes o hay obstáculos en el camino.

9.3.2 La Salmonela

La bacteria *Salmonella* es notablemente exitosa localizando alimento. En un experimento clásico, se introduce una pipeta capilar con nutrientes en agua donde bacterias nadan libremente. Después de algunos minutos, hay significativamente más bacterias dentro de la pipeta que afuera —tanto cuando el tubo contiene un atrayente como cuando contiene un repelente, en cuyo caso el movimiento neto es de alejamiento. La Fig. 9.1 muestra las tres condiciones experimentales y las trayectorias observadas.

La observación detallada del movimiento de salmonelas individuales revela dos comportamientos básicos que se alternan. El primero son las **maromas** (*tumbling mode*): la bacteria gira sobre sí misma sin desplazamiento neto —exploración, muestreo de diferentes direcciones posibles. El segundo es el **nado en línea recta** (*running mode*): la bacteria avanza en la dirección actual —explotación de una dirección prometedora. La Fig. 9.2 muestra el mecanismo físico: en modo maroma, los flagelos rotan en sentido horario y se desenredan; en nado recto, rotan en sentido antihorario y forman un haz sincronizado que propulsa a la bacteria.

Lo crucial no son los dos comportamientos en sí, sino la regla que determina cuándo cambiar de uno a otro: si la concentración química está mejorando, continúa el nado recto; si deja de mejorar o empeora, pasa a maromas hasta que por casualidad apunte en una dirección donde la concentración vuelva a mejorar. Lo que controla la transición no son los valores absolutos de concentración, sino los *cambios*. La bacteria es sensible a si las cosas están mejorando o empeorando, no a cuán buenas son en un momento dado.




Figura 4.1. Experimento de la pipeta capilar con *Salmonella typhimurium* en tres condiciones. Control: movimiento aleatorio sin dirección neta. Con atrayente: nados más largos, maromas menos frecuentes; acumulación neta en la pipeta. Con repelente: nados dirigidos lejos de la pipeta; movimiento neto de alejamiento.

Figura 9.1




Figura 4.2. Los dos modos de locomoción bacteriana. En modo maroma (izq.), los flagelos giran en sentido horario y se desenredan, sin producir desplazamiento neto. En modo nado recto (der.), los flagelos rotan en sentido antihorario, forman un haz sincronizado y propulsan a la bacteria en línea recta.

Figura 9.2

9.3.3 La Pregunta Crucial: ¿Simultánea o Sucesiva?

Esto nos lleva a una pregunta fundamental: ¿cómo “sabe” la bacteria si va en la dirección correcta? Hay dos posibilidades en principio. La primera es **comparación simultánea**: la bacteria podría tener receptores en diferentes partes de su cuerpo que comparan la concentración en distintos puntos del espacio al mismo tiempo, como un mamífero que compara las señales que llegan a sus dos fosas nasales. La segunda es **comparación sucesiva**: la bacteria compara la concentración en su posición actual con la concentración en su posición inmediatamente anterior.

La evidencia experimental descarta la primera posibilidad. El diámetro de una bacteria es tan pequeño que la diferencia de concentración entre sus dos extremos es prácticamente imperceptible —el gradiente espacial, a esa escala, no puede detectarse. Lo que sí puede detectarse son los *cambios temporales* en la concentración mientras la bacteria se mueve. Esto se confirma experimentalmente: las transiciones entre maromas y nado recto se producen ante cambios bruscos en la concentración, no ante valores absolutos. Como veremos a lo largo del curso, esta sensibilidad a cambios más que a valores absolutos es una característica ubicua de los sistemas sensoriales y de aprendizaje.

9.3.4 La Adaptación Sensorial

Hay una complicación adicional. Si la bacteria cambiara a nado recto ante el primer incremento detectado y se quedara así indefinidamente, probablemente terminaría en la primera mejora que encontró, no en la mejor ubicación posible. Las bacterias resuelven esto mediante **adaptación sensorial**: después de un tiempo breve —menos de un minuto en *Salmonella*— el sistema de detección “se acostumbra” al nivel actual de concentración. Lo que antes parecía “alta concentración” se convierte gradualmente en el nuevo punto de referencia “normal”. La bacteria vuelve a dar maromas hasta encontrar una concentración aún mayor.

La Fig. 9.3 muestra esta dinámica cuantitativamente. Cuando se añade un atrayente en $t = 0$, la fracción de bacterias en nado recto aumenta abruptamente, reflejando el cambio brusco detectado. Pero en el transcurso de menos de un minuto esa fracción regresa a los valores basales, aun cuando el atrayente sigue presente: la adaptación sensorial ajustó el punto de referencia al nuevo nivel. El sistema vuelve a ser sensible a *cambios adicionales*.

La adaptación sensorial implementa una forma de insatisfacción adaptativa: el organismo nunca se contenta completamente con lo actual, sino que sigue buscando mientras haya tiempo y energía. Como veremos más adelante, esta misma lógica reaparece en mecanismos de aprendizaje mucho más complejos.




Figura 4.3. Cuantificación de la respuesta al atrayente en *Salmonella typhimurium*. Al añadir el atrayente ($t = 0$), la fracción de bacterias en nado recto aumenta abruptamente. La recuperación al nivel basal en menos de un minuto refleja la adaptación sensorial: el sistema responde a cambios en la concentración, no a valores absolutos.

Figura 9.3

9.4 El Algoritmo

Imagina que subes el Ajusco con los ojos vendados. No puedes ver la cima ni el sendero. Lo único que puedes hacer es sentir si el suelo bajo tus pies va hacia arriba o hacia abajo. Si sube, sigues en esa dirección. Si empieza a bajar, te detienes y tanteas otras direcciones hasta encontrar una que vuelva a subir. Después de un tiempo —aunque la cuesta siga siendo empinada— el esfuerzo muscular se vuelve la nueva normalidad y ya no distingues si estás subiendo o no: vuelves a tantear. Eso es todo el algoritmo. La bacteria hace exactamente lo mismo, pero con concentración química en lugar de pendiente, y con flagelos en lugar de piernas.

El mecanismo necesita las mismas piezas en cualquier implementación: un sensor que detecta cambios en la variable relevante, una memoria brevísima del momento anterior, dos modos de movimiento contrastantes —explorar y explotar—, una regla para cambiar entre ellos, y la adaptación sensorial que equivale al momento en que dejas de sentir la pendiente y te obliga a buscar de nuevo. Con esas cinco piezas, el algoritmo está completo.

Existe además una variante ligeramente más sofisticada: en lugar de tomar la primera dirección que mejore, el organismo muestrea múltiples direcciones, registra el valor en cada una, y se mueve hacia la que mostró la mayor mejora. Es el **ascenso de mayor pendiente** —más costoso en memoria, pero más eficiente en entornos ruidosos donde un solo muestreo puede dar una impresión equivocada. El ejemplo de wifi lo ilustra bien: en la versión simple das un paso en una dirección y decides; en la versión de mayor pendiente te detienes, exploras varios pasos en distintas direcciones, memorizas los valores, y luego caminas decididamente hacia donde la señal fue mayor.

En ambos casos estás haciendo *comparaciones sucesivas*, igual que la bacteria: no puedes ver el router, solo puedes comparar si tienes más o menos señal que hace un momento. Esto distingue al ascenso de colina del mecanismo que veremos en el capítulo siguiente, donde la comparación es simultánea —dos puntos del espacio se comparan al mismo tiempo, no el mismo punto en dos momentos distintos.

¿Qué tan bueno es el algoritmo?

El algoritmo que describimos funciona, pero conviene preguntarse qué tan bien funciona y si puede hacerse mejor. Para eso, la competencia del Ajusco es útil más allá de ilustrar el mecanismo.

Imagina que ahora tienes información sobre la montaña: sabes que el Ajusco no es una colina perfectamente suave sino un terreno accidentado, con peñascos, cerros secundarios y mesetas que desde abajo parecen la cima. Tu compañero está vendado y usa el ascenso simple —da un paso, siente si subió o bajó, decide. Tú también estás vendado, pero usas el ascenso de mayor pendiente: antes de comprometerte con una dirección, tanteas varios pasos en distintas direcciones, memorizas los valores, y luego avanzas decididamente hacia donde la pendiente fue mayor. En una montaña suave, tu estrategia no te da ninguna ventaja y te cuesta tiempo extra.

En una montaña con muchos cerros secundarios, tu estrategia reduce el riesgo de quedarte atascado en uno de ellos.

Pero hay algo que ambos hacen mal: el tamaño del paso. Lejos de la cima, cuando el terreno cambia rápidamente con cada movimiento, tiene sentido dar pasos grandes —la información de un paso pequeño es poco informativa respecto a si la dirección general es buena. Conforme te acercas a la cima, la pendiente se suaviza y la señal de cada paso se vuelve más pequeña y más ruidosa. En ese momento, un paso grande puede hacerte cruzar la cima sin notarlo. El paso óptimo no es constante: debe ir reduciéndose conforme se acerca al objetivo.

En la ecuación del mecanismo, el tamaño efectivo del paso está controlado por el parámetro b : cuánto peso le da el sistema a cada diferencia detectada. Un b grande actúa como un paso largo —sensible, rápido para reaccionar, pero propenso a sobrepasar el objetivo. Un b pequeño actúa como un paso corto —robusto ante el ruido, pero lento para reaccionar ante cambios reales. El valor óptimo de b no es fijo: depende de las características del terreno que está navegando el organismo.

Lo mismo aplica al parámetro a , que controla cuánto tiempo sigue el organismo en modo de explotación después de que la señal se estabiliza. En una montaña con pocos máximos locales, un a alto es bueno —el organismo explota con inercia y llega rápido a la cima. En una montaña con muchos cerros secundarios, un a alto es una trampa: la inercia del sistema lo mantiene escalando el primer cerro que encuentra aunque haya uno más alto a su izquierda. El valor óptimo de a también depende del terreno.

Esto no es un defecto del mecanismo sino una propiedad fundamental de cualquier algoritmo de búsqueda: no existe una estrategia universalmente óptima independiente del problema. Lo que existe son estrategias bien adaptadas a tipos particulares de entornos. Y si el entorno cambia, o si el organismo no sabe de antemano qué tipo de entorno enfrenta, el valor fijo de a y b con que parte puede ser bueno o puede ser desastroso.

La solución verdaderamente óptima al problema no es encontrar los mejores valores fijos de a y b , sino desarrollar la capacidad de *ajustar esos valores conforme se acumula experiencia con el entorno*. Un agente que empieza con pasos grandes cuando el terreno es desconocido y los va reduciendo sistemáticamente conforme aprende que está cerca de un óptimo —ese agente es mejor que cualquier agente con parámetros fijos, sin importar qué tan bien calibrados estén esos parámetros. Esa capacidad de ajustar adaptativamente la importancia del error es exactamente lo que veremos en los mecanismos de aprendizaje de los bloques siguientes.

Veremos esa capacidad —ajustar adaptativamente la importancia del cambio detectado— cuando llegemos a los modelos de aprendizaje asociativo en el Bloque II.

9.5 Formalización Matemática

En el simulador que acaban de explorar, el parámetro a es exactamente el tiempo que el agente sigue explotando después de que la concentración dejó de mejorar. Con a cercano a 1, la inercia es grande —como un corredor que tarda en frenar. Con a cercano a 0, para casi de inmediato. El término $b \cdot [X(t+1) - X(t)]$ es la diferencia que ya calcularon en los ejercicios del simulador, multiplicada por qué tanto le importa al sistema esa diferencia.

Juntando las dos partes, la ecuación que rige todo lo que observaron es:

$$Y(t+1) = a \cdot Y(t) + b \cdot [X(t+1) - X(t)]$$

donde $Y(t)$ es la variable de decisión que determina el modo conductual, $X(t)$ es el valor de la variable ambiental (concentración química, intensidad lumínica, señal de wifi), a es el parámetro de adaptación sensorial ($0 < a < 1$), y b es el parámetro de sensibilidad al cambio ($b > 0$).

La regla de respuesta conecta Y con el comportamiento observable: si Y supera un umbral (típicamente cero), el organismo explota —nado recto, crecimiento hacia la luz, caminar en esa dirección; si Y está por debajo, explora —maromas, rotación, prueba otra dirección.

El marciano del capítulo anterior se preguntaba qué *hace* el vehículo. Aquí la pregunta es qué *problema resuelve* la bacteria —y esa pregunta nos dice por qué la ecuación tiene la forma que tiene. Si el problema es navegar sin mapa y sin receptores de distancia, necesitas comparación temporal, no espacial. Y necesitas adaptación que te impida conformarte con el primer gradiente positivo que encuentres. Todo lo demás se sigue de ahí.

9.5.1 Un Ejemplo Numérico

Sigamos la dinámica con valores concretos: $a = 0.9$, $b = 0.5$, umbral = 0. Partimos de $Y(0) = 0$ y $X(0) = 5$. El agente está en modo exploración.

Tiempo 1: $X(1) = 7$ — la concentración mejora. $Y(1) = 0.9 \times 0 + 0.5 \times (7 - 5) = 0 + 1.0 = 1.0 \rightarrow$ Explotar.

Tiempo 2: $X(2) = 9$ — sigue mejorando. $Y(2) = 0.9 \times 1.0 + 0.5 \times (9 - 7) = 0.9 + 1.0 = 1.9 \rightarrow$ Explotar.

Tiempo 3: $X(3) = 9$ — la concentración se estabiliza. $Y(3) = 0.9 \times 1.9 + 0.5 \times (9 - 9) = 1.71 + 0 = 1.71 \rightarrow$ Explotar (Y empieza a decaer).

Tiempo 4: $X(4) = 8$ — baja ligeramente. $Y(4) = 0.9 \times 1.71 + 0.5 \times (8 - 9) = 1.54 - 0.5 = 1.04 \rightarrow$ Explotar.

Tiempo 5: $X(5) = 7$ — sigue bajando. $Y(5) = 0.9 \times 1.04 + 0.5 \times (7 - 8) = 0.94 - 0.5 = 0.44 \rightarrow$ Explotar (Y casi en umbral).

Tiempo 6: $X(6) = 6$ — sigue empeorando. $Y(6) = 0.9 \times 0.44 + 0.5 \times (6 - 7) = 0.40 - 0.5 = -0.10 \rightarrow \text{Explorar}$.

La secuencia muestra algo importante: el sistema no cambia a exploración en el instante en que la concentración deja de mejorar. La inercia del término $a \cdot Y$ mantiene la explotación durante un tiempo —un filtro que evita responder a fluctuaciones momentáneas. Pero si la concentración no mejora de forma sostenida, Y cae por debajo del umbral y el organismo vuelve a buscar. Esto corresponde exactamente a lo que muestra la figura 4.3: la bacteria mantiene el nado recto por un tiempo incluso cuando la concentración se estabiliza, antes de que la adaptación sensorial la devuelva al modo exploración.

💡 ¡Prueba el Simulador Interactivo!

Para explorar los conceptos de este capítulo en la práctica, abre el siguiente simulador:
[Abrir Simuladores en Google Colab](#)

Verás un agente navegando un paisaje de concentración con dos fuentes: una fuente principal (la meta) y un máximo local (la trampa). Parámetros: a , b , nivel de ruido. La trayectoria se colorea por modo: exploración en azul, explotación en naranja. Gráficas en tiempo real de $Y(t)$ y $X(t)$.

Objetivo: Descubrir qué combinación de adaptación sensorial y sensibilidad al cambio produce navegación eficiente, y por qué ninguno de los extremos funciona bien.

Básico: Comienza con $a = 0.9$ y $b = 0.5$. Antes de iniciar la simulación, predice: ¿crees que el agente llegará a la fuente principal o quedará atrapado en el máximo local? Corre la simulación y verifica. Ahora reduce a a 0.3 manteniendo b constante. ¿Qué cambia?

Intermedio: Con $a = 0.97$ (adaptación muy lenta), ¿el agente escapa del máximo local? Prueba $a = 0.5$. ¿Por qué la adaptación sensorial ayuda a escapar de los máximos locales? Piensa en términos del Ajusto: si nunca dejas de sentir la pendiente actual, ¿qué te impide buscar una pendiente mayor?

Avanzado: Activa el ruido ambiental. Encuentra la combinación de a y b que produce la navegación más eficiente con ruido alto. ¿Por qué algunos valores de b que funcionaban sin ruido ya no funcionan? ¿Qué hace que el ruido sea un problema para la sensibilidad al cambio?

9.6 Lo que el Ascenso de Colina Hace y No Hace

El ascenso de colina permite adaptación en tiempo real y navegación eficiente hacia gradientes sin mapa ni receptores de distancia. El balance exploración-explotación emerge automáticamente de la dinámica del sistema, y la inercia del término $a \cdot Y$ actúa como filtro ante el ruido.

Lo que el mecanismo *no* hace es igualmente revelador. En este modelo la comparación es entre el valor actual y el valor inmediatamente anterior: **no hay integración de experiencias pasadas**. Si repetimos la misma situación mañana, el organismo responde igual que hoy —no hay memoria de largo plazo. El mecanismo es puramente reactivo: responde a cambios que ya ocurrieron, no anticipa cambios futuros. No hay modelo interno del entorno ni representación de dónde están las fuentes. Y no hay aprendizaje en el sentido estricto: una bacteria que navegó exitosamente ayer no navega mejor hoy por haber tenido esa experiencia.

Esta distinción es central para el libro. El **comportamiento adaptativo sin aprendizaje** —como el ascenso de colina— produce flexibilidad conductual en respuesta al entorno actual, pero sin retener información de experiencias previas. El **comportamiento adaptable** —que estudiaremos en los bloques siguientes— supone exactamente eso: un cambio duradero en el sistema como resultado de la experiencia. El ascenso de colina es un mecanismo sin historia. Su importancia pedagógica está en que los mismos principios —comparación, reducción de error, balance exploración-explotación— reaparecerán, transformados y enriquecidos, en los mecanismos de aprendizaje que estudiaremos más adelante.

9.7 Conexiones

9.7.1 Hacia atrás: Selección Natural

El ascenso de colina es una instancia de ensayo y error análoga, en su lógica, a la selección natural: la exploración aleatoria genera variación conductual; la comparación determina qué variantes se explotan; la explotación continúa mientras el gradiente es favorable. La diferencia crucial es la escala temporal. La selección natural opera en generaciones; el ascenso de colina opera en segundos o minutos en la vida del individuo. Son el mismo principio en escalas de tiempo radicalmente distintas.

9.7.2 Hacia adelante: Aprendizaje por Refuerzo

La diferencia $[X(t+1) - X(t)]$ es una primera versión del **error de predicción**: la discrepancia entre lo que se esperaba y lo que ocurrió. La actualización incremental de Y es análoga a cómo el valor asociativo se ajusta ensayo a ensayo en los modelos del Bloque II. Y el dilema exploración-explotación, que aquí aparece en su forma más simple, se convertirá en uno de los problemas centrales del aprendizaje por refuerzo en el Bloque IV.

9.7.3 Lateral: Sistemas de Retroalimentación (Próximo Capítulo)

El ascenso de colina utiliza **comparación sucesiva**: el mismo lugar en dos momentos distintos. El próximo capítulo introduce los sistemas de retroalimentación, que utilizan **comparación**

simultánea: dos puntos del espacio se comparan al mismo tiempo. Ambos son mecanismos de adaptación sin aprendizaje, pero la diferencia en el tipo de comparación tiene consecuencias importantes para qué problemas puede resolver cada uno —y la distinción entre los dos es exactamente lo que la evidencia experimental descartó en la Salmonella.

10 Resumen

El problema adaptativo de este capítulo es localizar recursos en entornos variables sin receptores de distancia ni mapa previo. La solución es el ascenso de colina: un algoritmo de comparación sucesiva que alterna entre exploración aleatoria y explotación direccional, guiado por cambios en una variable ambiental de interés. Sus piezas esenciales son: un sensor de cambios, una memoria mínima del momento anterior, dos modos conductuales contrastantes, una regla de transición entre ellos, y adaptación sensorial que previene el estancamiento en máximos locales.

Lo que el mecanismo no hace es tan importante como lo que hace: no hay integración de historia, ni predicción, ni representación del entorno, ni cambio duradero. Es comportamiento adaptativo sin aprendizaje. Su relevancia pedagógica está en que los mismos principios —comparación, reducción de error, balance exploración-explotación— reaparecerán, transformados y enriquecidos, en los mecanismos de aprendizaje de los bloques siguientes.

10.1 Ejercicios de Comprensión

1. La figura 4.3 muestra que después de añadir un atrayente, la fracción de bacterias en nado recto aumenta abruptamente y luego regresa a los valores basales en menos de un minuto. Explica este patrón en términos del parámetro a de la ecuación. ¿Qué valor de a produciría una recuperación más rápida? ¿Qué pasaría si $a = 1$ exactamente?
2. El capítulo descarta la posibilidad de comparación simultánea en *Salmonella* con un argumento basado en el tamaño de la bacteria. Formula ese argumento con tus propias palabras. ¿Puedes pensar en algún organismo que sí pudiera usar comparación simultánea para detectar un gradiente químico?
3. Imagina que buscas señal de wifi en un edificio desconocido. Describe, paso a paso, cómo aplicarías el ascenso de mayor pendiente. ¿En qué situaciones preferirías el ascenso simple? ¿Cuándo valdría la pena el esfuerzo adicional?
4. Usando la ecuación $Y(t+1) = a \cdot Y(t) + b \cdot [X(t+1) - X(t)]$, con $a = 0.8$ y $b = 1.0$, completa la tabla. El umbral para explotar es 0.

t	X(t)	Y(t)	¿Explorar o explotar?
0	10	0	—

t	X(t)	Y(t)	¿Explorar o explotar?
1	12	?	?
2	14	?	?
3	14	?	?
4	13	?	?

¿En qué momento el sistema cambia de modo? ¿Qué dice eso sobre la relación entre estabilización de concentración y exploración?

5. El capítulo afirma que el ascenso de colina no es aprendizaje. ¿Qué le falta para serlo? Formula una modificación hipotética al mecanismo que lo convertiría en algo más parecido al aprendizaje. ¿Qué nueva capacidad adaptativa tendría el organismo con esa modificación?

6. (*Reflexión*) La adaptación sensorial implementa una forma de “insatisfacción adaptativa”. ¿Por qué sería desadaptativo un organismo que no tuviera esta propiedad —que se contentara para siempre con el primer gradiente positivo que encontrara? ¿Puedes pensar en algún contexto donde esa estrategia podría ser ventajosa?

11 Sistemas de Retroalimentación

11.1 Comparación Simultánea y el Límite de la Reactividad

En el capítulo anterior dejamos a la bacteria navegando con un solo sensor. Su estrategia era comparar *ahora* con *hace un momento* en el mismo lugar: si la concentración mejora, sigue; si empeora, busca otra dirección. Eso funciona, pero es lento y sinuoso. La bacteria no sabe hacia dónde está el nutriente —solo sabe si está mejorando o no.

La aparición de la simetría bilateral en los animales resolvió esa limitación de una forma elegante: en lugar de un sensor que se mueve para comparar el mundo en distintos tiempos, el organismo dispone de dos sensores separados que comparan el mundo en distintos lugares *al mismo tiempo*. Con este arreglo, la dirección de la fuente queda codificada directamente en la diferencia entre lo que detecta el lado izquierdo y lo que detecta el lado derecho, sin necesidad de moverse primero para saberlo.

Este capítulo introduce el mecanismo que hace posible esa comparación simultánea y lo generaliza: el **sistema de retroalimentación**. Veremos cómo está organizado, qué preguntas conviene hacerle, y —lo más importante— cuál es la limitación fundamental que comparte con el ascenso de colina y que abre la puerta al aprendizaje.

11.2 El Problema: Orientarse en el Espacio

Imagina a una polilla nocturna. Hay una fuente de luz a una distancia desconocida. No tiene mapa, no tiene brújula. Solo tiene lo que sus dos ojos detectan en este momento: dos intensidades luminosas, una para cada lado de su cuerpo. ¿Cómo usa esa información mínima para orientar su cuerpo hacia la fuente?

Este problema —orientarse hacia o alejarse de una fuente puntual de estimulación— aparece en múltiples modalidades a lo largo del reino animal. La fototaxia de polillas y cucarachas, la quimiotaxia de insectos siguiendo plumas de feromonas, la fonotaxia de grillos hembra localizando machos que cantan, la termotaxia de serpientes detectando presas de sangre caliente: todos son el mismo problema computacional resuelto con el mismo principio básico. La diversidad está en el tipo de estímulo; el mecanismo subyacente es el mismo.

11.3 El Mecanismo: Comparación Simultánea

La solución más simple posible al problema de orientación tiene dos componentes. Primero, comparar simultáneamente la estimulación que llega al receptor izquierdo con la que llega al derecho. Segundo, girar en la dirección del receptor que recibe más estimulación —en el caso de fototaxia positiva, hacia la luz; en el caso de fototaxia negativa, como la cucaracha, en dirección contraria.

Este mecanismo —conocido en biología como **tropotaxia**— es una instancia del principio más general que introduce este capítulo: el **sistema de retroalimentación**. La información direccional está disponible instantáneamente, sin costo de movimiento. No hay que explorar para saber hacia dónde girar.

Dos experimentos clásicos establecen que lo que controla el comportamiento es la *diferencia* entre sensores, no el nivel absoluto de estimulación en ninguno de ellos.

El primero cubre uno de los ojos compuestos de una polilla con pintura opaca. La predicción es directa: con solo un sensor funcional, la diferencia bilateral siempre favorece ese lado; la señal de corrección nunca se cancela porque no hay información desde el lado opuesto. El resultado es un giro continuo, sin orientación hacia ningún punto. Cuando se cubre el ojo izquierdo, la polilla gira continuamente a la izquierda; cuando se cubre el derecho, gira a la derecha. La cucaracha hace exactamente lo opuesto —porque huye de la luz— lo que confirma que el signo del giro depende del tipo de fototaxia, no de cuál ojo está disponible.

****Descripción:** Trayectorias con un ojo cubierto. Filas: oscuridad, luz arriba, haz de luz. Columnas: ojo izquierdo ciego vs. ojo derecho ciego. Con un solo ojo funcional, el organismo gira continuamente en lugar de orientarse. La dirección del giro depende de qué ojo está disponible y del tipo de taxia (positiva/negativa).

El segundo experimento coloca dos fuentes de luz de igual intensidad a igual distancia del organismo. Si la conducta está controlada por la diferencia bilateral, la predicción es que el animal debería moverse en línea recta entre ambas fuentes —porque mientras estén equidistantes, los dos ojos reciben la misma estimulación, la diferencia es cero, y no hay señal de giro. Eso es exactamente lo que ocurre: el organismo avanza en línea recta hasta que la proximidad a una de las fuentes rompe la simetría, momento en que gira bruscamente. Pocas veces un experimento confirma tan limpiamente una predicción.

Descripción: Trayectorias de cochinilla con dos fuentes equidistantes. Las trayectorias reales muestran movimiento en línea recta entre las dos fuentes y el brusco cambio de dirección al acercarse a una de ellas. La línea recta ocurre porque la diferencia bilateral es cero cuando las fuentes son equidistantes.

Vale la pena subrayar el contraste con la bacteria del capítulo anterior: descartamos la comparación simultánea en la Salmonela porque el organismo es demasiado pequeño para




Figura 7.2. Trayectorias con un ojo cubierto bajo iluminacion lateral.
El giro continuo confirma que el mecanismo usa la diferencia entre receptores, no el nivel absoluto de estimulacion.
La direccion del giro depende de cual ojo esta disponible: siempre hacia el lado con mayor estimulacion.

Figura 11.1: Trayectorias con un ojo cubierto




Figura 7.3. Trayectorias con dos fuentes equidistantes (vista superior).
Mientras las fuentes son equidistantes el error bilateral es cero y el organismo avanza en línea recta.
Al acercarse a una fuente la simetría se rompe y el organismo gira hacia ella.

Figura 11.2: Dos fuentes de luz equidistantes

detectar diferencias de concentración entre sus dos extremos. En la polilla, el tamaño sí permite esa comparación —y la evidencia experimental muestra que exactamente eso es lo que ocurre.

11.4 El Sistema de Retroalimentación

La fototaxia es un caso particular de un mecanismo general que aparece a lo largo de la biología y la ingeniería: el **sistema de retroalimentación**. Estamos acostumbrados a pensar en la relación organismo-entorno como unidireccional —el entorno produce un estímulo, el organismo produce una respuesta. Pero esa imagen es incompleta: la respuesta del organismo modifica el entorno, lo que modifica el estímulo que controla la respuesta.

La temperatura alta produce sudoración; la sudoración reduce la temperatura; la temperatura reducida disminuye la sudoración. El bebé recién nacido succiona; la succión extrae leche; la tasa de succión estimula la producción de leche de la madre. En todos estos casos la causalidad no va de A a B sino que forma un lazo cerrado donde A y B se codeterminan mutuamente.

Formalmente, el sistema está definido por dos ecuaciones simultáneas acopladas. La **función de control** (del organismo) describe cómo se transforma el estímulo en comportamiento:

$$C = G(X)$$

La **función de retroalimentación** (del entorno) describe cómo el comportamiento modifica el estímulo:

$$X = E(C)$$

En fototaxia: C es la tasa de giro, X es la disparidad bilateral entre los dos ojos. El giro cambia el ángulo entre el organismo y la fuente, lo que cambia la disparidad, lo que cambia el giro. El lazo se cierra.

En la implementación biológica concreta hay cuatro componentes reconocibles. El **sensor** mide el estado actual —los ojos compuestos que detectan intensidad luminosa en cada lado. El **comparador** calcula la discrepancia entre el estado actual y el estado deseado —el circuito neural que resta la activación de un ojo de la del otro, produciendo la *señal de error*. El **controlador** transforma esa señal de error en una acción —la regla que convierte la disparidad en una tasa de giro. El **efector** ejecuta la acción —los músculos de las alas que producen el giro— y al hacerlo modifica el ángulo, cerrando el lazo.

Descripción: Diagrama de retroalimentación con componentes nombrados. Desired Output → Comparator → Error signal → Effectors (calefactor/AC) → Output, con Sensor + Feedback signal completando el lazo. El comparador integra la salida deseada con la




Figura 7.5. Diagrama genérico de un sistema de retroalimentación negativa con componentes nombrados. El comparador calcula el error entre el set point y el estado actual medido por el sensor. El sistema actúa para reducir ese error: cuando error = 0 la acción cesa.

Figura 11.3: Componentes del sistema de retroalimentación

señal de retroalimentación del sensor para producir la señal de error.

Esto contrasta con los **sistemas abiertos**, donde el comportamiento responde al entorno pero no modifica la variable que lo controla. Un calefactor encendido permanentemente sin importar la temperatura es un sistema abierto. El golpe de lengua de una rana capturando una mosca también: una vez iniciado, el movimiento se ejecuta hasta completarse sin corrección durante su trayectoria. Y cubrir un ojo en el experimento de tropotaxia transforma al organismo en un sistema abierto: el giro nunca recibe señal de corrección, y el resultado es rotación indefinida.

Vale la pena detenerse un momento para notar que, en este capítulo igual que en el anterior, hemos aplicado sin nombrarlo el análisis de tres niveles del Capítulo 1. El nivel computacional es orientarse hacia una fuente de forma rápida y robusta. El nivel algorítmico es la comparación simultánea bilateral, el cálculo de una señal de error, y la función de control que transforma ese error en tasa de giro. El nivel de implementación —los circuitos neurales específicos, los fotorreceptores, los músculos— varía entre especies y no necesitamos especificarlo para entender cómo funciona el sistema. Una polilla, un robot de dos ruedas y un sistema de climatización doméstico comparten la misma arquitectura algorítmica aunque sus implementaciones físicas no tengan nada en común.

La **retroalimentación negativa** ocurre cuando el comportamiento tiende a *reducir* la señal de error —la acción contrarresta la desviación que la provocó. El nombre puede sonar paradójico, pero refleja que la acción tiene signo opuesto al error. Es el caso de la fototaxia y de toda regulación homeostática.

La **retroalimentación positiva** ocurre cuando el comportamiento *amplifica* la señal de error. La apertura de canales de sodio durante un potencial de acción es el ejemplo canónico: la entrada de iones positivos despolariza la membrana, lo que abre más canales, en una cascada que solo se detiene cuando todos los canales están abiertos. Es útil para producir transiciones rápidas y decisivas entre estados, pero no puede servir como mecanismo de orientación.

11.5 Las Cuatro Preguntas

Ante cualquier sistema de retroalimentación, conviene hacerse las mismas cuatro preguntas en orden: ¿tiene el sistema un equilibrio? ¿Cuál es ese equilibrio? ¿Cómo llega el sistema al equilibrio —cuál es su dinámica? ¿Cómo responde ante una perturbación abrupta? Apliquémoslas al sistema de fototaxia.

Para hacerlo concreto, necesitamos la función de control. Sea ω la tasa de giro, S_{izq} la estimulación del sensor izquierdo, y S_{der} la del derecho:

$$\omega = k \cdot (S_{der} - S_{izq})$$

La diferencia entre paréntesis es la señal de error: codifica tanto la magnitud de la desviación como su dirección. Si $S_{der} > S_{izq}$, la fuente está a la derecha, el error es positivo, y ω es positivo (giro a la derecha). Si ambas son iguales, el error es cero y el organismo sigue recto.

El parámetro k es la *ganancia* del sistema: qué tan importante es para el organismo una diferencia dada entre sus sensores. Un k alto significa que diferencias pequeñas producen giros grandes; un k bajo requiere diferencias grandes para producir giros apreciables. Esta interpretación —la ganancia como peso de una señal de discrepancia— reaparecerá en capítulos posteriores cuando veamos cómo el aprendizaje modifica qué tanto le importa a un organismo la diferencia entre lo que predijo y lo que ocurrió. En fototaxia negativa, $k < 0$: ante más luz en el lado derecho, el organismo gira hacia la *izquierda*, alejándose. El signo de k define si el sistema busca o evita la fuente.

¿Tiene equilibrio? Sí. El equilibrio ocurre cuando $\omega = 0$, es decir, cuando la señal de error es cero.

¿Cuál es el equilibrio? La señal de error es cero cuando $S_{der} = S_{izq}$, lo que ocurre cuando el organismo apunta directamente hacia la fuente (ángulo $\theta = 0^\circ$). Hay un segundo equilibrio matemático en $\theta = 180^\circ$, pero es inestable: cualquier perturbación mínima empuja al sistema lejos de ese punto. El equilibrio adaptativo es el único estable.

¿Cuál es la dinámica? La señal de error es mayor cuando el ángulo θ es grande y más pequeña cuando θ es pequeño. Esto significa que el giro correctivo es grande cuando más lo necesitas y se va volviendo cada vez más sutil conforme te acercas al equilibrio. La convergencia que se desacelera al acercarse al equilibrio produce el patrón de trayectoria observado en los

experimentos: no una línea recta, sino una **espiral que se cierra progresivamente** hacia la fuente. Cuanto mayor el ángulo inicial, mayor la curvatura; cuanto más cercano al equilibrio, más recta la trayectoria.

Sistema de retroalimentación en fototaxia de polilla




Figura 7.6. Sistema de retroalimentación para fototaxia positiva en polilla. El ángulo entre organismo y fuente es la variable controlada. La polilla gira en proporción a la disparidad bilateral; el giro reduce el ángulo, que reduce la disparidad, que reduce el giro: el sistema converge a $\theta = 0$.

Figura 11.4: Sistema de retroalimentación de la mariposa

Descripción: Diagrama específico para la mariposa. Set point (45°) → Comparador (E_Angle) → Controller (Flying Decision-making circuit) → Actor (Wing) → Flying, con Sensor (Compound eyes) + señal de Angle cerrando el lazo. Los ángulos y nombres de señales corresponden a las variables del sistema real.

La distinción entre **transitorio** y **estado estacionario** es importante. El transitorio es el período de ajuste desde las condiciones iniciales hasta el equilibrio —la espiral de aproximación. El estado estacionario es el comportamiento una vez alcanzado el equilibrio. Cuando ocurre una perturbación (una ráfaga de viento que desvía a la polilla), el sistema entra en un nuevo transitorio que lo lleva de vuelta al estado estacionario.

¿Cómo responde ante perturbación? Una polilla con 0° recibe una ráfaga de viento que la desvía a $= 30^\circ$. Sin retroalimentación, continuaría en esa dirección indefinidamente. Con retroalimentación: el nuevo ángulo genera nueva disparidad, nueva señal de error,

nuevo giro correctivo, y la polilla vuelve al equilibrio. La perturbación es compensada sin ninguna “decisión” explícita, simplemente por la estructura del lazo. Una ventaja adicional: la robustez es independiente del valor exacto de k . Tanto un organismo joven con músculos débiles como uno adulto con músculos fuertes alcanzarán $\theta = 0^\circ$, solo que a velocidades distintas.

11.5.1 ¿Qué tan buena es la función de control?

La función de control que describimos —girar a una tasa proporcional a la disparidad bilateral— funciona. La polilla llega a la fuente de luz, el organismo con un ojo cubierto gira indefinidamente, el sistema con demora oscila. Pero conviene preguntarse si esa función es la mejor posible.

Considera dos organismos con la misma arquitectura sensorial pero diferente ganancia k . El primero tiene k bajo: responde débilmente a cada unidad de disparidad, tarda más en corregir una desviación pero nunca sobrecompensa. El segundo tiene k alto: responde con fuerza a cada unidad de disparidad, corrige rápidamente pero puede pasarse de largo. En un ambiente tranquilo, sin viento, con la fuente de luz fija, el segundo organismo llega antes. En un ambiente con perturbaciones frecuentes —ráfagas de viento que desvían continuamente al organismo de su trayectoria— el organismo de k alto puede entrar en un ciclo de sobre-correcciones que lo hace menos eficiente que el de k bajo.

El valor óptimo de k no existe en abstracto: existe en relación a las características del entorno. En un entorno estable, alta ganancia es mejor. En un entorno turbulento, ganancia moderada produce mejor desempeño a largo plazo. La “solución” que vemos en cualquier especie particular es el resultado de que la selección natural ajustó k al entorno promedio que esa especie ha enfrentado a lo largo de su historia evolutiva. Una polilla que evolucionó en ambientes con poco viento tiene, probablemente, una ganancia más alta que una especie similar que evolucionó en zonas costeras con viento constante. No lo hemos medido, pero la predicción es directa.

Esto revela algo importante sobre qué significa “entender” un comportamiento. Si solo preguntamos cómo funciona el mecanismo —nivel algorítmico— la respuesta es la función de control y el valor de k que tiene esa especie. Pero si preguntamos por qué ese valor particular de k —por qué no más alto, por qué no más bajo— la respuesta requiere el nivel computacional: cuál es el problema adaptativo que ese organismo resuelve y en qué tipo de entorno lo resuelve. El valor de k es la respuesta al problema; el problema es lo que explica el valor de k .

La misma lógica aplica a la forma de la función de control. La función lineal $\dot{\theta} = k \cdot (S_{\text{der}} - S_{\text{izq}})$ que usamos es la más simple posible. Podría imaginarse una función que no solo usa la disparidad actual sino la *tasa de cambio* de la disparidad —si la diferencia entre sensores está creciendo rápidamente, corrige más agresivamente que si está creciendo despacio, aunque en ambos casos el valor actual de la disparidad sea el mismo. Esa función sería más eficiente ante blancos móviles. Que organismos distintos tengan funciones de control distintas es esperable: la función es la solución y el entorno define el problema.

Lo que hace óptima a la solución más sofisticada no es solo tener la ganancia correcta, sino poder *cambiar adaptativamente qué tan importante es el error* dependiendo de la situación. Un organismo que en entornos tranquilos usa k alto para llegar rápido, y en entornos turbulentos reduce automáticamente su ganancia para no oscilar —ese organismo supera a cualquier competidor con ganancia fija, sin importar qué valor fijo tenga ese competidor. Esa capacidad de modificar la importancia del error basándose en la experiencia reciente con el entorno es, nuevamente, exactamente lo que los mecanismos de aprendizaje permiten. La diferencia entre un sistema de retroalimentación con k fijo y un sistema que aprende el valor de k adecuado no es de tipo sino de escala temporal: el primero es la solución filogenética al problema, el segundo es la solución ontogenética. Cuando en el Bloque II veamos el parámetro de los modelos de aprendizaje, reconoceremos en él la misma pregunta que hemos planteado aquí: ¿qué tan importante debería ser el error para este organismo, en este entorno, en este momento?

¡Prueba el Simulador Interactivo!

Para explorar los conceptos de este capítulo en la práctica, abre el siguiente simulador:

[Abrir Simulador sistemas de retroalimentación](#)

Explora el primer simulador: fototaxias

Objetivo: Descubrir cómo la ganancia k afecta la velocidad de convergencia sin cambiar el equilibrio, y por qué cubrir un ojo transforma el sistema de cerrado a abierto.

Básico: Con $\theta = 75^\circ$ y $k = 1.0$, observa la trayectoria. ¿Es una línea recta o una espiral? Antes de cambiar k , predice: si doblas k a 2.0, ¿el organismo llegará más rápido al mismo equilibrio, o llegará a un equilibrio diferente?

Intermedio: Activa la opción “cubrir ojo izquierdo”. ¿Qué ocurre con la trayectoria? ¿Puedes explicarlo en términos de la señal de error?

Avanzado: Cambia el signo de k (fototaxia negativa). ¿Hacia dónde se mueve ahora el organismo? ¿Qué representa biológicamente este cambio de signo?

11.6 Regulación y Servomecanismos

Hasta aquí el set point —el estado deseado— ha sido fijo: ángulo cero, fuente al frente. Hay una distinción útil entre dos tipos de sistemas que aparecen con frecuencia.

En los sistemas de **regulación**, el set point es interno y permanece relativamente fijo: la temperatura corporal de un mamífero ($\sim 37^\circ\text{C}$), la concentración de glucosa en sangre, el pH de los fluidos internos. El entorno cambia —hace calor, hace frío, comes mucho o poco— pero el organismo corrige continuamente para mantener su estado interno estable. Esto es lo que Cannon llamó homeostasis.

Los **servomecanismos** tienen un set point externo y variable: lo que el sistema persigue cambia de posición en el tiempo. La fototaxia se convierte en servomecanismo cuando la

fuentes de luz se mueven. Un misil teledirigido es el ejemplo tecnológico —no persigue un punto fijo, sino un avión que se desplaza. El seguimiento ocular es el ejemplo biológico cotidiano: cómo tus ojos rastrean un objeto en movimiento sin que tengas que pensarlo. La diferencia importa por sus limitaciones. Un sistema de regulación puede fallar si la perturbación excede su capacidad correctiva. Un servomecanismo puede fallar si el objetivo se mueve más rápido de lo que el sistema puede seguir —hay un límite de velocidad de seguimiento, llamado ancho de banda, más allá del cual el sistema pierde el blanco.

¡Sigue probando el Simulador Interactivo!

[Abrir Simulador sistemas de retroalimentación](#)

Explora el segundo simulador: Efecto de la Demora

Básico: Con $k = 1.0$ y sin demora, confirma la convergencia suave. Añade una demora de 5 pasos. ¿Qué ocurre?

Avanzado: Encuentra el valor de delay a partir del cual el sistema comienza a oscilar para $k = 1.0$. Luego reduce k a la mitad. ¿El mismo delay ahora produce oscilaciones o no? ¿Por qué la ganancia y la demora interactúan?

11.7 El Límite Fundamental: Esclavos del Presente

Los sistemas de retroalimentación son elegantes y poderosos, pero comparten con el ascenso de colina una limitación que no puede resolverse con más ganancia ni más sensores: son completamente **reactivos**. Para que actúen, primero tiene que haber un error. Siempre van un paso atrás.

El termostato no enciende antes de que la temperatura baje. Enciende porque ya bajó. La polilla no gira antes de desviarse de la fuente. Gira porque ya se desvió.

La regadera de agua caliente ilustra las consecuencias de esta reactividad cuando hay demoras. Si hay un desfase significativo entre el momento en que giras la perilla y el momento en que sientes el cambio de temperatura, tiendes a sobrecompensar: “¡demasiado fría!” [giras mucho hacia caliente] “¡ahora demasiado caliente!” [giras mucho hacia fría] y así sucesivamente, oscilando alrededor de la temperatura deseada sin llegar a ella. El problema no es la falta de retroalimentación —hay retroalimentación perfectamente funcional. El problema es que la retroalimentación llega tarde: para cuando la señal de corrección viaja de regreso, ya produjo un exceso en la dirección contraria.

En entornos reales, las demoras son ubicuas. El sistema nervioso tarda en procesar información sensorial. Los músculos tardan en responder. El entorno tarda en cambiar en respuesta al comportamiento. Cada demora puede desestabilizar un sistema de retroalimentación pura. La evolución ha desarrollado estrategias para minimizar estas demoras, pero ninguna las elimina por completo: la retroalimentación siempre reacciona después del hecho.

11.8 El Conductor y las Gasolineras

Considera un problema cotidiano que lleva esta limitación a su punto más claro.

Un conductor viaja por carretera y necesita recargar gasolina en algún punto del trayecto. En principio podría resolver el problema con retroalimentación pura: cuando el tanque llegue a cero, detenerse y buscar gasolinera. El error dispara la respuesta. Problema: para cuando el error se materializa, ya es demasiado tarde. En carretera abierta, el tanque vacío puede dejarte varado entre gasolineras.

Una estrategia apenas mejor es fijar un umbral más alto: cargar cuando quede un cuarto de tanque. Es retroalimentación mejorada, pero sigue siendo reactiva: espera a que el estado del sistema alcance un nivel de alerta antes de actuar. En una ciudad con gasolineras cada dos kilómetros, esa estrategia funciona. En carretera del norte de México, donde pueden pasar cien kilómetros entre gasolineras, puede no ser suficiente.

La solución que adoptan los conductores experimentados es cualitativamente diferente: aprenden la *distribución espacial* de las gasolineras en su ruta habitual. Saben que en tal tramo hay gasolinera en el kilómetro 45, en el kilómetro 130, en el kilómetro 210. Con ese conocimiento, el conductor carga gasolina no cuando el tanque está bajo, sino *antes de un tramo largo sin estaciones*. El comportamiento ya no responde al estado actual del tanque; responde a una predicción sobre necesidades futuras basada en conocimiento aprendido del entorno.

La diferencia entre el conductor novato y el experimentado no es una diferencia en el hardware —ambos tienen los mismos instrumentos, el mismo tanque, los mismos pies. La diferencia es que el conductor experimentado aprendió relaciones en el mundo que le permiten predecir: “si no cargo aquí, más adelante habrá problemas.” Ese aprendizaje —la adquisición de conocimiento sobre relaciones predictivas en el entorno— es precisamente lo que los sistemas de retroalimentación pura no pueden hacer.

A este tipo de control se le llama **control anticipatorio** o *feedforward*. La distinción respecto a la retroalimentación es precisa: en la retroalimentación, la señal que controla el comportamiento es el error actual; en el feedforward, es una predicción del error futuro derivada de un modelo aprendido del entorno. El conductor experimentado opera en modo feedforward respecto a la gasolina: carga antes de que aparezca el error, porque aprendió que cierta señal presente predice una necesidad futura.

El feedforward no reemplaza a la retroalimentación —la complementa. Si una gasolinera esperada está cerrada, el conductor reactiva inmediatamente la estrategia reactiva. Los sistemas biológicos más robustos combinan ambos lazos: la retroalimentación garantiza la corrección cuando algo sale mal; el feedforward evita que salga mal en primer lugar.

¡Sigue probando el Simulador Interactivo!

[Abrir Simulador sistemas de retroalimentación](#)

Explora el tercer simulador: Reactivo vs. Anticipatorio

Básico: Con la distribución por defecto de gasolineras [40, 90, 250, 280, 450 km], ¿cuál conductor llega al final de los 500 km? ¿En qué kilómetro se queda varado el reactivo?

Avanzado: Cambia las gasolineras a [20, 40, 60, 460, 480] —muchas al inicio, casi ninguna al final. ¿Cambia el resultado? ¿Puede el conductor reactivo tener éxito con algún umbral diferente al 15%? ¿Cuál es el umbral mínimo que garantiza llegar?

11.9 El Puente Hacia el Aprendizaje

Este capítulo y el anterior han explorado mecanismos adaptativos que funcionan sin aprendizaje: el ascenso de colina y la retroalimentación. Ambos son herramientas poderosas para problemas relativamente estables y locales. Ambos comparten la misma limitación: responden al mundo tal como es *ahora*, no al mundo tal como *será*.

Para sobrevivir en un mundo donde eventos pasados predicen eventos futuros, un organismo necesita algo más: poder modificar su comportamiento basándose en experiencia acumulada. Aprender que cierto estímulo predice cierta consecuencia, y ajustar la conducta *antes* de que la consecuencia llegue. En términos del conductor: aprender que cierta señal en el entorno predice escasez de gasolineras adelante, y actuar en consecuencia.

Esto es el condicionamiento asociativo, y es el tema central del resto del libro. Los mecanismos que veremos —condicionamiento pavloviano, aprendizaje instrumental, modelos de reducción de error— son todos soluciones al mismo problema: ¿qué predice qué? ¿qué acción produce qué consecuencia? Cuando un organismo resuelve ese problema, ya no vive esclavizado al presente. Puede anticipar, prepararse, y actuar sobre el futuro antes de que llegue.

11.10 Comparación: Los Dos Mecanismos Sin Historia

	Ascenso de Colina (Cap. 4)	Retroalimentación (Cap. 5)
Tipo de comparación	Sucesiva (ahora vs. antes)	Simultánea (derecha vs. izquierda)
Sensores requeridos	Uno solo	Bilaterales (dos)
Información direccional	No —solo tendencia local	Sí —dirección inmediata
Velocidad de convergencia	Lenta, sinuosa	Rápida, en espiral
Requiere memoria	Sí (valor previo)	No (comparación instantánea)
Robustez ante perturbaciones	Moderada	Alta

Ambos mecanismos son adaptativos y complementarios. Muchos organismos los usan en diferentes contextos o en combinación. Lo que comparten —y lo que justifica estudiarlos juntos— es la limitación que abre la puerta al aprendizaje: son reactivos. No tienen historia, no tienen predicción, no tienen modelo del futuro.

11.11 Ejercicios de Comprensión

1. Para cada comportamiento, decide si es (a) ascenso de colina, (b) taxia, (c) retroalimentación con set point interno, o (d) sistema abierto sin retroalimentación: un murciélago ajusta la dirección de vuelo basándose en diferencias de tiempo entre la llegada del eco a cada oído; una planta cierra sus hojas al detectar vibración; un humano mantiene su temperatura corporal en 37°C; un caracol navega hacia mayor humedad comparando su situación actual con la de hace un minuto.
2. Dibuja el diagrama de lazo de retroalimentación para la termorregulación en un mamífero. Identifica el sensor, el comparador, el controlador, el efector, y la función de retroalimentación. ¿Cuál es el set point? ¿Cuál es la señal de error cuando la temperatura ambiente baja bruscamente?
3. La función de control de una polilla es $\dot{\theta} = k \cdot (S_{\text{der}} - S_{\text{izq}})$ con $k = 2$. En un momento dado, $S_{\text{der}} = 8$ y $S_{\text{izq}} = 5$. ¿Cuál es la tasa de giro? ¿En qué dirección está la fuente? ¿Qué ocurre en el siguiente instante si el giro fue efectivo y ahora $S_{\text{der}} = 6.5$ y $S_{\text{izq}} = 6.5$?
4. El experimento de cubrir un ojo transforma al organismo de un sistema cerrado a uno abierto. Explica por qué en términos de las dos ecuaciones del sistema (función de control y función de retroalimentación). ¿Cuál de las dos ecuaciones deja de funcionar correctamente?
5. Diseña el sistema de retroalimentación para un robot que debe seguir una línea negra en el piso usando dos sensores de luz en la parte frontal inferior. Especifica: (a) cuál es la señal de error, (b) cómo varía el signo de k según si el robot va hacia la línea o se aleja, (c) qué ocurre cuando el robot cruza la línea completamente y ambos sensores ven blanco.
6. El ejemplo del conductor y las gasolineras ilustra la diferencia entre reactivo y anticipatorio. Piensa en un ejemplo de tu propia vida donde aplicas una estrategia anticipatoria. ¿Qué señal usas como predictor? ¿Cuándo y cómo aprendiste que esa señal predice la necesidad futura? ¿Recuerdas haber fallado —usando la estrategia reactiva— antes de aprender la anticipatoria?

11.12 Para Profundizar

Fraenkel, G. S., & Gunn, D. L. (1961). *The Orientation of Animals: Kineses, Taxes and Compass Reactions*. Dover. El tratado clásico. Los capítulos 2–4 cubren la evidencia experimental en taxias con más detalle del que fue posible aquí.

Braitenberg, V. (1984). *Vehicles: Experiments in Synthetic Psychology*. MIT Press.

Una joya conceptual: comportamientos sorprendentemente complejos emergen de sistemas de retroalimentación simple. Breve y completamente accesible.

Powers, W. T. (1973). *Behavior: The Control of Perception*. Aldine. Un argumento radical: todo comportamiento animal es, fundamentalmente, control de percepción mediante retroalimentación. Controversial pero influyente.

Ashby, W. R. (1956). *An Introduction to Cybernetics*. Chapman & Hall. Los fundamentos matemáticos de los sistemas de retroalimentación, escritos con claridad excepcional. Los capítulos 1–3 son suficientes para los propósitos de este curso.

|

|

12 El Problema de la Asignación de Crédito

Al final del capítulo anterior dejamos a nuestro organismo en una situación paradójica. Los sistemas de retroalimentación que describimos son notablemente eficaces: pueden orientar un cuerpo hacia una fuente de luz, mantener la temperatura dentro de un margen preciso, seguir una presa en movimiento. Pero tienen una limitación que el ejemplo del conductor y las gasolineras ilustró de manera directa: responden a lo que está ocurriendo ahora, sin ninguna capacidad de anticipar lo que está por ocurrir. El conductor que carga gasolina solo cuando el tanque ya está vacío llegará varado tarde o temprano. El conductor experimentado actúa antes —carga cuando ve que se aproxima un tramo largo, porque ha aprendido que esa señal predice la necesidad futura.

Ese salto, de reactivo a anticipatorio, requiere algo que los mecanismos del Bloque I no tenían: la capacidad de aprender que ciertos eventos del entorno predicen la llegada de sucesos biológicamente importantes. Pero esto introduce de inmediato un problema que no es trivial. Cuando ocurre algo importante —aparece comida, ataca un depredador, se produce un malestar— el entorno está lleno de estímulos simultáneos y el pasado está lleno de eventos candidatos. ¿A cuál de todos ellos se le debe atribuir la responsabilidad? ¿Qué evento, de entre los centenares que precedieron al suceso, fue realmente su causa? A este problema de adaptación se le conoce como el **problema de la asignación de crédito**, y es el tema central de este capítulo.

12.1 El Problema: Un Espacio Enorme de Candidatos

Considera la situación concreta de un perro callejero que encuentra comida en una banqueta. En ese momento hay docenas de estímulos presentes simultáneamente: el olor del asfalto húmedo, el sonido de una bocina lejana, la figura de un transeúnte que se aleja, el color de la bolsa que contenía la comida, la hora del día, el olor particular del barrio. Y más allá de los estímulos presentes, hay una historia de eventos que ocurrieron antes: algo cruzó por ahí cinco minutos atrás, hubo un camión de basura en la mañana, llovió ayer. Cualquiera de estos factores podría, en principio, predecir dónde y cuándo aparecerá comida en el futuro.

O considera tu propia experiencia: regresas a casa después de comer en un restaurante nuevo y experimentas un fuerte malestar estomacal. ¿Qué lo causó? Las posibilidades son abrumadoras. Podría ser el platillo que ordenaste, el olor del restaurante, la música que sonaba, algo que comiste ayer, algo que tocaste en el transporte público, el estrés acumulado del día. Esta lista podría extenderse indefinidamente hacia el pasado. Sin algún mecanismo que filtre ese espacio de posibilidades, el aprendizaje sería computacionalmente

intratable —un organismo que evaluara sistemáticamente cada candidato posible quedaría paralizado antes de poder actuar.

Y sin embargo, la mayoría de los organismos aprenden relaciones predictivas con una eficiencia sorprendente, en tiempo real, sin acceso a bases de datos ni laboratorio de estadística. La pregunta es cómo.

La respuesta es que los organismos no buscan en todo el espacio de candidatos. Buscan en un subconjunto reducido y ordenado, definido por un conjunto de reglas que llamamos **sesgos inductivos**. Estos sesgos hacen dos cosas: primero, reducen drásticamente el espacio de candidatos posibles; segundo, establecen un orden de prioridad para evaluarlos. Antes de examinarlos en detalle, conviene preguntarse de dónde vienen y por qué tienen la forma que tienen.

12.2 El Genoma Como Archivo Causal

El genoma no es un acumulador indiferente de variación aleatoria. La fracción del genoma que ha sido modelada por la selección natural —la parte que afecta el éxito reproductivo y que ha cambiado bajo la presión del entorno— es, en sentido literal, un registro comprimido de las regularidades estadísticas del entorno ancestral: qué eventos tendían a co-ocurrir, con qué frecuencias, en qué secuencias temporales. Cada generación, los organismos con mecanismos mejor calibrados a esas regularidades dejaron más descendientes, y ese proceso iterativo —que la ecuación de Price formalizó en el capítulo sobre selección natural— produjo, acumulativamente, un sistema nervioso que llega al mundo ya “informado” sobre la estructura causal más probable de su entorno.

Desde esta perspectiva, la selección natural es una forma de aprendizaje filogenético. No es el aprendizaje de un organismo individual durante su vida, sino el aprendizaje de una especie a lo largo de sus generaciones. Y al igual que el aprendizaje individual produce cambios en el organismo que reflejan las regularidades del entorno que ese individuo ha experimentado, el aprendizaje filogenético produce cambios en el acervo genético que reflejan las regularidades del entorno que esa especie ha habitado. Los sesgos inductivos son el producto más visible de ese proceso: no restricciones arbitrarias impuestas desde fuera, sino conocimiento filogenético sobre la estructura causal del mundo, destilado por selección durante escalas de tiempo inaccesibles para cualquier individuo.

Veremos más adelante en el curso que hay una manera precisa de medir cuánta información contiene un organismo sobre su entorno, y que la selección natural puede entenderse como el proceso que maximiza esa cantidad, generación tras generación. Por ahora, lo que importa es la consecuencia directa para los sesgos: si el entorno ancestral tenía una estructura causal particular —si los eventos biológicamente importantes tendían a ser precedidos por ciertas clases de estímulos, con ciertas demoras temporales, en ciertos contextos sensoriales— entonces la selección favorecerá organismos que busquen primero en esa parte del espacio de candidatos. Eso es exactamente lo que observaremos.

12.3 El Sistema de Comportamiento Como Primer Filtro

Antes de examinar los sesgos inductivos específicos, hay un nivel de organización más fundamental que los estructura a todos: los **sistemas de comportamiento**.

Jerry Hogan y John Timberlake desarrollaron una perspectiva que ha sido influyente precisamente porque da sustrato funcional a la idea de relevancia biológica. Su propuesta es que el comportamiento de los organismos no es una colección arbitraria de respuestas inconexas, sino que está organizado en sistemas funcionales pre-estructurados por la evolución. Un sistema de comportamiento es un conjunto coordinado de mecanismos perceptuales, motivacionales y motores que evolucionó para resolver un problema adaptativo específico: el sistema de alimentación, el sistema de defensa ante depredadores, el sistema reproductivo. Cada uno tiene sus propias estructuras de detección, sus propias respuestas características, su propia lógica temporal.

Lo que hace crucial esta organización para la asignación de crédito es la siguiente observación: cuando ocurre un suceso biológicamente importante, no genera una activación genérica del organismo. Activa el sistema de comportamiento apropiado para ese tipo de suceso. La presentación de comida activa el sistema de alimentación, con todas sus estructuras perceptuales y motoras. Un depredador activa el sistema de defensa. Y esta activación de un sistema específico tiene una consecuencia inmediata: reduce drásticamente el espacio de estímulos que serán siquiera considerados como candidatos a la asignación de crédito.

Cuando el sistema de alimentación está activo, los estímulos relevantes para la alimentación —sabores, olores, señales visuales de comida— son procesados preferentemente. Los estímulos irrelevantes para la alimentación —sonidos ambientales neutros, características del suelo— reciben mucha menos atención. El sistema de comportamiento funciona así como un filtro atencional de primer orden: antes de que operen los sesgos específicos que examinaremos a continuación, el tipo de suceso biológicamente importante ya ha limitado severamente el espacio de búsqueda.

En el lenguaje del aprendizaje automático contemporáneo, podríamos decir que los sistemas de comportamiento son *priors* estructurados: no comenzamos asignando probabilidades iguales a todos los estímulos del universo, sino con un espacio de hipótesis ya preconfigurado donde ciertas dimensiones de estimulación son a priori más probables de ser relevantes, dado el tipo de suceso que ocurrió. Este insight de Hogan y Timberlake no es solo teórico —lo veremos confirmado empíricamente en cada uno de los experimentos que siguen.

12.4 El Primer Sesgo: Contigüidad Temporal

12.4.1 El Experimento de Pavlov

Dentro del sistema de comportamiento que el suceso biológicamente importante ha activado, el primer sesgo que opera es la **contigüidad temporal**: los eventos que

ocurrieron aproximadamente al mismo tiempo que el suceso son candidatos más plausibles que los que ocurrieron hace mucho tiempo. La intuición es directa —la mayoría de los mecanismos causales biológicamente relevantes producen sus efectos con relativa rapidez— y fue el primero en recibir atención sistemática.

A principios del siglo XX, Ivan Pavlov le dio sentido experimental a este sesgo. El protocolo básico es conocido: a un perro se le presenta un estímulo auditivo —un tono— seguido por acceso a comida. El tono, inicialmente neutral, adquiere la capacidad de provocar salivación precisamente porque predice la llegada de la comida. Pavlov y sus sucesores exploraron sistemáticamente distintas variaciones temporales del procedimiento. En el condicionamiento de demora, el tono inicia primero y la comida llega mientras el tono sigue activo: el intervalo relevante es el que transcurre entre el inicio del tono y el inicio de la comida. Cuando ese intervalo es corto —de medio segundo a dos segundos— el aprendizaje es excelente; cuando se extiende a varios segundos o minutos, el aprendizaje disminuye sistemáticamente aunque el tono permanezca presente. En el condicionamiento de huella, el tono termina completamente antes de que inicie la comida, dejando un intervalo vacío entre ambos; el aprendizaje decrece con la duración de ese intervalo. Y en el condicionamiento hacia atrás —la comida se presenta primero, el tono después— el aprendizaje es mínimo o nulo.




Figura 8.1. Los cuatro protocolos temporales del condicionamiento clásico y el gradiente de la demora.

Figura 12.1: Protocolos temporales del condicionamiento clásico y gradiente de la demora.

Note

Descripción. Los cuatro procedimientos temporales básicos del condicionamiento clásico. Eje horizontal: tiempo. Las barras sólidas indican la duración de cada estímulo. De arriba a abajo: condicionamiento de demora corta (EC activo cuando llega el EI — máximo aprendizaje), demora larga (EC aún activo pero intervalo mayor), huella (EC apagado antes de que llegue el EI — intervalo de huella vacío), y condicionamiento hacia atrás (EI antes que EC — mínimo aprendizaje). La flecha lateral indica el gradiente de la demora: la fuerza del condicionamiento disminuye sistemáticamente conforme aumenta el intervalo entre el inicio del EC y el inicio del EI.

El patrón que emerge de estos estudios es el **gradiente de la demora**: la fuerza del condicionamiento disminuye sistemáticamente conforme aumenta el tiempo entre el estímulo candidato y el suceso biológicamente importante. Dependiendo de la preparación, después de menos de un minuto de intervalo frecuentemente no se observa aprendizaje alguno. Nota que este gradiente no es binario —contiguo o no contiguo— sino continuo: mientras más cercanos en el tiempo, mayor es el crédito asignado.

El gradiente de la demora tiene una interpretación directa en términos del problema de asignación de crédito. Frente al espacio enorme de candidatos posibles, el organismo descarta todos los que no ocurrieron aproximadamente al mismo tiempo que el suceso. El espacio se reduce radicalmente. Pero conviene preguntarse de inmediato: ¿es siempre esto una buena política?

12.5 ¿Es la Contigüidad Condición Necesaria? El Experimento de García

El gradiente de la demora parecía establecer la contigüidad como un principio fundamental: sin proximidad temporal, no hay aprendizaje. Pero esta generalización ya había empezado a ceder antes de que alguien la pusiera explícitamente a prueba.

A finales de los años cincuenta, John García trabajaba en un laboratorio de radiación estudiando los efectos de la exposición sobre ratas. Observó algo que nadie buscaba: las ratas desarrollaban aversión a su comida habitual después de ser irradiadas, aunque el malestar gástrico causado por la radiación tardara horas en aparecer. Nadie había diseñado ese experimento. Las horas de demora entre la ingesta y el malestar deberían haber hecho el aprendizaje imposible, según el gradiente que Pavlov había establecido. Y sin embargo ocurría.

García diseñó entonces un experimento para explorar ese resultado de manera sistemática. El diseño publicado con Koelling en 1966 tiene una elegancia particular: en lugar de manipular una variable a la vez, pone en juego dos tipos de estímulos y dos tipos de consecuencia simultáneamente, de modo que los resultados de los cuatro grupos se iluminan mutuamente.

A todas las ratas se les daba acceso a un bebedero con agua azucarada; cada lametazo

producía simultáneamente un tono y un destello de luz. Así, el estímulo era siempre un compuesto: sabor por un lado, señal audiovisual por otro. Luego los grupos se separaban. A la mitad se les administraba una descarga eléctrica inmediata con cada lametazo; a la otra mitad se les inyectaba una sustancia que producía malestar gastrointestinal con un retraso de horas.




Figura 8.2. Diseño y resultados del experimento de García y Koelling. En entrenamiento todos los animales reciben el compuesto. En prueba, los grupos se disocian: cada consecuencia genera aversión solo al estímulo biológicamente relevante para ella.

Figura 12.2: Diseño y resultados del experimento de García y Koelling (1966).

Note

Descripción. En la fase de entrenamiento todos los animales reciben el compuesto sabor+audiovisual contiguo con su respectiva consecuencia: descarga eléctrica inmediata (grupo izquierdo) o malestar gastrointestinal con retraso de horas (grupo derecho). En la fase de prueba los estímulos se presentan por separado. El grupo con descarga desarrolla aversión al estímulo audiovisual pero no al sabor; el grupo con malestar desarrolla aversión al sabor pero no al audiovisual. El mismo compuesto produce resultados completamente distintos dependiendo del tipo de consecuencia, lo que demuestra que la naturaleza del suceso biológicamente importante determina qué dimensiones del estímulo entran en el espacio de candidatos para la asignación de crédito.

Los resultados cruzaron de manera llamativa. Las ratas con descarga eléctrica no dejaron

de beber el agua dulce, pero sí evitaban el bebedero cuando este producía el tono y la luz. Las ratas con malestar gastrointestinal hacían exactamente lo contrario: dejaban de beber el agua dulce, pero no presentaban aversión al tono ni a la luz.

Los dos grupos no ilustran el mismo fenómeno y vale la pena separarlos.

En el grupo de descarga, ambos componentes del compuesto eran igualmente contiguos con la consecuencia —el shock llegaba con cada lametazo, sin demora. A pesar de esa igualdad temporal, el aprendizaje fue selectivo: solo el estímulo audiovisual adquirió valor aversivo. Este es el resultado más limpio del experimento. Con contigüidad idéntica para los dos componentes, el sistema de defensa seleccionó uno y descartó el otro. La contigüidad no decidió qué se aprendió: la naturaleza del suceso biológicamente importante sí lo hizo.

En el grupo de enfermedad, el resultado es diferente en su estructura aunque paralelo en su forma: las ratas aprendieron a evitar el sabor, no el audiovisual. Pero la consecuencia llegó horas después —territorio completamente fuera del gradiente pavloviano. El aprendizaje ocurrió de todas maneras. La contigüidad no era condición necesaria. La explicación no está en el mecanismo sino en la función: para un omnívoro que puede ingerir toxinas naturales cuyo efecto tarda horas en manifestarse, un sistema de aprendizaje que requiriera contigüidad estricta entre sabor y malestar sería inútil. La selección natural produjo, en cambio, un sistema preparado para asociar sabores con consecuencias gastrointestinales a través de demoras que reflejan la firma temporal real de los venenos en el entorno ancestral.

Que la contigüidad no sea condición necesaria no significa que sea irrelevante. Estudios posteriores que variaron la demora entre la ingesta y el malestar encontraron un gradiente: la aversión aprendida era más intensa cuando el intervalo era más corto. Y cuando se presentaban dos sabores antes de inducir el malestar, la aversión se formaba con mayor fuerza hacia el sabor temporalmente más cercano a la consecuencia. El sistema de aprendizaje sigue siendo sensible a la proximidad temporal —pero la ventana dentro de la cual esa sensibilidad opera es mucho más ancha que la que Pavlov había descrito, y esa anchura es en sí misma una adaptación evolutiva.

A lo que acabamos de describir —la dependencia del tipo de estímulo que entra al espacio de candidatos respecto a la naturaleza del suceso biológicamente importante— se le conoce como el sesgo de **relevancia biológica**, también llamado *preparedness* en la literatura anglosajona.

12.5.1 La Relevancia Biológica Como Sesgo Evolutivo

Para las ratas omnívoras que viven principalmente en la oscuridad, cuando el suceso biológicamente importante es un malestar gastrointestinal, el espacio de candidatos relevantes está conformado por estímulos gustativos, no por estímulos visuales o auditivos. Al sentirnos mal del estómago, nosotros mismos hacemos lo mismo: lo primero que preguntamos es qué comimos, aunque nuestra última comida haya sido muchas horas antes. Rara vez nos preguntamos qué música escuchábamos.

Este sesgo no es arbitrario. Refleja la historia evolutiva de la especie y su nicho ecológico.

Para un omnívoro nocturno, la toxicidad de los alimentos se señala principalmente por el sabor; la visión no proporciona información confiable sobre toxicidad en entornos oscuros. Para las palomas, en cambio, que forrajea visualmente durante el día en ambientes abiertos, la dimensión relevante es la estimulación visual, no el sabor. Cuando a las palomas se les induce malestar gastrointestinal contiguo con una señal visual, aprenden la aversión con facilidad; no así cuando el estímulo es gustativo.

La coevolución entre aves y polillas tóxicas ilustra con elegancia cómo los sesgos de relevancia biológica y las señales en el entorno se moldean mutuamente a lo largo del tiempo. Algunas polillas evolucionaron toxicidad, y simultáneamente evolucionaron patrones de coloración llamativos —el aposematismo— que señalizan esa toxicidad de manera visualmente detectable. Las aves que aprenden rápidamente a asociar esos patrones visuales con el malestar sobreviven mejor. Y otro grupo de polillas no tóxicas evolucionó para imitar esos patrones, aprovechando el sesgo de relevancia biológica visual de las aves para evadir la depredación: el mimetismo batesiano. El sistema completo —toxicidad, coloración aposemática, sesgo de aprendizaje visual de las aves, mimetismo— es un ejemplo de cómo la selección natural moldea simultáneamente las señales en el entorno y los sesgos que las detectan.

12.5.2 El Sesgo de Novedad

Los estudios de García también revelaron un tercer sesgo: la **novedad**. Cuando antes de inducir el malestar gástrico se presenta a las ratas dos sabores —uno familiar, que han probado repetidamente en días previos, y uno novedoso, que prueban por primera vez—, ambos igualmente contiguos con la consecuencia, las ratas desarrollan aversión al sabor novedoso pero no al familiar. El sistema de aprendizaje prioriza estímulos que no han sido procesados previamente.

La lógica adaptativa es clara. Si un organismo ha consumido un alimento familiar múltiples veces sin consecuencias aversivas, la probabilidad de que ese alimento sea la causa de un episodio aislado de enfermedad es baja. En cambio, un alimento nuevo es un candidato más plausible. El sesgo hacia la novedad reduce la probabilidad de desarrollar aversiones incorrectas a alimentos seguros y dirige la búsqueda hacia los verdaderos culpables.

12.6 ¿Es la Contigüidad Condición Suficiente?

Hasta aquí hemos visto que la contigüidad, modulada por la relevancia biológica y la novedad, es suficiente para generar aprendizaje cuando hay un solo candidato presente y el suceso es genuinamente nuevo. Pero el entorno natural raramente presenta un solo estímulo a la vez. El perro callejero que encuentra comida percibe simultáneamente docenas de estímulos, todos igualmente contiguos con el hallazgo. Si la contigüidad fuera suficiente, el perro aprendería que todos y cada uno de esos estímulos predicen comida, lo cual sería inútil: un predictor que siempre está presente no discrimina nada.

La pregunta de si la contigüidad es condición suficiente se exploró sistemáticamente a finales de los años sesenta. La respuesta resultó ser negativa, de dos maneras distintas.

12.6.1 Ensombrecimiento: Los Estímulos Compiten

B. J. Reynolds realizó a finales de los años cincuenta un experimento sencillo con palomas. A dos palomas se les entrenó a discriminar entre dos teclas: una tecla positiva, que cuando era picada producía acceso al comedero, y una negativa, que no lo producía. Ambas teclas estaban iluminadas con compuestos de dos estímulos que variaban en forma y color: la tecla positiva mostraba un triángulo blanco sobre fondo rojo; la negativa, un círculo blanco sobre fondo verde. Después del entrenamiento, Reynolds presentó los cuatro estímulos por separado para determinar cuál había adquirido control sobre la conducta.




Figura 8.3. Ensombrecimiento en el experimento de Reynolds. Ambas palomas son entrenadas con el mismo compuesto posi. En prueba, cada paloma responde a un único componente: una al color, la otra a la forma. Ninguna responde a los dos. Los estímulos compiten por la asignación de crédito aunque ambos fueron igualmente contiguos con el refuerzo.

Figura 12.3: Ensombrecimiento en el experimento de Reynolds (1961).

Note

Descripción. Fase de entrenamiento: ambas palomas reciben el mismo compuesto positivo (triángulo blanco sobre fondo rojo → comida) y el mismo compuesto negativo (círculo blanco sobre fondo verde → nada). Fase de prueba: cada componente se presenta por separado. La paloma 1 responde al

fondo rojo pero no a la forma; la paloma 2 responde a la forma triangular pero no al color. Ninguna responde a ambos componentes del compuesto positivo, a pesar de que ambos fueron igualmente contiguos con el refuerzo durante el entrenamiento. Los estímulos compiten por la asignación de crédito.

El resultado fue que cada paloma respondía a solo uno de los dos componentes del compuesto positivo. Una paloma respondía al color rojo e ignoraba la forma; la otra respondía a la forma triangular e ignoraba el color. A pesar de que ambos elementos habían sido perfectamente contiguos con la recompensa durante el entrenamiento, solo uno de ellos adquirió control conductual en cada animal.

A este fenómeno se le llama **ensombrecimiento**: un elemento saliente del compuesto —más intenso, más novedoso, más contrastante— “ensombrece” el aprendizaje sobre elementos menos salientes. La implicación es fundamental: los estímulos no aprenden en paralelo de manera independiente. Compiten entre sí por la asignación de crédito. Lo que aprende uno afecta lo que puede aprender el otro.

Retomando el ejemplo del perro amenazante: si el perro te ataca, para algunos de ustedes el predictor establecido será el gruñido, para otros el color del pelaje, para otros la raza. Los factores que determinan cuál elemento gana la competencia incluyen la saliencia perceptual —qué tan intenso o contrastante es el estímulo— y las predisposiciones de relevancia biológica que acabamos de discutir. Lo que el ensombrecimiento establece es que esta competencia existe, y que ganarla no es simplemente cuestión de ser contiguo con el suceso.

12.6.2 Bloqueo: La Historia del Organismo Importa

Si el ensombrecimiento muestra que la contigüidad no basta cuando dos estímulos compiten simultáneamente, el experimento de bloqueo de Leon Kamin demuestra algo más llamativo: la historia previa de un estímulo puede suprimir completamente el aprendizaje sobre otro estímulo, incluso cuando ambos son igualmente contiguos con el suceso biológicamente importante.

El punto se entiende bien con un ejemplo cotidiano. Imagina que después de visitar varios restaurantes has aprendido que los manteles de tela son un buen predictor de la calidad de la comida. Visitas ahora un restaurante nuevo que tiene manteles de tela y, además, música clásica de fondo. La comida es igualmente buena. ¿Habrás aprendido que la música clásica predice buena comida? Para saberlo tendrías que observar si, al elegir entre dos restaurantes nuevos sin manteles de tela, preferirías el que tiene música clásica. La intuición sugiere que probablemente no. Una vez que el mantel de tela ya predecía perfectamente la buena comida, la música clásica no añadía información nueva.

Leon Kamin puso a prueba esta intuición en 1969 en uno de los experimentos más influyentes en la historia del estudio del aprendizaje. El diseño trabajó con dos grupos de ratas. Al grupo experimental se le entrenó primero con luz sola seguida de descarga eléctrica, hasta que la luz era un predictor establecido. Luego, ese mismo grupo recibió

presentaciones del compuesto luz más tono seguido de descarga. Al grupo control, se le presentó el compuesto desde el inicio, sin la fase previa con la luz. En ambos casos, la tercera fase consistió en presentar el tono solo para medir cuánto habían aprendido las ratas sobre él.




Figura 8.4. Diseño del experimento de bloqueo de Kamin. La única diferencia entre grupos es la Fase 1: el grupo experimental a la Fase 2 con la luz ya establecida como predictor. Pese a que el tono es igualmente contiguo con la descarga en ambos grupos solo el grupo control aprende sobre él. La contigüidad no es condición suficiente cuando el error de predicción es cero.

Figura 12.4: Diseño del experimento de bloqueo de Kamin (1969).

Note

Descripción. La única diferencia entre grupos es la Fase 1: el grupo experimental llega a la Fase 2 con la luz ya establecida como predictor de la descarga; el grupo control no tiene historia previa. En la Fase 2 ambos grupos reciben el compuesto luz+tono seguido de descarga. En la prueba, solo el grupo control muestra respuesta condicionada al tono. El tono es igualmente contiguo con la descarga en ambos grupos — la diferencia es que en el grupo experimental la luz ya predice perfectamente la descarga, el error de predicción es cero, y no hay nada nuevo que aprender.

Los resultados fueron claros. Las ratas del grupo control —que no tenían experiencia previa con la luz— aprendieron a responder al tono. Las del grupo experimental —cuya

luz ya era un predictor establecido— no mostraron prácticamente ningún aprendizaje sobre el tono. El término para este fenómeno es **bloqueo**: la experiencia previa con un predictor establecido bloquea el aprendizaje sobre nuevos estímulos incorporados al compuesto.

¿Por qué ocurre el bloqueo? La interpretación que el experimento sugiere es que las ratas del grupo experimental, al encontrar el compuesto luz más tono seguido de descarga, no se sorprenden: la luz ya predecía la descarga. No hay nada nuevo que aprender. El tono es informacionalmente redundante —su presencia o ausencia no modifica la predictibilidad del suceso. Y si no hay información nueva, no hay razón para modificar el sistema.

Esta interpretación revela algo profundo sobre la lógica del aprendizaje: el sistema no responde a la mera ocurrencia del suceso biológicamente importante, sino a la *sorpresa* que ese suceso produce. El aprendizaje es proporcional a la discrepancia entre lo que ocurrió y lo que se esperaba. Si la predicción era perfecta, el error es cero y no hay aprendizaje. Si ocurre algo inesperado, el error es distinto de cero y el sistema se actualiza. Kamin llamó a esta idea predictibilidad; en el capítulo siguiente la veremos formalizada con precisión matemática como **error de predicción**.

12.7 Optimalidad: ¿Cuándo Funciona la Contigüidad y Cuándo Falla?

Hemos descrito la contigüidad como un sesgo inductivo y hemos dicho que es el resultado de aprendizaje filogenético. Conviene ahora preguntarse con más precisión cuándo es una política óptima y cuándo no.

Un sesgo es óptimo cuando la estructura del entorno para el que fue diseñado coincide con la estructura del entorno donde se aplica. La contigüidad temporal como heurística para causalidad funciona bien cuando los mecanismos causales biológicamente relevantes producen sus efectos con rapidez. Considera los casos más frecuentes en el entorno ancestral de la mayoría de los animales: un depredador que ataca produce dolor en segundos; un alimento que desencadena saciedad lo hace en minutos; una pareja potencial que emite una señal está presente cuando la emite. En estos contextos, la relación causal tiene una firma temporal característica: el efecto sigue a la causa con relativa inmediatez. En esos entornos, la contigüidad es una heurística potente porque permite ignorar la inmensa mayoría del historial de eventos pasados y concentrar la búsqueda en los candidatos temporalmente recientes. El costo de ignorar candidatos lejanos en el tiempo es bajo, porque causas lejanas son improbables dado el tipo de mecanismos que operan.

Pensemos en el parámetro que controla la anchura del gradiente de la demora —qué tan rápido declina el aprendizaje conforme aumenta el intervalo entre estímulo y consecuencia. En los experimentos pavlovianos, ese parámetro está calibrado para intervalos de segundos a minutos. Esa calibración no es arbitraria: refleja la distribución real de demoras causales en el entorno ancestral. Un organismo con un gradiente demasiado estrecho —que solo aprende sobre eventos del último segundo— pierde muchas relaciones causales reales.

Uno con un gradiente demasiado amplio —que considera como candidatos todo lo que ocurrió en la última semana— incluye tanto ruido que el espacio de candidatos vuelve a ser inmanejable. El valor óptimo está en algún punto entre estos extremos, y ese punto depende de la distribución de demoras causales en el entorno.

El experimento de García es el contraejemplo perfecto al parámetro estándar. Las toxinas que producen malestar gastrointestinal tienen perfiles temporales peculiares: muchos venenos naturales requieren horas para ser absorbidos y producir síntomas. Un organismo cuyo gradiente de demora solo cubriera minutos sería incapaz de aprender a evitar la mayoría de los alimentos tóxicos en la naturaleza. La selección natural resolvió esto de manera elegante: para la clase específica de relación sabor-malestar gastrointestinal, el gradiente de la demora es mucho más ancho que para otras relaciones causales. Esto no contradice el principio general de la contigüidad —lo especializa: la anchura óptima del gradiente depende del mecanismo causal específico que se está detectando.

El sesgo de relevancia biológica opera, en este sentido, en dos niveles simultáneos. Por un lado, define qué dimensiones del estímulo son siquiera candidatos para la asignación de crédito dado el tipo de consecuencia: sabores para el malestar gastrointestinal en omnívoros, señales visuales para el dolor externo. Por otro, calibra la anchura del gradiente de demora para cada tipo de relación: estrecho donde el mecanismo causal es rápido —depredador y dolor—, amplio donde es lento —toxina y malestar—. Y el sistema nervioso ha sido construido para que esta calibración diferencial ocurra de manera automática, dependiendo del tipo de suceso biológicamente importante que activa el sistema de comportamiento relevante.

Nótese que esta es exactamente la lógica de los pasajes de optimalidad de los capítulos anteriores: el parámetro que controla la sensibilidad al error — b en kinesis, k en taxias— tiene un valor óptimo que depende del entorno, y la solución verdaderamente óptima es poder ajustar ese valor adaptativamente. La anchura del gradiente de la demora es otro parámetro con esta misma propiedad. La selección natural lo ha ajustado de manera diferenciada para diferentes clases de relaciones causales, pero ese ajuste es fijo para cada especie. El aprendizaje individual puede, dentro de ciertos límites, afinar esa calibración a las condiciones específicas del entorno del organismo.

•

Básico. Antes de correr el simulador, predice: ¿a qué intervalo habrá caído la fuerza de condicionamiento a la mitad en cada preparación? Verifica tu predicción con el gráfico. (Pista: cuando $\exp(-t/\tau) = 0.5$, despeja t .)

Intermedio. Modifica `tau_pavlov` a 5, 15 y 60 segundos. Para cada valor, describe el tipo de entorno —¿qué clase de mecanismos causales predominan?— que haría óptimo ese gradiente. ¿Qué costo paga el organismo con un tau demasiado estrecho? ¿Y con uno demasiado amplio?

Avanzado. Diseña una “especie” con dos parámetros tau independientes: uno estrecho para relaciones audiovisuales y uno amplio para relaciones gustativas. ¿Cuándo y por

cuánto supera la especie especializada a la generalista?

Básico. En el escenario de bloqueo, el estímulo B es tan contiguo con el EI como el estímulo A durante la Fase 2. ¿Por qué no aprende? Observa el valor de la variable **error** al inicio de la Fase 2 y explica qué ocurre con él.

Intermedio. Modifica el experimento de bloqueo de modo que **lam** cambie de 1.0 a 1.5 en la Fase 2 —el EI se vuelve más intenso. ¿Qué ocurre ahora con B? Este resultado tiene un nombre en la literatura experimental (el “desbloqueo”). ¿Por qué tiene sentido desde la perspectiva del error de predicción?

Avanzado. El ensombrecimiento depende de la diferencia en **alpha_A** y **alpha_B**. Encuentra el valor mínimo de esa diferencia para que el ensombrecimiento sea “completo” —es decir, para que B aprenda menos del 10% del máximo posible. ¿Cómo depende ese umbral del valor de **beta**? ¿Qué dice esto sobre la interacción entre saliencia del estímulo y tasa de aprendizaje del EI?

12.8 Hacia el Modelo Formal

Los experimentos de Pavlov, García, Reynolds y Kamin describen, en conjunto, un sistema de aprendizaje con propiedades precisas. Es sensible a la contigüidad, pero no esclavamente. Está modulado por la relevancia biológica del suceso. Procesa estímulos en competencia, no de manera independiente. Y su motor no es la mera co-ocurrencia de un estímulo con un suceso, sino la información que ese estímulo aporta sobre la predicción de ese suceso.

Estos hechos no son una colección de curiosidades —son las restricciones que debe satisfacer cualquier modelo formal del aprendizaje asociativo. El bloqueo, en particular, plantea un desafío conceptual preciso: ¿por qué un estímulo contiguo con un suceso biológicamente importante no aprende nada, si ese suceso ocurrió? La respuesta que los experimentos sugieren es que el sistema no responde a la ocurrencia del suceso —responde a la *sorpresa* que ese suceso produce. Si el suceso ya estaba predicho, su ocurrencia no es sorprendente y no hay información nueva que incorporar. El tonto no aprende en el experimento de Kamin porque el error de predicción es cero: la luz ya predecía perfectamente la descarga, y la descarga ocurrió exactamente como se esperaba.

Esta intuición se formaliza de manera precisa en el modelo propuesto por Bush y Mosteller en 1951, que estudiaremos en el capítulo siguiente. El modelo parte de una idea simple: lo que controla el aprendizaje no es el valor absoluto del suceso biológicamente importante, sino la discrepancia entre el suceso obtenido y el suceso predicho —el error de predicción. Cuando la predicción es perfecta, el error es cero y no hay aprendizaje. Cuando hay sorpresa, el error es distinto de cero y el sistema se actualiza.

Noten la conexión con lo que ya conocen. El error de predicción es la misma operación que la señal de error en los sistemas de retroalimentación del capítulo 5: la discrepancia entre el estado deseado y el estado actual. Y es la misma operación que aparece en la ecuación de Price: la diferencia entre el rasgo del individuo y el promedio de la población, ponderada por el éxito relativo. El mismo principio reaparece ahora en el aprendizaje asociativo. El capítulo siguiente formaliza ese principio y muestra cómo una ecuación sorprendentemente simple captura el ensombrecimiento, el bloqueo, la extinción y docenas de otros fenómenos del condicionamiento clásico.

12.9 Conexiones

12.9.1 Hacia atrás: Selección Natural y Retroalimentación

Los sesgos inductivos son el resultado directo del proceso que describimos en el capítulo sobre selección natural. El genoma, actuando como archivo causal acumulado a lo largo de generaciones, codifica las regularidades estadísticas del entorno ancestral en forma de predisposiciones a aprender ciertas relaciones más fácilmente que otras. La ecuación de Price es el mecanismo mediante el cual esos sesgos fueron refinados: los organismos con sesgos mejor calibrados al entorno dejaron más descendientes, y esa covarianza entre el sesgo y el éxito reproductivo produjo el ajuste acumulativo que observamos hoy.

La señal de error en los sistemas de retroalimentación —la discrepancia entre el set point y el valor actual— es la misma operación que ahora reaparece como error de predicción: la discrepancia entre lo que el organismo esperaba y lo que ocurrió. La arquitectura es la misma; cambia el tipo de variable que se compara.

12.9.2 Hacia adelante: Asignación de Crédito a Respuestas (Capítulo 9)

El problema que hemos abordado en este capítulo es la asignación de crédito a estímulos: ¿qué eventos del entorno predicen el suceso biológicamente importante? El capítulo 9 plantea el problema análogo para respuestas: ¿qué acciones del organismo *producen* ese suceso? Los principios son estructuralmente similares —contigüidad, relevancia, novedad, competencia— pero el hecho de que el organismo mismo genera la variabilidad sobre la que opera la selección introduce complejidades adicionales. El trabajo de Staddon y Simmelhag que veremos en ese capítulo conecta directamente con la teoría de sistemas de comportamiento introducida aquí.

12.9.3 Hacia adelante: Bush y Mosteller y el Error de Predicción (Capítulo 10)

El bloqueo de Kamin establece la evidencia central que motiva el primer modelo formal del aprendizaje asociativo. El aprendizaje no responde a la ocurrencia del suceso biológi-

camente importante sino a la *sorpres*a que ese suceso produce —la discrepancia entre lo que ocurrió y lo que el organismo esperaba. En 1951, Bush y Mosteller formalizaron esa intuición en una ecuación de actualización cuya estructura es simple: el valor de un estímulo se ajusta en cada ensayo en proporción a esa discrepancia. La velocidad del ajuste está controlada por un parámetro que cumple la misma función que b en kinesis y k en taxias: determinar qué tanto le importa al sistema la diferencia entre predicción y resultado. El capítulo 8 desarrolla ese modelo a partir de los datos sobre aprendizaje de estímulos que hemos visto aquí.

12.9.4 Hacia adelante: Rescorla-Wagner y la Competencia entre Estímulos (Capítulo 11)

El modelo de Bush y Mosteller captura el error de predicción para un estímulo en solitario, pero no deriva el bloqueo. El bloqueo requiere algo adicional: que el error de predicción no se calcule sobre el valor de un estímulo individual sino sobre la suma de los valores de *todos* los estímulos presentes simultáneamente. Esa extensión —propuesta por Rescorla y Wagner en 1972— convierte la competencia entre estímulos en una consecuencia matemática de la ecuación, no en un supuesto adicional. Cuando A ya predice perfectamente el suceso biológicamente importante, la suma de valores iguala al máximo posible, el error es cero, y B no aprende nada aunque sea perfectamente contiguo. El capítulo 11 examina ese modelo y sus consecuencias, que van bastante más lejos del bloqueo.

12.10 Resumen

El problema de la asignación de crédito pregunta cuál de los innumerables eventos que preceden a un suceso biológicamente importante merece ser identificado como su predictor. El espacio de candidatos es enorme, y sin guía la búsqueda es computacionalmente intratable.

Los organismos resuelven este problema con una cascada de sesgos inductivos que operan en distintos niveles. El primer filtro lo proporcionan los sistemas de comportamiento: el tipo de suceso biológicamente importante activa el sistema funcionalmente apropiado, y ese sistema determina qué dimensiones del entorno son siquiera relevantes. Dentro del sistema activo, la contigüidad temporal opera como primer sesgo: los eventos cercanos en el tiempo son candidatos prioritarios porque la mayoría de los mecanismos causales biológicamente relevantes operan con rapidez. La relevancia biológica especifica adicionalmente qué dimensiones del estímulo —sabor, sonido, imagen— son más probables de ser causalmente relevantes para cada tipo de consecuencia, reflejando la historia evolutiva de la especie en su nicho ecológico particular. La novedad prioriza estímulos nuevos sobre familiares, porque causas nuevas son más plausibles para efectos nuevos.

Pero la contigüidad no es ni necesaria ni suficiente. No es necesaria porque las aversiones al sabor demuestran que se puede aprender con demoras de horas. No es suficiente porque el ensombrecimiento y el bloqueo demuestran que la contigüidad no garantiza aprendizaje cuando hay competencia entre estímulos. El principio subyacente, que el bloqueo de Kamin revela con especial claridad, es que el aprendizaje no es proporcional a la ocurrencia del suceso sino a la sorpresa que ese suceso produce —la discrepancia entre lo que ocurrió y lo que el organismo esperaba. Esa discrepancia es el error de predicción, concepto que los capítulos 8 y 9 formalizarán en dos pasos: primero para estímulos individuales, luego para estímulos en competencia.

12.11 Ejercicios

1. El capítulo propone que los sesgos inductivos son “conocimiento filogenético sobre la estructura causal del mundo”. Explica con tus propias palabras qué significa esto. ¿Qué tendría que haber sido cierto en el entorno ancestral de los roedores omnívoros para que el sesgo de relevancia biológica gustativa —buscar la causa del malestar gastrointestinal en los sabores recientes— haya evolucionado? ¿Qué tipo de entorno haría desadaptativo ese mismo sesgo?
2. El experimento de García usó un compuesto de sabor + estímulo audiovisual. Las ratas con malestar gastrointestinal aprendieron a evitar el sabor pero no el estímulo audiovisual; las ratas con descarga eléctrica hicieron lo contrario. Reformula este resultado en términos de sistemas de comportamiento: ¿qué sistema activa cada tipo de consecuencia, y cómo determina ese sistema qué dimensiones del estímulo entran en el espacio de candidatos? En el grupo de descarga, ambos componentes del compuesto eran igualmente contiguos con el shock; en el grupo de enfermedad, la consecuencia llegó horas después. ¿Cambia esta asimetría de demoras la interpretación del resultado en términos de sistemas de comportamiento, o el fenómeno es el mismo independientemente de la demora? Justifica tu respuesta.
3. El gradiente de la demora tiene un valor óptimo que depende del tipo de mecanismo causal. Para cada uno de los siguientes pares causa-efecto, razona cuál sería el rango de demoras que debería cubrir el gradiente óptimo, y por qué: (a) depredador → ataque, (b) toxina de digestión lenta → malestar, (c) pareja potencial → apareamiento. ¿Qué predice este análisis sobre las diferencias entre especies con dietas o nichos ecológicos distintos?
4. En el experimento de bloqueo de Kamin, el grupo control aprende sobre el tono aunque el tono es igualmente contiguo con la descarga para ambos grupos. Usa el concepto de error de predicción para explicar por qué el grupo control aprende y el experimental no. Luego predice qué ocurriría si en la Fase 2 del experimento la descarga fuera el doble de intensa que en la Fase 1. ¿Cambiaría el resultado para el grupo experimental? ¿Por qué?
5. Usa el Simulador 6.2 para explorar qué ocurre cuando λ cambia de 1.0 a 1.5 en la Fase 2 del bloqueo. Este resultado, llamado “desbloqueo”, fue una de las primeras

evidencias experimentales a favor del modelo de Rescorla-Wagner. Explica en términos intuitivos —sin la ecuación formal, que veremos en el siguiente capítulo— por qué el cambio en la intensidad del EI “desbloquea” el aprendizaje sobre el estímulo que había sido bloqueado.

6. (Reflexión) El capítulo afirma que los sesgos inductivos son soluciones evolutivas a un problema computacional real, no limitaciones arbitrarias. Pero también pueden producir errores sistemáticos cuando el organismo se encuentra en un entorno diferente del ancestral. Describe dos situaciones del entorno humano contemporáneo en que los sesgos de contigüidad o relevancia biológica llevan a conclusiones erróneas sobre la causalidad. ¿Qué tienen en común esas situaciones? ¿Qué dice esto sobre el alcance y los límites del aprendizaje filogenético?

12.12 Lecturas Recomendadas

García, J., & Koelling, R. A. (1966). Relation of cue to consequence in avoidance learning. *Psychonomic Science*, 4, 123–124. — El artículo original en dos páginas. Imprescindible por su claridad y porque el experimento habla por sí mismo.

Kamin, L. J. (1969). Predictability, surprise, attention, and conditioning. En B. A. Campbell & R. M. Church (Eds.), *Punishment and Aversive Behavior*. Appleton-Century-Crofts. — El experimento original del bloqueo con el análisis conceptual completo. Accesible y con la lógica del experimento explicada paso a paso.

Seligman, M. E. P. (1970). On the generality of the laws of learning. *Psychological Review*, 77, 406–418. — El artículo que sistematizó la evidencia de relevancia biológica y acuñó el término *preparedness*. Vista panorámica más allá de los experimentos individuales.

Timberlake, W., & Lucas, G. A. (1989). Behavior systems and learning: From misbehavior to general principles. En S. B. Klein & R. R. Mowrer (Eds.), *Contemporary Learning Theories*. Erlbaum. — La exposición más accesible del enfoque de sistemas de comportamiento aplicado al aprendizaje.

Domjan, M. (2005). Pavlovian conditioning: A functional perspective. *Annual Review of Psychology*, 56, 179–206. — Revisión de cómo los principios del condicionamiento reflejan soluciones evolutivas a problemas adaptativos. Nivel moderado; muy recomendable como lectura de integración después de este capítulo.

|

|

13 El Problema de la Asignación de Crédito (II)

13.1 Acciones, Inducción y el Problema del Control

Al final del capítulo anterior dejamos al organismo en posesión de una capacidad importante pero parcial: puede predecir cuándo va a llover mirando el cielo, puede anticipar el ataque de un depredador al escuchar su rugido, puede aprender que ciertos sabores preceden al malestar. Esa capacidad predictiva tiene un valor enorme, pero tiene también un límite preciso: el organismo no controla el cielo, no controla la presencia del depredador, no controla los sabores que encuentra. Puede prepararse para lo que viene, pero no puede alterar lo que viene.

Uno de los saltos más importantes en la historia evolutiva fue la emergencia de mecanismos que, a través de la acción y la interacción con el entorno, permiten a los organismos no solo predecir sino *controlar* la ocurrencia de sucesos biológicamente importantes. Un organismo que aprende no solo que el cielo nublado anuncia lluvia, sino que *llevar paraguas* produce la consecuencia de llegar seco, ha adquirido algo cualitativamente distinto. La lluvia sigue siendo independiente de él; pero la consecuencia de llegar empapado ya no lo es. Entre la acción del organismo y el resultado hay ahora una relación de dependencia que puede ser aprendida, explotada y perfeccionada.

Este es el problema adaptativo que nos ocupa: ¿cómo aprende un organismo que sus propias acciones producen sucesos biológicamente importantes? Y, antes de eso, ¿de dónde vienen las acciones entre las que puede elegir?

13.2 Thorndike y dos preguntas que se confundieron durante décadas

A principios del siglo XX, Edward Thorndike encerró gatos en cajas de escape desde las que el animal podía salir accionando un cerrojo, tirando de una cuerda o pisando una palanca. El patrón fue consistente: al inicio los gatos tardaban mucho, probando un repertorio amplio de respuestas antes de dar con la correcta por casualidad; con la repetición, ese tiempo disminuía hasta que el animal accionaba el dispositivo casi inmediatamente. Thorndike llamó a esto aprendizaje por *ensayo y error*.

Pero los datos contienen dos observaciones distintas. La primera: el gato *hace algo* al ser encerrado. No se queda inmóvil, no selecciona al azar de toda la gama posible de movimientos de un cuerpo en el espacio. Explora, araña, empuja, vocaliza —respuestas

apropiadas a la situación de escape, no al cortejo ni a la alimentación. La segunda: de ese repertorio inicial, el animal selecciona progresivamente la respuesta que abre la caja. Son fenómenos distintos: uno sobre el origen de la variabilidad conductual, otro sobre su selección.

La *Ley del Efecto* de Thorndike intentó responderlos con el mismo principio: *una respuesta seguida de un estado de cosas satisfactorio queda asociada con la situación y aumenta su probabilidad futura*. La contigüidad temporal era, para Thorndike, tanto condición suficiente como necesaria. Esa confusión costó décadas.

13.3 El primer sesgo: la inducción de respuestas por el SBI

Retomemos el lenguaje del capítulo anterior. Los sesgos inductivos que hacen manejable el problema de la asignación de crédito operan en dos niveles distintos. El primero delimita el espacio de candidatos: ¿qué respuestas son siquiera consideradas? El segundo establece el orden de prioridad dentro de ese espacio reducido: ¿cuál se evalúa primero?

La Ley del Efecto, como señalamos, se concentra casi exclusivamente en el segundo nivel —la contigüidad como criterio de selección— y deja sin respuesta la pregunta del primer nivel. ¿De dónde viene el repertorio inicial de respuestas sobre el que opera la selección? La respuesta emergió de una dirección que Thorndike no anticipó. La mera presentación de un suceso biológicamente importante *induce* en el organismo un conjunto de respuestas características: las apropiadas para interactuar con ese tipo de consecuencia. No son respuestas arbitrarias del espacio motor completo, sino un subconjunto organizado funcionalmente. La comida induce comportamientos de consumación y búsqueda alimentaria. Una amenaza induce comportamientos de escape y evitación. Un posible compañero reproductivo induce comportamientos de cortejo. Como vimos en el capítulo 6, estas respuestas inducidas se organizan en los sistemas de comportamiento que Hogan y Timberlake describieron: el SBI activa el sistema funcionalmente apropiado, y ese sistema pre-configura el espacio de respuestas candidatas.

Pero el sistema de comportamiento no actúa en el vacío. ¿Qué respuestas quedan disponibles depende también de qué oportunidades de acción ofrece el entorno físico en ese momento. Una paloma ante un comedero no ejecuta el mismo conjunto de respuestas alimentarias que una paloma en campo abierto, aunque el SBI sea idéntico. El entorno no es un telón de fondo neutro: estructura activamente qué respuestas son posibles y cuáles no. Piensen en cómo cambia su comportamiento al entrar a una biblioteca frente a entrar a un gimnasio, aunque lleguen con el mismo objetivo. El concepto de *affordance* —que exploraremos con detalle en capítulos posteriores— captura esta idea: las propiedades del entorno que hacen posibles ciertas acciones y no otras. Por ahora basta notar que el repertorio inducido no es solo función del SBI; es función del SBI *en ese entorno particular*.

Este principio de inducción fue reconocido tempranamente en la literatura del aprendizaje pero tardó en articularse con precisión formal. Volveremos a él cuando lleguemos a los

programas de refuerzo y la igualación. Por ahora, la observación empírica clave provino de un experimento diseñado para examinar la explicación de Skinner sobre un fenómeno curioso: la “superstición” en palomas.

13.4 El experimento de Skinner y la réplica de Staddon y Simmelhag

En 1948, Skinner publicó un experimento que se volvería célebre. A palomas hambrientas se les presentaba comida cada quince segundos, completamente independiente de su comportamiento. Y sin embargo, muchas aves desarrollaron comportamientos estereotipados: una giraba en círculos, otra movía la cabeza rítmicamente, otra se desplazaba en diagonal. El comportamiento difería entre individuos.

La interpretación de Skinner fue directa: para cada paloma, alguna respuesta había ocurrido accidentalmente inmediatamente antes de la entrega de comida, y esa contigüidad accidental era suficiente para fortalecerla. El animal no necesitaba detectar ninguna relación real entre su conducta y el resultado; bastaba la proximidad temporal para producir el aprendizaje. Para Skinner, la contigüidad temporal era el mecanismo: un reforzador era “contingente” sobre una respuesta en el único sentido de que la seguía en el tiempo. El experimento de superstición era su demostración más limpia.

Staddon y Simmelhag no estuvieron de acuerdo, y en 1971 publicaron una réplica que cambiaría la discusión. Usaron el mismo procedimiento básico de Skinner —comida cada quince segundos independiente del comportamiento— pero observaron cuidadosamente qué hacían las palomas *a lo largo de todo el intervalo*, no solo en el momento inmediatamente anterior a la comida. Los resultados desmontaron la narrativa de Skinner en dos frentes. Primero, el comportamiento no difería arbitrariamente entre palomas: era predecible. Al final del intervalo, cerca del momento de entrega de la comida, prácticamente todas las palomas mostraban el mismo tipo de respuestas —orientarse hacia la pared del comedero, picotear en esa dirección. Staddon y Simmelhag llamaron a estas “respuestas terminales”. Inmediatamente después de recibir la comida, y durante la primera mitad del intervalo siguiente, aparecían respuestas muy distintas —explorar el piso, dar giros, desplazarse— que estos autores llamaron “respuestas interinas”. La figura 7.1 muestra esta distribución temporal con claridad.

Figura 7.1 — Organización temporal de respuestas inducidas
(Datos: Staddon & Simmelhag, 1971)




Figura 13.1: Organización temporal de respuestas inducidas

Note

Descripción. Eje horizontal: tiempo en el intervalo entre entregas de comida (0–12 seg). Eje vertical: probabilidad de ocurrencia. Líneas sólidas negras: respuestas terminales (orientarse al comedero, picotear la pared) — crecen conforme se acerca el SBI y alcanzan su máximo en $t = 12$. Líneas punteadas grises: respuestas interinas (picotear el piso, dar giros, desplazarse) — alcanzan su máximo en la primera mitad del intervalo y declinan antes del SBI. Línea vertical verde punteada: momento de entrega de comida. Datos de Staddon y Simmelhag (1971).

Segundo, el patrón no era el que predice la contingüidad accidental. Si la contingüidad fuera el mecanismo, las respuestas que aparecen justo antes de la comida —las terminales— deberían ser las que más varían entre individuos, porque dependen de qué estaba haciendo

cada paloma en ese momento preciso por azar. Pero ocurrió exactamente lo contrario: las respuestas terminales eran las más consistentes entre animales. Las interinas, que ocurren lejos temporalmente de la comida, eran las que mostraban más variación.

La conclusión fue clara: sin ninguna relación de dependencia entre respuesta y comida, la mera contigüidad accidental no explicaba el patrón observado. Lo que sí lo explicaba era el principio de inducción: la presentación periódica de un SBI alimenticio induce el conjunto de respuestas apropiadas para ese SBI, y la periodicidad temporal organiza esas respuestas a lo largo del intervalo. Las terminales reflejan la activación anticipatoria del sistema de alimentación conforme se acerca el momento de la comida; las interinas son comportamientos de actividad general inducidos por la llegada del SBI que van diluyéndose en el tiempo. El comportamiento observado por Skinner no era aprendizaje por contigüidad accidental —era inducción organizada temporalmente. La contigüidad, como condición suficiente para asignar crédito a una respuesta, no se sostiene.

13.5 ¿Es la contigüidad una condición necesaria?

El experimento de Skinner eliminaba la relación de dependencia entre respuesta y SBI. Los experimentos que siguen hacen lo contrario: mantienen esa relación de dependencia pero manipulan la *demora* entre la respuesta y el SBI. Si la contigüidad fuera necesaria, una demora suficientemente larga debería hacer imposible el aprendizaje. La pregunta es cuánta demora puede tolerarse.

La estrategia experimental adoptó como punto de referencia la contigüidad estricta —demora de cero segundos— y exploró qué ocurre cuando ese intervalo se extiende progresivamente. Pero antes de describir los resultados, conviene apreciar un problema metodológico que hacía difícil interpretar estos experimentos con demora. Si el animal puede seguir respondiendo durante el periodo de demora, sus respuestas adicionales pueden quedar accidentalmente contiguas con el SBI que fue producido por una respuesta anterior. ¿Cómo distinguir entonces si el aprendizaje se debe a la relación de dependencia original —la respuesta que inició el contador— o a esas contigüidades accidentales posteriores?

Dickinson y sus colaboradores diseñaron un procedimiento que abordó exactamente esta dificultad. Las ratas tenían una palanca disponible y el tiempo de la sesión se dividía en intervalos de un segundo. En cada segundo, el animal tenía la oportunidad de presionar la palanca. Cuando lo hacía, se iniciaba un periodo de demora de duración programada, al final del cual se entregaba la comida. El problema es que durante ese periodo de demora el animal podía volver a presionar la palanca, y cada nueva presión iniciaba un contador adicional —lo que creaba la posibilidad de que alguna presión quedara accidentalmente contigua con la comida producida por una presión anterior.

Para resolver esta ambigüedad, Dickinson incluyó un segundo grupo de ratas —el grupo *yoked* o apareado— que recibía exactamente los mismos refuerzos, en los mismos momentos, que el grupo experimental, pero sin ninguna relación de dependencia entre su comportamiento y esa entrega. Si el aprendizaje observado en el grupo experimental se

debiera solo a las contigüidades accidentales dentro del periodo de demora, el grupo yoked debería aprender igual —porque experimentaba las mismas contigüidades accidentales, distribuidas del mismo modo en el tiempo. Si el grupo experimental aprendía más, eso indicaba que la relación de dependencia contribuía al aprendizaje más allá de las contigüidades accidentales.

Con demoras de hasta dieciséis segundos, el grupo experimental aprendió claramente; el grupo yoked no lo hizo. Con treinta y dos segundos, el experimental seguía respondiendo más, aunque más lento. A sesenta y cuatro segundos, ambos grupos fueron indistinguibles.

Figura 7.2 — Dickinson et al. (1992)




Figura 13.2: Resultados de Dickinson et al. (1992)

Note

Descripción. Panel izquierdo: tasa de respuesta (presiones de palanca por minuto) como función de la demora programada (0, 4, 8, 16, 32, 64 segundos) — curva decreciente. Panel derecho: curvas de adquisición para el grupo experimental (master) y el grupo apareado (yoked) en condiciones de 16 y 32 segundos de demora. Las curvas del grupo experimental crecen a lo largo de las sesiones; las del grupo yoked permanecen en valores bajos. La disociación entre los dos grupos demuestra que el aprendizaje se debe a la relación de dependencia, no a contigüidades accidentales durante la demora. Datos de Dickinson et al. (1992).

Hay dos conclusiones en estos datos. La primera es que la contigüidad estricta no es

necesaria: el organismo puede aprender la relación entre su respuesta y la comida incluso cuando hay treinta y dos segundos entre ellas, y ese aprendizaje no se debe a contigüidades accidentales sino a la relación de dependencia en sí misma. La segunda es que la demora importa: mientras más larga sea, más lento y débil es el aprendizaje. La contigüidad no es la llave del aprendizaje, pero es un facilitador poderoso.

Lattal fue aún más lejos en el experimento diseñado para eliminar cualquier posibilidad de contigüidad accidental. Sus palomas recibían comida, en promedio, cada treinta segundos —pero solo si habían transcurrido diez segundos desde la última respuesta. Si el animal respondía antes de que pasaran esos diez segundos, el contador se reiniciaba. Este procedimiento, conocido como DRO (*differential reinforcement of other behavior*), garantiza que la comida nunca puede seguir inmediatamente a una respuesta: siempre habrá una separación mínima de diez segundos. En ningún sentido ordinario del término puede decirse que hay contigüidad entre respuesta y SBI.

Y sin embargo, las palomas de Lattal aprendieron. La tasa de picoteo de la tecla aumentó claramente por encima de la línea base en cinco de los cinco sujetos del experimento, como muestra la figura 7.3. El animal aprendió a picar la tecla a pesar de que esa tecla nunca fue inmediatamente seguida de comida —a pesar de que, estrictamente hablando, el procedimiento estaba diseñado para que hubiera una separación garantizada. Si Dickinson mostró que la contigüidad no es necesaria con demoras de decenas de segundos, Lattal mostró que no lo es incluso cuando se elimina por diseño.

Figura 7.3 — Lattal (1987): Aprendizaje bajo DRO (demora ≥ 10 seg)




Figura 13.3: Resultados de Lattal (1987)

Note

Descripción . Cinco paneles, uno por sujeto (palomas 3490, 3494, 3538, 3630, 4230). Eje horizontal: sesiones sucesivas. Eje vertical: tasa de respuesta en escala logarítmica. Línea punteada horizontal: tasa de referencia. En todos los sujetos la tasa de picoteo aumenta claramente por encima de la línea de referencia a pesar de que el procedimiento DRO garantizaba una separación mínima de 10 segundos entre cualquier respuesta y la comida. Datos de Lattal (1987).

La misma conclusión a la que llegamos en el capítulo anterior para los estímulos se aplica aquí para las respuestas. Ni necesaria ni suficiente —pero no irrelevante. Lo que los organismos hacen, más que registrar proximidad temporal entre eventos discretos, es detectar una relación estadística a lo largo del tiempo: que la tasa de SBIs es mayor cuando cierta respuesta ocurre que cuando no ocurre. La contigüidad es un correlato frecuente de esa relación causal real, y por eso sirve como heurístico útil en muchas circunstancias. Pero no es la relación causal misma.

13.6 Perspectiva molecular y perspectiva molar

Este cambio de énfasis —de eventos individuales a relaciones estadísticas— tiene un nombre en la literatura: es el contraste entre las perspectivas molecular y molar del aprendizaje instrumental.

La perspectiva molecular examina pares de eventos individuales: esta respuesta fue seguida de este SBI a tal distancia temporal. Es la perspectiva que subyace a la idea de contigüidad: lo que importa es la proximidad de cada par de eventos. La perspectiva molar, en cambio, examina la covariación entre patrones de actividad y tasas de resultados a lo largo de períodos extendidos: ¿cuál es la tasa de SBIs durante los períodos en que el organismo ejecuta esta respuesta, comparada con la tasa durante los períodos en que no la ejecuta?

La evidencia de Dickinson y Lattal habla a favor del nivel molar como el nivel apropiado de análisis. El organismo no parece llevar un registro de pares respuesta-SBI; parece integrar información sobre covariaciones a lo largo de ventanas temporales amplias. Esta integración es lo que hace posible el aprendizaje con demoras de decenas de segundos: la demora individual entre respuesta y consecuencia no destruye el aprendizaje porque la covariación estadística persiste a escalas de tiempo más largas.

Veremos esta distinción reaparecer con más fuerza cuando lleguemos al tema de los programas de refuerzo y la igualación, donde las teorías moleculares predicen patrones de respuesta constantes dentro del intervalo, mientras que las teorías molares predicen que lo que el organismo maximiza es la tasa de SBIs a lo largo de períodos extendidos —predicciones que divergen de manera empíricamente resoluble.

13.7 La percepción de causalidad: el experimento de Killeen

Hasta aquí hemos argumentado que los organismos son sensibles a la covariación estadística entre sus respuestas y los SBIs. Pero ¿cómo sería posible demostrarlo directamente, en lugar de inferirlo de los experimentos de demora? Killeen diseñó una manera ingeniosa. Sus palomas tenían ante sí una tecla central iluminada. Podían picotearla, y con una probabilidad de 0.05, ese picotazo apagaba la tecla central y encendía dos teclas laterales. Hasta aquí, un procedimiento de aprendizaje ordinario. Pero Killeen añadió un elemento crucial: al mismo tiempo que las palomas picoteaban, una computadora generaba “pseudo-picotazos” a la misma tasa, y esos pseudo-picotazos tenían también una probabilidad de 0.05 de apagar la tecla central.

En cualquier momento en que la tecla central se apagaba, podía haber ocurrido por una de dos razones: porque la paloma acababa de picarla, o porque la computadora generó un pseudo-picotazo. La tarea para las palomas era discriminar entre estas dos posibilidades. Si el apagado lo había causado su propio picotazo, picar la tecla derecha producía acceso a comida. Si el apagado era independiente de su respuesta, picar la tecla izquierda producía comida. Acertar —identificar correctamente que el apagado fue consecuencia del picotazo

propio— se llama un *acierto* o *hit*. Confundir un apagado independiente con uno causado por la propia respuesta se llama *falsa alarma*.

Lo que hace este diseño particularmente poderoso es que permite separar dos cosas que normalmente van juntas: la capacidad real para detectar causalidad, y el criterio de decisión que el organismo adopta dados los pagos asociados a acertar y equivocarse. Killeen varió la cantidad de comida que las palomas recibían tras un acierto, manteniendo constante el costo de las falsas alarmas.

El primer resultado fue que las palomas son detectoras genuinas de causalidad. Sus curvas de características operativas del receptor —las curvas ROC que grafican la tasa de aciertos contra la tasa de falsas alarmas bajo diferentes criterios de decisión— se ubicaron consistentemente por encima de la diagonal del azar. Las palomas discriminaron entre consecuencias que dependían de sus propias respuestas y consecuencias que no, con una precisión aproximada del 80% en los ensayos. No son detectores perfectos, pero sí funcionan claramente mejor que el azar.




Figura 13.4: Resultados de Killeen (1978)

Note

Descripción Panel izquierdo: Curvas ROC para cuatro palomas en el experimento de Killeen (1978). Eje horizontal: P(falsa alarma). Eje vertical: P(acierto). Línea punteada diagonal: rendimiento al azar. Las curvas de los cuatro sujetos se ubican por encima de la diagonal; la discriminabilidad fue de aproximadamente el 80% en los ensayos. Cada punto corresponde a

una condición distinta de pago. Panel derecho: Eje horizontal: tiempo entre la respuesta de la paloma y el evento no contingente (0.2 a 1.0 segundos). Eje vertical: $P(\text{falsa alarma})$. Cuatro curvas, una por condición de pago (1.8, 2.3, 2.8 y 3.8 segundos de acceso a comida). En todas las condiciones, la probabilidad de falsa alarma disminuye conforme aumenta la separación temporal. Datos de Killeen (1978)

El segundo resultado es que el criterio de decisión es flexible y sensible a los pagos. Cuando los aciertos valían mucha comida, las palomas adoptaban un criterio liberal: respondían con frecuencia que el apagado había sido causado por ellas, lo que incrementaba tanto los aciertos como las falsas alarmas. Cuando los aciertos valían poca comida, el criterio se volvía conservador. Es exactamente lo que haría un observador racional que maximiza la ganancia esperada: si detectar causalidad cuando existe vale mucho y el costo de una falsa alarma es bajo, conviene ser generoso en las atribuciones causales. Si acertar vale poco o equivocarse es costoso, conviene ser conservador.

El tercer resultado es quizás el más revelador para la discusión sobre contigüidad. Killeen también hizo algo que vale la pena que ustedes ponderen antes de ver el resultado. Varió el tiempo transcurrido entre la respuesta de la paloma y el apagado de luz *no contingente* —es decir, el tiempo entre la respuesta y el evento accidental posterior. La probabilidad de falsa alarma disminuye sistemáticamente conforme ese intervalo se alarga, desde 0.2 segundos hasta 1.0 segundos. ¿Por qué? Porque la contigüidad temporal opera como señal de posible causalidad —y a mayor distancia temporal, la señal se debilita. No es un mecanismo determinístico; es un heurístico que disminuye con la demora.

El cuadro que emerge de los tres experimentos —Dickinson, Lattal y Killeen— es consistente. Los organismos son detectores de contingencia estadística dotados de un sistema de decisión ajustable. Integran información a lo largo de ventanas temporales amplias para estimar si sus respuestas covarian con los SBIs. Utilizan la proximidad temporal como heurístico —y por eso son susceptibles a falsas alarmas cuando eventos accidentales quedan cerca de sus respuestas. Y calibran su criterio de decisión según los costos y beneficios de acertar y equivocarse en cada contexto particular.

13.8 Por qué la contigüidad es un buen sesgo, y cuándo falla

Si los organismos son detectores de contingencia estadística más que registradores de contigüidad, ¿por qué la contigüidad temporal funciona tan bien como regla práctica en la mayoría de los entornos naturales?

La respuesta tiene que ver con la estructura causal del entorno ancestral. La mayoría de los mecanismos causales biológicamente relevantes —un depredador que ataca, una fruta que cae, una trampa que se cierra— operan con rapidez. La demora entre una acción y sus consecuencias en esos contextos es de segundos, no de horas. Cuando las cadenas causales son cortas y los mecanismos rápidos, la contigüidad temporal es un

indicador confiable de causalidad real. La selección natural favoreció sistemas que buscan primero en el vecindario temporal inmediato de cada consecuencia inesperada, porque en ese vecindario se encuentran la mayoría de las causas reales.

Pero el heurístico falla en condiciones específicas. Cuando las cadenas causales son largas —como en muchas relaciones entre comportamiento y sus consecuencias en el entorno humano— la acción y el resultado pueden estar separados por horas o días. Cuando los SBIs son frecuentes e independientes de la conducta del organismo —como en entornos muy enriquecidos con consecuencias no contingentes— la tasa de contigüidades accidentales sube y con ella la tasa de falsas alarmas. Y cuando el organismo ejecuta muchas respuestas concurrentes, el problema de asignar crédito a la respuesta correcta entre varias candidatas se vuelve especialmente difícil.

En esas condiciones, la contigüidad como heurístico produce errores sistemáticos —los que se conocen coloquialmente como “conductas supersticiosas”. No son fallas del mecanismo; son la consecuencia predecible de aplicar un heurístico adaptado a cierto tipo de entorno en condiciones diferentes.

13.9 Apertura hacia los modelos formales

Todo lo que hemos discutido en este capítulo puede reformularse con una pregunta computacional precisa: ¿cómo actualiza un agente el valor que asigna a un evento —estímulo o respuesta— en función de los resultados que ha obtenido en el pasado? Esa pregunta tiene una respuesta formal, y el siguiente capítulo la desarrolla a partir de la ecuación que Bush y Mosteller propusieron a mediados del siglo XX. El modelo es general: opera sobre cualquier evento predictivo, sea un estímulo que anticipa un SBI o una respuesta que lo produce. Por eso cap 10 cierra al mismo tiempo los dos capítulos precedentes.

La idea central es sencilla: el valor que el agente asigna a un evento se actualiza en cada ocasión, y la magnitud de esa actualización depende de la discrepancia entre lo que ocurrió y lo que se esperaba. Si el evento fue seguido de más SBI del anticipado, su valor sube; si fue seguido de menos, baja. Lo que hace esta ecuación especialmente interesante es que puede leerse de más de una manera: como un integrador con fuga, como un proceso de reducción de error de predicción, y como un filtro de media exponencial corrida que pondera más los eventos recientes. Cada lectura ilumina un aspecto distinto del mecanismo. El siguiente capítulo examina las tres con detalle.

13.10 Simulador 7.1: Inducción temporal y respuestas interinas/terminales

El siguiente código implementa una versión simplificada de la dinámica temporal que Staddon y Simmelhag documentaron. El SBI induce dos clases de respuestas cuya probabilidad cambia a lo largo del intervalo entre entregas: las interinas, que alcanzan su máximo poco después del SBI anterior, y las terminales, que crecen conforme se acerca el siguiente SBI.

[SIMULADOR 7.1 — Disponible en línea. El simulador implementa la dinámica temporal de Staddon y Simmelhag: el SBI induce respuestas interinas y terminales cuya probabilidad cambia a lo largo del intervalo entre entregas. Parámetros ajustables: duración del intervalo, tasa de decaimiento de las respuestas interinas, tasa de crecimiento de las terminales, número de intervalos a simular.]

Ejercicios con el Simulador 7.1:

Básico. Con los parámetros predeterminados (intervalo de 15 segundos), observa en qué momento del intervalo las dos curvas se cruzan. ¿Tiene sentido que Staddon y Simmelhag encontraran respuestas interinas en la primera mitad del intervalo y terminales en la segunda mitad?

Intermedio. Cambia el intervalo a 30 segundos y luego a 5 segundos. ¿Cómo cambia la ventana temporal en que dominan las respuestas interinas? ¿Qué predice esto sobre la distribución de respuestas cuando el SBI ocurre muy frecuentemente?

Avanzado. Modifica el parámetro DECAIMIENTO al mismo valor que ANTICIPACION. ¿Qué forma toman las curvas? ¿Desaparecerían prácticamente las respuestas interinas si el decaimiento fuera muy rápido? Relaciona tu respuesta con la idea de que las respuestas interinas son “conductas de espera” que llenan el tiempo entre SBIs.

13.11 Simulador 7.2: Detección de contingencia con gradiente de demora

Este simulador implementa un agente que aprende la tasa de SBIs contingentes a su respuesta versus la tasa de SBIs no contingentes, con un gradiente de demora que pondera más los SBIs cercanos en el tiempo.

[SIMULADOR 7.2 — Disponible en línea. El simulador implementa un agente que aprende la tasa de SBIs contingentes a su respuesta versus la tasa de SBIs no contingentes, con un gradiente de demora exponencial. Parámetros ajustables: $P(\text{SBI} \mid \text{respuesta})$, $P(\text{SBI} \mid \text{no respuesta})$, tasa de aprendizaje, demoras a comparar, número de sesiones.]

Ejercicios con el Simulador 7.2:

Básico. Observa cómo cambia la curva de aprendizaje al aumentar la demora de 0 a 32 segundos. ¿A partir de qué demora el agente deja de aprender claramente? Compara tu respuesta con los datos de Dickinson.

Intermedio. Cambia `P_SBI_SIN_RESPUESTA` al mismo valor que `P_SBI_DADO_RESPUESTA`. ¿Qué ocurre con el aprendizaje? Explica por qué en términos de contingencia estadística: ¿qué cambia en la relación entre respuesta y SBI?

Avanzado. Modifica la función `simular_aprendizaje` para que el gradiente de demora sea lineal en lugar de exponencial. ¿Cambia cualitativamente el patrón de resultados? ¿Qué forma del gradiente parece más consistente con los datos de Dickinson?

13.12 Conexiones

13.12.1 Hacia atrás: Asignación de crédito a estímulos (Capítulo 6)

La estructura argumentativa de este capítulo replica la del anterior. En el capítulo 8, la pregunta era si la contigüidad entre estímulo y SBI era condición necesaria y suficiente para el aprendizaje predictivo; la conclusión fue que no lo era en ninguna de las dos direcciones. Aquí la misma pregunta se formula para las respuestas, y la conclusión es la misma. El paralelismo no es casual: ambos problemas son instancias del problema de la asignación de crédito, y ambos se resuelven con el mismo mecanismo subyacente —la detección de contingencia estadística, modulada por sesgos inductivos que priorizan el espacio de búsqueda.

13.12.2 Hacia adelante: La ecuación de Bush y Mosteller (Capítulo 8)

El siguiente capítulo formaliza el mecanismo de actualización del valor que este capítulo ha descrito en términos cualitativos. La ecuación de Bush y Mosteller captura la idea central: el valor de una acción se ajusta en proporción a la discrepancia entre lo que ocurrió y lo que se esperaba. El lector que haya comprendido la lógica del aprendizaje por contingencia en este capítulo estará en buena posición para apreciar por qué esa ecuación tiene la forma que tiene —y para examinar las distintas maneras en que puede interpretarse.

13.12.3 Lateral: Programas de refuerzo e igualación (Bloque IV)

La distinción entre perspectiva molecular y perspectiva molar que introdujimos brevemente en este capítulo se volverá central en el Bloque IV. Los programas de refuerzo —reglas que especifican qué respuestas producen SBIs y con qué probabilidades— producen patrones de comportamiento que las teorías moleculares han tenido dificultades para predecir. Las perspectivas molares de Baum y el modelo formal de Killeen —que reservamos

intencionalmente para ese bloque— ofrecen descripciones más precisas de esos patrones, y su presentación allí tendrá más fuerza porque los estudiantes conocerán ya los datos que intentan explicar.

13.13 Ejercicios

1. El capítulo distingue entre el *origen* del repertorio conductual y la *selección* entre ese repertorio. ¿Cuál de las dos preguntas responde la Ley del Efecto? ¿Qué observación de los datos de Thorndike plantea la pregunta que la Ley del Efecto no responde?
2. Staddon y Simmelhag encontraron que las respuestas terminales eran más consistentes entre palomas que las respuestas interinas, a pesar de que las terminales eran las que más frecuentemente precedían a la comida. ¿Por qué este resultado contradice la explicación de Skinner? ¿Qué predice el principio de inducción que se aplica aquí?
3. Describe con tus propias palabras el procedimiento de Dickinson. ¿Cuál era el problema metodológico que el procedimiento intentaba resolver? ¿Por qué era necesario el grupo yoked para interpretar los resultados?
4. En el experimento de Lattal, las palomas aprendieron a picar la tecla a pesar de que el procedimiento DRO garantizaba que la comida nunca podía seguir inmediatamente a una respuesta. ¿Cómo interpretarías este resultado desde la perspectiva molecular? ¿Y desde la perspectiva molar? ¿Cuál de las dos interpretaciones parece más consistente con el resultado?
5. En el experimento de Killeen, las palomas adoptaban un criterio más liberal para atribuir causalidad cuando los aciertos valían más comida. Traduce este resultado a un contexto cotidiano: ¿puedes pensar en una situación humana en que el valor de acertar en una atribución causal lleva a las personas a atribuir causalidad con más frecuencia, incluso cuando la evidencia es ambigua? ¿Cuándo sería eso adaptativo y cuándo podría ser problemático?
6. El capítulo argumenta que la contigüidad es un buen heurístico en entornos donde los mecanismos causales operan rápido y las cadenas causales son cortas. Describe dos contextos —uno natural, uno del entorno humano contemporáneo— donde ese heurístico produce inferencias causales correctas, y dos contextos donde produce errores sistemáticos. ¿Qué tienen en común los contextos donde falla?
7. (*Reflexión*) La conducta supersticiosa humana —llevar amuletos, seguir rituales antes de un examen, evitar el número trece— puede interpretarse como resultado de los mismos mecanismos que Killeen estudió en palomas. ¿Qué condiciones aumentarían la probabilidad de que un organismo humano desarrolle una conducta supersticiosa? ¿Qué condiciones la reducirían? ¿Qué dice este análisis sobre la racionalidad de las supersticiones?

13.14 Resumen

El problema adaptativo de este capítulo es el del control: aprender que las propias acciones producen sucesos biológicamente importantes. Como en el capítulo anterior con los estímulos, la pregunta central es si la contigüidad temporal entre respuesta y SBI es condición necesaria y suficiente para ese aprendizaje.

La respuesta es la misma: ni lo uno ni lo otro. No es suficiente porque el experimento de Staddon y Simmelhag muestra que la contigüidad accidental no puede dar cuenta del patrón organizado de respuestas inducidas por el SBI; la organización temporal de ese patrón es predecible desde el principio de inducción, no desde la contigüidad accidental. No es necesaria porque Dickinson demostró que el aprendizaje ocurre con demoras de hasta treinta y dos segundos —y que ese aprendizaje se debe a la relación de dependencia real, no a contigüidades accidentales durante la demora— y porque Lattal demostró que el aprendizaje ocurre incluso cuando el procedimiento elimina por diseño cualquier posibilidad de contigüidad.

Lo que los organismos detectan es covariación estadística: la tasa de SBIs es mayor cuando la respuesta ocurre que cuando no ocurre. El experimento de Killeen confirma que esa capacidad de detección es real y funciona con alta precisión, que el criterio de decisión es ajustable según los costos y beneficios de acertar y equivocarse, y que la contigüidad temporal opera como señal de posible causalidad —con el resultado de que la probabilidad de atribuir causalidad a eventos independientes decrece conforme aumenta la separación temporal.

El capítulo 10 formaliza el mecanismo de actualización que hace posible esta detección de contingencia, a partir de la ecuación que Bush y Mosteller propusieron para describir cómo el valor de una acción se ajusta con la experiencia.

13.15 Lecturas Recomendadas

Thorndike, E. L. (1911). *Animal Intelligence: Experimental Studies*. Macmillan. — El texto original de Thorndike, con las observaciones sobre cajas puzzle que dieron origen a la Ley del Efecto. Los capítulos centrales son accesibles y muestran el razonamiento experimental de la época.

Staddon, J. E. R., & Simmelhag, V. L. (1971). The “superstition” experiment: A reexamination of its implications for the principles of adaptive behavior. *Psychological Review*, 78, 3–43. — La réplica directa de Skinner, con datos detallados sobre la distribución temporal de las respuestas. Más técnica, pero los resultados hablan por sí mismos.

Dickinson, A., Watt, A., & Griffiths, W. J. H. (1992). Free-operant acquisition with delayed reinforcement. *Quarterly Journal of Experimental Psychology*, 45B, 241–258. — El experimento de demora con el diseño yoked. Nivel moderado; especialmente valiosa la sección metodológica que justifica el uso del grupo de control.

Lattal, K. A. (1987). Considerations in the experimental analysis of reinforcement delay. En M. L. Commons, J. E. Mazur, J. A. Nevin & H. Rachlin (Eds.), *Quantitative Analyses of Behavior, Vol. 5*. Erlbaum. — El experimento DRO y su interpretación. Nivel moderado.

Killeen, P. R. (1978). Superstition: A matter of bias, not detectability. *Science*, 199, 88–90. — El experimento de detección de causalidad en palomas. Tres páginas. Uno de los artículos más elegantes de la literatura del aprendizaje.

Timberlake, W., & Lucas, G. A. (1989). Behavior systems and learning: From misbehavior to general principles. En S. B. Klein & R. R. Mowrer (Eds.), *Contemporary Learning Theories*. Erlbaum. — El marco de sistemas de comportamiento aplicado al aprendizaje instrumental. Conecta directamente con el capítulo 6 y da contexto para el principio de inducción.



14 Aprendizaje por Refuerzo

14.1 El Modelo de Bush y Mosteller

Los capítulos anteriores dejaron pendiente una promesa. En los capítulos de kinesis y retroalimentación vimos mecanismos que permiten a los organismos orientarse, navegar y regular variables internas con notable eficiencia. Pero tienen una limitación que señalamos entonces: responden a lo que ocurre *ahora*, sin ninguna capacidad de anticipar lo que está por ocurrir. El conductor que carga gasolina solo cuando el tanque está vacío llegará varado tarde o temprano. Lo que le falta es la capacidad de aprender que ciertas señales *predicen* la necesidad futura.

Los capítulos 6 y 7 establecieron las condiciones empíricas bajo las cuales esa capacidad predictiva se desarrolla —y las condiciones bajo las cuales no se desarrolla. Mostraron que los organismos son detectores de covariación estadística: aprenden que ciertos estímulos predicen SBIs, y que ciertas respuestas los producen. Pero no describieron el mecanismo formal que hace posible esa detección.

Este capítulo presenta ese mecanismo. En 1951, Robert Bush y Frederick Mosteller propusieron una ecuación de actualización que ha demostrado ser, pese a su simplicidad, una de las más productivas de la psicología del siglo XX. La ecuación puede leerse de tres maneras distintas. Las tres son algebraicamente idénticas, pero cada una ilumina un aspecto diferente de lo que el mecanismo hace y por qué tiene la forma que tiene.

Antes de la ecuación, sin embargo, conviene observar los datos que debe explicar.

14.2 Las curvas de aprendizaje

Desde finales del siglo XIX, el estudio del aprendizaje ha producido una regularidad empírica notable: cuando un organismo experimenta repetidamente la relación entre un evento y un SBI, alguna medida de su comportamiento cambia de forma característica. Aumenta rápidamente al principio y se va estabilizando conforme el aprendizaje madura. La curva resultante es negativamente acelerada —ganancias grandes al inicio, decrecientes con la práctica.

La figura 8.1 muestra un ejemplo con condicionamiento clásico: la frecuencia del reflejo de parpadeo en humanos expuestos a un tono seguido de un soplo al ojo, con diferentes intensidades del soplo (Parssey, 1948). La figura 8.2 muestra un ejemplo instrumental: la velocidad con que ratas tocan una palanca que produce comida, con diferentes niveles de privación (Ramond, 1954). La forma de la curva es la misma en ambos casos —estímulo o respuesta, condicionamiento clásico o instrumental, rata o humano. El modelo que

presentamos en este capítulo debe poder explicar ese patrón. Al final del capítulo veremos por qué lo logra.




Figura 10.1. Curvas de adquisición y extinción del reflejo de parpadeo en humanos (datos idealizados de Parssey, 1948).
intensidades del soplo al ojo. Línea continua: adquisición. Línea discontinua: extinción.

Figura 14.1: Curva de adquisición condicionamiento clásico

Note

Descripción. Curvas de adquisición y extinción del reflejo de parpadeo en humanos. Eje horizontal: ensayos. Eje vertical: frecuencia del reflejo condicionado. Tres curvas para distintas intensidades del soplo al ojo. Todas muestran el patrón negativamente acelerado durante la adquisición y el declive durante la extinción. Datos de Parssey (1948).]**




Figura 10.2. Curvas de adquisición de la velocidad de respuesta instrumental en ratas (datos idealizados de Ramond 1954). El patrón negativamente acelerado es idéntico al de la figura 10.1.

Figura 14.2: fCurva de adquisición condicionamiento instrumental

Note

Descripción Curva de adquisición de la velocidad de respuesta en condicionamiento instrumental con ratas. Eje horizontal: sesiones. Eje vertical: velocidad de respuesta. Dos curvas para dos niveles de privación alimentaria. El patrón es cualitativamente idéntico al de la figura 8.1. Datos de Ramond (1954).

Nota. La curva negativamente acelerada es el patrón *promedio*, pero existe un debate sobre si refleja el aprendizaje de organismos individuales o es un artefacto estadístico. Si distintos organismos aprenden de manera abrupta —un cambio discreto de no responder a responder— pero en ensayos distintos, el promedio grupal producirá una curva continua aunque ningún individuo la

siga. Skinner, Estes y más recientemente Gallistel han insistido en analizar datos de sujetos individuales por esta razón. En un capítulo posterior, cuando examinemos los modelos de Gallistel sobre tiempo y correlaciones, veremos que esa discusión tiene consecuencias formales sobre cómo debe concebirse el mecanismo de aprendizaje.

14.3 Aprendizaje por Refuerzo: elementos comunes

Todos los modelos de aprendizaje por refuerzo comparten una arquitectura básica. A cada evento que puede predecir un SBI —sea un estímulo condicionado o una respuesta— se le asigna un número que representa su *valor predictivo* actual. A lo largo del siglo XX ese número recibió distintos nombres: fuerza del reflejo, fuerza del hábito, fuerza asociativa. Nosotros lo llamaremos valor predictivo — V cuando hablemos de estímulos, Q cuando hablemos de respuestas— aunque en lo que sigue usaremos V para los dos salvo donde la distinción importe.

Una aclaración terminológica que conviene hacer desde el inicio: en la literatura matemática del aprendizaje, al SBI se le llama *refuerzo* y se representa con R o con λ . Usaremos ese término en las ecuaciones y derivaciones que siguen, recordando que es exactamente el mismo concepto que en los capítulos anteriores llamamos suceso biológicamente importante. Refuerzo = SBI.

El modelo propone que V se actualiza en cada *ensayo* —cada vez que el evento se presenta— como función de lo que ocurre en ese ensayo. Si el evento va seguido del refuerzo, V sube. Si ocurre sin refuerzo, V baja. El mero paso del tiempo entre ensayos no cambia V ; solo la experiencia directa con el evento lo modifica. Por eso se dice que son modelos basados en ensayos.

El modelo es una instancia de un sistema de retroalimentación, como los que vimos en el capítulo 5. La función del organismo transforma refuerzos en valor predictivo. La función del entorno —los programas de refuerzo que estudiaremos en bloques posteriores— transforma el comportamiento en consecuencias. Las dos funciones están acopladas en un lazo cerrado.

14.4 Ecuaciones en diferencia: un lenguaje ya conocido

Antes de escribir la ecuación, conviene reconocer su forma. En capítulos anteriores encontramos ecuaciones que describen cómo una variable cambia de un momento al siguiente como función de su valor previo y de alguna influencia externa. En el ejemplo de los contagios de covid, el número de casos hoy dependía del número de casos ayer y de la tasa de transmisión. En el modelo de ascenso de colina, el valor de la variable de decisión en el siguiente instante dependía de su valor actual y del cambio detectado en el entorno. Esas ecuaciones se llaman *ecuaciones en diferencia*: expresan el estado del sistema en el tiempo $t + 1$ como función del estado en el tiempo t . Son ecuaciones recursivas que se

aplican en cada paso al resultado del paso anterior, y siempre requieren especificar un valor inicial.

El modelo de Bush y Mosteller es exactamente una ecuación de esa naturaleza. V_{t+1} —el valor predictivo en el siguiente ensayo— depende de V_t —el valor acumulado hasta ahora— y de R_t —si hubo o no refuerzo en el ensayo actual. La dinámica que produce es la misma clase de trayectoria que ya conocen: un sistema que evoluciona ensayo a ensayo, que puede tener un equilibrio, y cuya trayectoria depende de los parámetros y del valor inicial.

14.5 Primera lectura: el integrador con fuga

La forma más directa de pensar en el modelo es como un proceso de carga y descarga. Cada refuerzo *carga* —fortalece— el valor del evento, y cada presentación sin refuerzo lo *descarga* —lo debilita. En este marco, V (o Q) es la cantidad de carga del sistema en cada momento. La batería del teléfono es el análogo cotidiano: se carga mientras está conectada, se descarga mientras se usa, y en ningún momento llega a cero de golpe ni alcanza el máximo instantáneamente.

Asumimos que V_{t+1} depende de solo dos factores: el valor acumulado hasta ahora, V_t , y lo que ocurrió en el ensayo actual, R_t —que vale 1 si hubo refuerzo y 0 si no lo hubo.

El punto clave es que estos dos factores no siempre deben tener el mismo peso. En un entorno muy estable, donde la historia acumulada es un buen predictor del futuro, tiene sentido darle más peso a la experiencia pasada que al ensayo actual. En un entorno cambiante, donde el pasado distante es poco relevante, tiene sentido darle más peso a la experiencia reciente. El parámetro α —entre 0 y 1— captura exactamente esa importancia relativa: cuánto pesa la experiencia acumulada frente al nuevo refuerzo. Si los dos factores deben sumar 1, la ecuación queda:

$$V_{t+1} = (1 - \alpha) V_t + \alpha R_t \quad \text{donde } 0 < \alpha < 1$$

Esta es la ecuación del *integrador con fuga*. El parámetro $(1 - \alpha)$ es el peso de la historia acumulada; α es el peso del refuerzo actual.

Para ver los dos procesos por separado, conviene examinar cada caso. Cuando hay refuerzo ($R_t = 1$), la ecuación carga el sistema: $V_{t+1} = (1 - \alpha)V_t + \alpha$, y el incremento es proporcional a qué tan lejos está V de su máximo. Cuando no hay refuerzo ($R_t = 0$), la ecuación se reduce a:

$$V_{t+1} = (1 - \alpha) V_t$$

En este caso la descarga es pura: cada presentación del evento sin refuerzo multiplica la carga actual por $(1 - \alpha)$, reduciéndola en una fracción α . Un sistema con mucha carga acumulada pierde más en términos absolutos que uno con poca carga —exactamente como una batería que se descarga más rápido cuando está llena que cuando está casi vacía.

Cuando α es cercano a 0, la historia acumulada domina: cada nuevo ensayo apenas mueve la cantidad de carga, y el sistema es resistente a fluctuaciones pero lento para detectar cambios reales. Cuando α es cercano a 1, el refuerzo actual domina: el sistema responde rápido a cambios pero es volátil ante fluctuaciones accidentales. Pensemos en una amistad de muchos años que siempre ha sido positiva. Una mañana esa persona no te saluda. Con α cercano a 0, ese evento apenas altera tu valoración de la relación —la historia pesa más. Con α cercano a 1, ese único evento tiene un peso desproporcionado sobre años de experiencia acumulada. Ninguno de los dos extremos es adaptativo en general; el valor óptimo de α depende de qué tan estable y predecible sea el entorno. Podemos ver que la velocidad del aprendizaje depende del valor de α , y es así como se le conoce en los libros de texto estandar.

La ecuación puede expresarse de dos formas equivalentes que la literatura usa indistintamente. La primera enfatiza el *nivel* del valor predictivo ensayo a ensayo:

$$V_{t+1} = (1 - \alpha) V_t + \alpha R_t$$

La segunda enfatiza el *cambio* de ensayo a ensayo. Si definimos $\Delta V = V_{t+1} - V_t$, restando V_t de ambos lados:

$$\Delta V = \alpha (R_t - V_t)$$

Ambas formas son idénticas. La primera es útil para simular la trayectoria de V ; la segunda hace visible de inmediato que el cambio es proporcional a la discrepancia entre lo que ocurrió y lo que se esperaba —anticipando la segunda lectura.

Para ver cómo funciona la primera forma, sigamos el siguiente ejemplo numérico. Con $\alpha = 0.5$, $V_0 = 0$, y cuatro ensayos de adquisición seguidos de tres de extinción:

Ensayo	R_t	V_t	$V_{t+1} = 0.5 V_t + 0.5 R_t$	Fase
1	1	0.000	0.500	Adquisición
2	1	0.500	0.750	Adquisición
3	1	0.750	0.875	Adquisición
4	1	0.875	0.938	Adquisición
5	0	0.938	0.469	Extinción
6	0	0.469	0.234	Extinción
7	0	0.234	0.117	Extinción

Noten el patrón en ambas fases. Durante la adquisición, el V obtenido en cada ensayo se convierte en el nuevo V_t del ensayo siguiente; el valor crece rápidamente al principio y se desacelera conforme se aproxima a 1. Durante la extinción —cuando $R_t = 0$ y la ecuación se reduce a $V_{t+1} = (1 - \alpha)V_t$ — el proceso se invierte: la carga disminuye en cada ensayo en una fracción α de su valor actual. Desde 0.938, la descarga es más rápida que desde 0.234, porque hay más carga que perder. Con $\alpha = 0.2$ el proceso de adquisición es más lento: $V_1 = 0.2$, $V_2 = 0.36$, $V_3 = 0.488$, $V_4 = 0.590$; y la extinción también es más lenta. La forma de las trayectorias es la misma; cambia la velocidad.




Figura 10.3. Trayectorias de V para dos valores de α , con refuerzo constante ($R = 1$) y $V_0 = 0$. Ambas curvas son negativamente aceleradas y convergen a 1; $\alpha = 0.50$ converge más rápido que $\alpha = 0.20$.

Figura 14.3: Curvas de aprendizaje para diferentes alphas

Note

Descripción: Trayectorias de V para $\alpha = 0.2$ y $\alpha = 0.5$, con refuerzo constante ($R = 1$) y $V_0 = 0$. Eje horizontal: ensayos. Eje vertical: valor V . Ambas curvas son negativamente aceleradas y convergen a 1, pero con velocidades distintas. Con $\alpha = 0.5$ la convergencia es más rápida; con $\alpha = 0.2$ es más lenta.

y suave. Datos de las diapositivas del curso.




Figura 10.4. Trayectoria de V durante adquisición ($R = 1$, azul) y extinción ($R = 0$, naranja), $\alpha = 0.3$. La descarga es proporcional al valor acumulado; más carga, mayor pérdida por ensayo.

Figura 14.4: Trayectorias adquisición y extinción

Note

Descripción: Trayectoria de V durante adquisición ($R = 1$) y extinción ($R = 0$), $\alpha = 0.3$. Eje horizontal: ensayos. Eje vertical: valor V . V crece durante la adquisición siguiendo la curva negativamente acelerada; decrece durante la extinción siguiendo una curva especular. La tasa de cambio en ambas fases es proporcional al valor actual de V .

14.6 Segunda lectura: la reducción del error de predicción

La misma ecuación puede leerse de otra manera. Basta reordenar los términos algebraicamente:

$$V_{t+1} = (1 - \alpha) V_t + \alpha R_t$$

$$V_{t+1} = V_t - \alpha V_t + \alpha R_t$$

$$V_{t+1} = V_t + \alpha (R_t - V_t)$$

La expresión $(R_t - V_t)$ es la clave. Es la diferencia entre lo que ocurrió (R_t) y lo que el organismo esperaba (V_t): el *error de predicción*. En la literatura contemporánea se representa con δ :

$$\delta_t = R_t - V_t$$

Con esa notación, la ecuación del nivel queda:

$$V_{t+1} = V_t + \alpha \delta_t$$

Y la ecuación del cambio queda:

$$\Delta V = \alpha \delta_t$$

Si el refuerzo fue mayor de lo anticipado, δ es positivo y V sube. Si fue menor, δ es negativo y V baja. Si el refuerzo ocurrió exactamente como se esperaba — $R_t = V_t$ — entonces $\delta = 0$ y V no cambia. En la literatura contemporánea, esta forma se conoce como la *regla delta*, y es la versión dominante en la psicología del aprendizaje y las neurociencias.

Esta lectura sugiere una intuición sobre el bloqueo de Kamin que vimos en el capítulo 6. Si un estímulo ya predice perfectamente el refuerzo — $V_t = R_t$ — entonces $\delta_t = 0$: no hay sorpresa y no hay nada que aprender. Cuando se presenta el compuesto AB, si A ya predice el refuerzo perfectamente, el error de predicción debería ser cero y B no debería aprender nada. La intuición es correcta, pero la

ecuación de Bush y Mosteller no puede derivarla formalmente: opera sobre eventos individuales y no tiene mecanismo para distribuir el error de predicción entre estímulos simultáneos. Esa extensión es precisamente lo que Rescorla y Wagner añadieron en 1972, y es el tema del capítulo siguiente.

La figura 8.5 muestra la evolución paralela de V y δ a lo largo del aprendizaje. Al inicio, cuando V es bajo y el refuerzo ocurre, δ es grande y positivo —mucha sorpresa, mucho aprendizaje. Conforme V crece y se aproxima al valor de equilibrio, δ se hace cada vez más pequeño. El aprendizaje se desacelera no porque el mecanismo cambie, sino porque hay menos error que corregir. La curva negativamente acelerada es, desde esta perspectiva, la consecuencia directa de un sistema que aprende proporcionalmente a su propia ignorancia.




Figura 10.5. Trayectorias paralelas de V (panel superior, azul) y δ (panel inferior, naranja), $\alpha = 0.3$, $R = 1$. Conforme V crece, proporcionalmente. El aprendizaje se desacelera porque el error de predicción disminuye.

Figura 14.5: Trayectoria de V y de error de predicción

Note

Descripción: Trayectorias paralelas de V y δ . Panel superior: V crece de 0 hacia 1 siguiendo la curva negativamente acelerada. Panel inferior: δ decrece desde su valor máximo inicial hacia cero. La relación entre las dos curvas ilustra que el aprendizaje se desacelera porque el error de predicción disminuye. $\alpha = 0.3$, $R = 1$.

Esta lectura también conecta con la neurociencia. A finales de los años noventa, Wolfram Schultz encontró que las neuronas dopaminérgicas del mesencéfalo de primates se comportan exactamente como predice la señal δ . Al inicio del entrenamiento disparan cuando ocurre el refuerzo inesperado. Conforme el animal aprende, la respuesta dopaminérgica se desplaza hacia el estímulo predictor —el momento donde se produce el error de predicción— y desaparece en el momento del refuerzo, porque este ya no es sorprendente. Cuando el refuerzo esperado no ocurre, las neuronas muestran una supresión de actividad: un error de predicción negativo. La dopamina no es simplemente una señal de placer; es una señal de error de predicción.